한국어 RFP, 근거와 함께 답합니다

제안요청서를 읽고, 관련 내용으로 답변하는 시스템을 만들었습니다.

문서와 질문

한국어 RFP
HWP·PDF + 사용자의 질문

→

검색하고 답변

관련 문서 조각을 찾고
그 내용을 읽어 답합니다.

→

답변과 근거 번호

필요한 정보를 답하고
참고한 문서로 연결합니다.

> 긴 문서의 요구사항과 조건을 찾고,
> **답변이 어디에서 나왔는지 확인하는 것**이 목표입니다.

문서를 찾고, 근거로 답합니다

문서를 미리 준비하고, 질문 종류에 맞는 근거로 답합니다.

① 문서 준비 · 미리 저장



② 질문 처리 · 본문 질문의 대표 경로



답변 옆에서 근거를 확인합니다

질문 사무실 예약 서비스에 필요한 기능은 무엇인가요?

검색된 문서 조각

[1] 필수 기능은
회의실 예약, 예약 취소,
사용 현황 조회입니다.

EXAONE

→

질문과 근거를
함께 읽습니다

답변

회의실 예약, 예약 취소,
사용 현황 조회가
필요합니다. [1]

답변의 [1]을 따라가면, 어떤 문장에서 나온 내용인지 확인할 수 있습니다.

번호가 있다는 사실만으로 답변의 내용까지 옳다고 보장되지는 않습니다.

검색은 KURE를 선택했습니다

같은 개발 질문 30개로 비교했습니다. 모든 지표에서 KURE가 앞선 것은 아닙니다.

고정 조건: 같은 질문 · 고정 길이 조각 · Dense Top-5 · 리랭커 끔

비교한 내용	KURE-v1	BGE-m3
검색 결과의 사실 포함 지표[1]	**0.7312**	0.6355
첫 결과가 정답 문서인 질문	26 / 30	**27 / 30**

[1] 질문마다 필요한 핵심 표현 중 검색된 글에 포함된 비율을 구한 뒤,
정답 사실이 있는 **23문항에서 평균**냈습니다. **답변 정확도가 아닙니다.**

필요한 사실을 더 가져온 점을 보고 **KURE를 유지**합니다.
첫 결과의 적중 수는 BGE가 더 높았습니다.

답변은 EXAONE을 선택했습니다

응답 시간과 적절한 답변 보류를 봤습니다. 근거 충실도는 Qwen이 높았습니다.

같은 개발 질문 30개 · 같은 KURE·Dense Top-5 · temperature 0 · 문맥창 8192토큰

비교한 내용	EXAONE 3.5 7.8B	Qwen 3.5 9B
응답 지연 p95[1] · 초	**9.645**	14.027
정답 근거가 없는 7문항에서 보류	**7 / 7**	6 / 7
자동 심판의 근거 충실도 · 5점	4.23	**4.73**

[1] 응답 시간의 95백분위입니다. 낮을수록 느린 응답까지 짧았습니다.
보류는 정답 근거가 없는 문항에서 평가했습니다. 많이 보류할수록 좋다는 뜻이 아닙니다.

작은 과거 실험입니다. 자동 채점 변동과 시드 미기록의 한계가 있습니다.

실행 결과와 답변 품질을 나눠 봤습니다

문서 처리와 구성 실행을 확인했습니다. 처리 성공이 정확도를 뜻하지는 않습니다.

문서 처리

100개 문서

HWP 96개 + PDF 4개에서
텍스트 추출을 확인했습니다.

최근 팀 구성 비교

8개 질문 × 6개 구성

= **48회 실행**

38회 정상 + 10회 오류

> 요구 조건 누락과 다른 사업 정보 혼입이 남아 있습니다.
> **답변 품질과 오류 원인은 따로 검증해야 합니다.**

최근 비교는 **gpt-6-luna/low** 실행입니다. 앞장의 EXAONE·Qwen 실험과 별개이며,
변경 요소 하나의 효과를 분리한 비교도 아닙니다.

현재 구성은 유지하며 개선합니다

새 기초 구성은 개선 요소를 하나씩 넣어 보기 위한 실험 출발점입니다.

유지하는 현재 구성

검색 KURE-v1 + Chroma

답변 EXAONE 3.5 7.8B

기존 선택과 비교 기록을 보존하고,
개선 요소를 반영할 때 다시 검증합니다.

개선 시험용 기초 구성

검색 TF-IDF + JSON 색인

답변 Haiku 4.5

문서 읽기·분할·검색·답변을
최소 흐름으로 나눴습니다.

> 새 구성에서 확인한 것은 **합성 문서 2개의 연결 성공과 PR #2 병합**입니다.
> 실제 RFP 품질이 더 낫다고 확인한 것은 아닙니다.

두 구성의 점수를 직접 비교하지 않고, 각 구성 안에서 조건을 맞춥니다.

한 번에 하나씩 바꿔 비교합니다

검색 모듈을 바꾸는 예시입니다. 답변 모델과 나머지 조건은 그대로 둡니다.

구성 A	같은 문서·질문 변경 전	→	기존 검색 모듈 TF-IDF	→	Haiku 4.5 같은 생성 설정
구성 B	같은 문서·질문 변경 후	→	**교체할 검색 모듈** **이 요소만 변경**	→	Haiku 4.5 같은 생성 설정

고정할 조건 문서 · 질문 · 실행 환경 · 생성 설정 · 채점 기준

근거를 찾았는지, 조건을 빠뜨렸는지, 잘못된 주장을 했는지 봅니다.
응답 시간과 실행 실패도 함께 기록합니다.

개선이 확인된 변경만 반영합니다

실험용 구성의 개선을 확인한 뒤, 현재 구성에서도 같은 조건으로 재확인합니다.

① 기초 구성에서 비교

Haiku를 고정한 A/B 비교
한 요소의 효과를 확인합니다.

→

② 현재 구성에서 재확인

EXAONE을 고정한 A/B 비교
현재 구성에서도 효과를 봅니다.

→

③ 채택·보류 이유 기록

품질 · 중요한 오류 · 응답 시간
근거와 판단을 함께 남깁니다.

> 두 비교는 각각 조건을 맞춰 따로 수행합니다.
> **현재 구성에서도 좋아지고 중요한 오류가 늘지 않은 변경만 반영합니다.**

통과 기준은 실험 전에 정합니다.
처음 보는 질문과 사람의 검토도 포함합니다.