RAG 모델 버전과 구조 설계

2026-10-14 | 팀 공유용 코드와 실행 기준

목적: 사용자 기준 코드는 Baseline, 네 팀원 후보는 Version 1~4로 구분해 팀원이 선택하여 재사용합니다. 기존 modular 저장소와 병합하지 않았습니다.

배포 기본: Claude Haiku 4.5 API - claude-haiku-4-5-20251001
실제 정리 수: Baseline 1개 + 후보 4개 = 총 5개 구성

GitHub 공개 공유 저장소 열기

버전별 차이

폴더	파서 / 청크	임베딩 / 검색	상태
Baseline	custom olefile / PyMuPDF fixed 1000 / 200	KURE-v1 / Chroma dense Top5 / 재순위 off	기준 코드 실행 가능
Version 1	HwpHwpxLoader / Markdown PDF 700 / 100	BGE-m3-ko / FAISS business 식별 / BM25 RRF / Alibaba	고정 원본 연결 후보
Version 2	같은 파서 700 / 100	BGE-m3-ko / FAISS Kiwi BM25 RRF / Alibaba	고정 원본 연결 후보
Version 3	custom HWP / Markdown PDF child 800 / 150 parent 8000	OpenAI 임베딩 / FAISS RRF / BGE 재순위 / parent Top4	고정 원본 연결 후보
Version 4	custom HWP / Markdown PDF 500 / 100	KoE5 / FAISS dense Top4 또는 RRF Top5	고정 원본 연결 후보

사용 범위: Baseline은 공유된 실행 코드를 제공합니다. Version 1~4는 원본 LICENSE를 찾지 못해 새 코드 복사본을 공개하지 않았습니다. 권한 확인 후 고정 로컬 모듈을 연결합니다. 번호는 성능 순위가 아닙니다.

발표 자료는 기존 평가 시점 구성입니다. 배포 실행 기본은 Haiku 4.5이며 동일조건 품질 재평가 전입니다.

코드와 아키텍처

문서 준비 - Baseline



입력 문서를 파싱하고 출처 ID를 유지합니다. 청크·벡터·문서 요약은 로컬 데이터 폴더에 준비합니다. 원문·벡터·요약은 저장소에 올리지 않습니다.

질문 처리 - Baseline



질문 재작성, 분류, 요약, 비교 병합과 생성은 같은 Anthropic 공급자를 사용합니다. 약한 근거는 거절하고 근거 ID·숫자·날짜를 검사합니다. 이 규칙은 독립적인 의미 정답 판정을 보장하지 않습니다.

실제 모듈과 입출력

위치 / 역할	입력 → 출력
Baseline/rfp_rag/ingest/load.py parser	data_dir → 문서 dict 목록; ID·본문·파서 상태
ingest/chunk.py chunker	문서 dict + 크기/겹침 → 청크 dict 목록
rfp_rag/index.py embedder	cfg → 임베딩 공급자; 색인은 CLI로 별도 구축
rfp_rag/retrieve.py retriever	cfg + question → 근거 Document 목록
rfp_rag/pipeline.py / answer.py generator + verification	question + state + cfg → 답변·근거·found; 대화 상태 갱신
rfp_rag/providers.py 공급자 연결	cfg + 개인 환경 키 → ChatAnthropic; 구조화 결과를 기존 JSON 문자열 규약으로 변환
Baseline/team_versions/runtime.py 버전 공통 입구	version + 고정 로컬 모듈 + providers → run/call 세션

팀원이 시작하는 방법

1. 버전과 키 설정

루트에서 python run.py --list 또는 --version baseline / v1 / v2 / v3 / v4로 설정을 확인합니다. 설치와 실제 실행은 Baseline 폴더에서 합니다. .env.example의 ANTHROPIC_API_KEY는 빈 값이며 .env는 커밋에서 제외합니다. .env를 자동으로 읽지는 않습니다.

```
cd Baseline
python -m venv .venv
.venv₩Scripts₩activate
python -m pip install -r requirements.txt

$secureKey = Read-Host "Anthropic API key" -AsSecureString
$env:ANTHROPIC_API_KEY = ([System.Net.NetworkCredential]::new("", $secureKey)).Password
```

2. 데이터 준비와 실행

data/raw에 본인 문서와 data_list.csv를 둡니다. 준비한 KURE 모델·색인·요약이 필요합니다. 색인 구축은 모델이 없으면 다운로드할 수 있고 요약·질문 호출은 API 비용이 발생합니다. 이 작업에서 다운로드와 API 호출은 0회입니다.

```
python -m rfp_rag.ingest.chunk --exp 07_verify
python -m rfp_rag.index --exp 07_verify --embedder nlpai-lab/KURE-v1 --method fixed
python -m rfp_rag.ingest.enrich --exp 07_verify
python -m rfp_rag.pipeline --exp 07_verify --ask "사업 요구사항을 설명해 줘."
```

3. 후보의 실행 연결과 평가 한계

각 Version/version.json의 historical_settings는 원본 조건, deployment_generator는 Haiku 조건입니다. 권한 확인된 로컬 모듈의 파일 목록·SHA-256을 검사한 뒤 연결합니다. Version 1~2는 parser → cleaning → chunker → embedder → retriever → Haiku 연결 → generator, Version 3~4는 parser → chunker → embedder → Haiku 연결 → generator → retriever입니다. connect_haiku() 이후 원래 모델 초기화 단계를 다시 호출하지 않습니다.

공통 run/call 입구에서 원래 인자·반환값을 유지합니다. 원본 공급자·경로·메타데이터는 호출자가 전달합니다. Version 3의 OpenAI 임베딩 조건은 유지하므로 준비한 벡터나 별도 OpenAI 환경 설정이 필요할 수 있습니다. Haiku는 답변 생성 모델입니다.

검증: 설정·공통 호출·고정 파일·권한 처리·세션 격리·Haiku mock 검사, 기존 코어 합성 검사와 네 원본 흐름의 합성 연결 검사를 통과했습니다. 실제 API 모델 성능과 새 설치 환경의 전체 실행은 미검증입니다.

근거: 기존 07_verify는 대체 후보 전체의 개선이 입증되지 않아 유지한 기준입니다. 과거 EXAONE·Luna 관측과 새 Haiku 실행 설정을 구분합니다. 같은 조건의 전체 순위는 보류합니다. 원본 SHA·필수 attribution·미채택 근거는 Baseline/docs에 보존합니다. 발표자료는 presentations에 원본 그대로 있습니다.