FINAL 02 제안요청서 검색과 답변 최종 기술 리포트

2026년 10월 20일 최종 제출용 정리

1 프로젝트 목표와 최종 선택

이 프로젝트는 HWP와 PDF 제안요청서 100건에서 질문과 관련된 근거를 찾아 한국어 답변을 만드는 RAG 시스템이다. 긴 문서의 요구사항과 조건을 사람이 일일이 찾는 부담을 줄이는 것이 목표다.

현재 실행 구성은 FINAL-02 하나로 정리했다. 10월 19일 실험 기록의 채택 제안 이후, 사용자가 10월 20일 제공한 재현 코드를 최종본으로 선택했다. 이전 구현과 평가의 출처는 문서와 Git 이력에 보존한다.

FINAL-02는 FINAL-01보다 문맥과 기록된 검색 시간이 작고 질문 분해 호출이 추가되지 않는다. 답변 점수의 작은 차이는 통계적으로 유의하지 않다고 기록돼 있어, 정확도가 더 높다고 단정하는 대신 실행의 단순성과 입력 부담을 고려해 선택했다.

단계	FINAL-02 설정
문서 처리	HwpHwpxLoader 표 Markdown과 pymupdf4llm, 제공 파싱 캐시
청킹	1000/200, 구분자 줄바꿈과 공백, 사업명 헤더 없음
임베딩과 색인	dragonkue/BGE-m3-ko, 정규화, FAISS
검색	사업 식별 후 Dense 20과 Kiwi BM25 20, RRF k=60
재순위화	BAAI/bge-reranker-v2-m3, 최종 문맥 6개
생성	claude-haiku-4-5-20251001, 원본 FINAL-02 프롬프트
평가	Gemini 3.1 Flash-Lite Judge, RAGAS 0.3.9 F1와 Faithfulness
자료 범위	문서 100건, 평가 문항 300개, 제공 결과의 1회 실행

이 리포트는 제공된 코드와 저장 결과를 검토한 최종 정리다. 이번 모듈화에서 모델을 실행하거나 새로운 정확도·비용·속도 개선을 측정하지 않았다.

2 실행 구조와 모듈화

문서 준비와 질문 처리를 나눴다. 문서 준비는 파싱 캐시와 메타데이터를 연결하고 청크를 만든다. 질문이 들어오면 사업을 식별하고 검색 후보를 합쳐 재순위화한 뒤 상위 근거를 생성 모델에 전달한다.

문서와 파싱 캐시 → 청킹과 임베딩 → 사업 식별과 검색 → RRF와 재순위화 → 근거 6개와 답변 → 검색과 답변 평가

모듈	역할
config.py	최종 모델·문서 선택·청킹·검색 설정
parsing.py	HWP/PDF 추출과 성공·실패 캐시
data.py	평가셋 1.1 검증, 메타데이터 연결과 말뭉치 준비
chunking.py	헤더 없는 문서 분할과 청크 번호 부여
embedding.py	원본 BGE 임베딩 모델 연결
routing.py	사업명·별칭·기관을 이용한 사업 식별
retrieval.py	사업 범위별 FAISS·Kiwi BM25와 RRF 결합
reranking.py	검색 후보 전체를 BGE로 다시 정렬
generation.py와 pipeline.py	원본 프롬프트·생성 연결·답변 캐시·출처 기록
metrics.py와 evaluation.py	근거 문장 순위·포함률과 Gemini 채점
experiments.py	base·ragas·summary, 문항별 체크포인트
__main__.py	ask·평가·오프라인 검사 명령

각 모듈은 rfp_rag 아래에 있다. 사업을 찾지 못하거나 모호하면 전체 문서에서 검색하는 원본 동작을 유지했다. 질문 분해·청크 사업명 헤더·숫자 후처리를 새로운 기능처럼 추가하지 않았다.

원본 설정 파일에는 10문서·700/100·GTE가 남아 있었으나 final02.py가 이를 덮어썼다. 새 기본값은 실제 FINAL-02 실행 설정과 맞췄고, 프롬프트는 원본 파일의 바이트를 그대로 보존했다.

3 시도한 구성과 설계 변화

초기 구현과 팀원 코드 접수, 작은 조건 비교, 전체 문서 검색 평가, 최종 답변 평가를 서로 다른 근거로 다뤘다. 평가셋과 생성·채점 모델이 다른 수치를 같은 순위표로 합치지 않았다.

단계	시도한 것	해석과 처리
초기 07_verify	KURE·Chroma·EXAONE, 질문 분기와 숫자 검증	초기 개발·확인용 평가 조건으로 보존
Version 1과 2	사업 식별, BGE·FAISS, Kiwi BM25 비교	원본 코드 접수와 실제 품질 평가를 구분
Version 3과 4	HWP 보정, parent/child, OpenAI 또는 KoE5	서로 다른 원본 구성으로 보존
10문서와 30문항	임베딩·프롬프트·Judge·리랭커·청크 크기 변경	검색 순위와 생성 품질을 따로 해석
100문서와 300문항	검색 범위 확대, 근거 누락과 문맥 길이 확인	검색 전용 결과를 답변 정확도로 표현하지 않음
최종 두 후보	FINAL-01과 FINAL-02의 같은 프롬프트 비교	전체 문맥 부담과 추가 호출을 고려해 FINAL-02 선택

청킹과 검색에서 배운 점

작은 실험에서는 700/100에서 1000/200으로 청크를 넓히며 필요한 근거를 한 조각에 더 담는 방향을 확인했다. 다만 맞는 청크 하나를 찾는 것과 여러 절에 흩어진 근거를 모두 모으는 것은 다른 문제였다.

리랭커나 청크 크기로 검색 순위가 좋아져도 생성 지표가 같은 폭으로 좋아지지는 않았다. 이 때문에 검색 성과와 답변 성과를 분리하고, 질문 유형별 근거 누락도 함께 보았다.

과거 코드의 보존

구버전 실행 폴더와 선택기는 현재 기본 실행에서 제거했다. 당시 README·출처·평가 해석·설정 기록은 docs/history에 보존했다. 교체 전 전체 코드는 Git commit 0f77930191bcb5d5b12c13a8d52d08184154c2f6에서 확인할 수 있다. Git 이력과 별도 modular 저장소는 변경하지 않았다.

4 FINAL 02 결과와 지표 정의

제공된 all_scores.csv 300행을 읽어 평균을 다시 계산했고 five_metric_summary.csv와 같은 값을 확인했다. 문항별 질문·답변·문맥·채점 이유는 공개하지 않고 숫자 집계만 보존한다.

지표	결과	분모와 뜻
Hit@5	0.9550	289문항, 근거가 처음 나온 순위가 5 이내
MRR	0.8618	289문항, 첫 근거 순위의 역수 평균
LLM-as-Judge	0.9300	300문항, Gemini 사실 정확성·필수 항목 채점
Factual Correctness F1	0.5749	300문항, RAGAS 사실 일치의 F1
Faithfulness	0.9848	300문항, 답변 주장이 주어진 근거에 충실한 정도
근거 문장 재현율	0.9055	300문항, 최종 문맥에 들어간 필요한 근거 비율
근거 전부 전달	252/300	0.8400, 필요한 근거가 모두 포함된 문항
평균 문맥 길이	5,079.2167자	300문항, 생성 모델에 넘긴 문맥 길이
검색 시간 중앙값	1.704초	300문항, 최초 색인 구축은 제외한 기록

근거 문장이 원본 청크와 연결되지 않은 11문항의 Hit@5와 MRR은 결측값이다. 이를 0점으로 채우지 않는다. 검색 점수의 분모 289와 답변 평가의 분모 300을 함께 적어 해석 범위를 분명히 했다.

Faithfulness가 높아도 질문에 필요한 사실을 모두 답했다는 뜻은 아니다. 이번 결과에서도 F1과 근거 전부 전달 비율을 함께 봐야 한다. 원본 계산은 텍스트 정규화 후 근거 문장 포함 여부를 사용하므로 의미가 같은 표현을 모두 판별하는 평가가 아니다.

5 최종 두 후보의 비교와 선정

항목	FINAL-01	FINAL-02
검색 단위	parent 1400/200과 child 350/50	일반 청크 1000/200
질문 분해	사용	사용하지 않음
Judge	0.920	0.930
Factual Correctness F1	약 0.551	0.5749
Faithfulness	약 0.978	0.9848
근거 전부 전달	257/300	252/300
평균 문맥 길이	6,982자	5,079자
검색 시간 중앙값	4.9초	약 1.7초
여러 절 질문의 근거 수집	0.77	0.69

FINAL-01 수치는 제공 재현 가이드와 기존 팀 비교 기록을 인용했다. 해당 후보의 원문 결과를 이번에 다시 실행하거나 통계 검정을 재계산하지 않았다. FINAL-02 수치는 제공된 결과 파일로 대조했다.

답변 지표 세 개는 기록상 FINAL-02가 조금 높지만, 기존 문항별 비교에서 차이의 신뢰구간이 0을 포함한다. 유의한 차이를 못 찾았다는 결과를 두 모델의 동등성을 증명한 결과로 바꾸지 않는다.

FINAL-02의 문맥은 약 27% 짧고 기록된 검색 중앙값도 작다. 질문 분해용 추가 호출이 없고 실행 구성이 단순하다는 점을 고려해 최종 실행으로 선택했다. 여러 절 질문의 근거 확보에는 FINAL-01의 강점이 남으므로 선택이 모든 질문 유형의 우월성을 뜻하지 않는다.

Hit@5와 MRR은 두 후보의 순위 단위가 parent와 일반 청크로 다르다. 이를 나란히 놓고 검색 성능의 승패를 정하지 않는다. 다른 장비·최초 구축·동시 부하가 섞인 속도 비교로 확대하지 않으며, 비용 절감률도 새 실측 없이 제시하지 않는다.

6 재현에 필요한 자료와 실행

정확한 재현에는 원본 문서 100건, 함께 제공된 파싱 캐시, data_list.csv, 평가셋 dev_benchmark_v1.1.json이 필요하다. 이 자료는 원문과 질문·답변을 담을 수 있어 공개 저장소에서 제외했다. 승인된 비공개 보관본을 별도로 준비해야 한다.

```
python -m pip install -r requirements.txt
python -m pip install --no-deps langchain-hwp-hwpx-loader==0.1.1
python -m rfp_rag ask --query "이 사업의 요구사항을 설명해 줘."
python final02.py base --limit 3 --out-dir results/FINAL-02-test
python final02.py base
python final02.py ragas
python final02.py summary
```

ask와 base는 임베딩·리랭커를 로드하고 Claude를 호출할 수 있다. base의 Judge와 ragas는 Gemini를 호출한다. 위 명령은 재현 안내이며 이번 정리에서 실행하지 않았다. 설치·다운로드와 예상 호출량·예산을 확인한 뒤 실행해야 한다.

FINAL-02는 VM의 파싱 캐시를 기준으로 한다. Colab의 다른 캐시와 다섯 문서에서 본문 길이가 다르다고 제공 가이드가 명시한다. 같은 파일명이라도 본문이 다르면 청크와 검색 결과가 달라진다. 비공개 자료의 해시를 source-manifest.json에 기록해 같은 사본인지 비교할 수 있게 했다.

원본의 문항별 체크포인트, 다른 설정의 결과 폴더 재사용 차단, RAGAS 호출마다 Gemini 클라이언트를 만드는 동작을 유지했다. 결과 폴더와 .env는 Git에서 제외한다. 키 일부를 출력하던 구문은 제거했다.

모델 로더의 trust_remote_code 설정은 원본과 같다. 모델 revision과 제공 코드를 검토하기 전에는 자동 다운로드나 실행을 하지 않는다. GPU·새 설치 환경·외부 API의 실제 호환성은 이번 오프라인 검증으로 확인되지 않았다.

7 검증과 남은 한계

검증	확인한 결과
합성 단위 검사	12개 통과. 네트워크 연결을 막고 모의 모델 사용
원본과 모듈화 비교	질문 3개와 캐시 재호출을 합친 6건의 결과가 같음
원본 함수와 클래스	23개 정의의 AST 구문 구조가 같음
생성 프롬프트	제공 원본과 바이트가 같음
기존 저장 결과	300행 집계 평균이 제공 요약 CSV와 같음
새 모델 성능 실행	0회. 유료 API·모델 다운로드·전체 재평가 없음

테스트는 사업 식별과 전체 검색 복귀, RRF 결합과 중복 제거, 재순위 후 6개 문맥, 답변 캐시, 근거 결측값과 포함률, 잘못된 Judge 점수 거절, 평가셋 문서·문항 검증을 다룬다. 합성 입력이므로 실제 문서 파싱 품질과 모델 정확도를 대신하지 않는다.

이 실험은 기존 1회 실행과 LLM 채점에 의존한다. 반복 실행의 변동, 파싱 캐시 차이, 여러 절 근거 누락, 평가 단위 차이를 남은 한계로 둔다. 모델 설정만 보고 실제 실행 성과를 추정하거나 10월 14일의 OpenAI·44문항 개인 리포트를 FINAL-02의 성능 근거로 사용하지 않는다.

출처와 협업 기록

실행 원본은 이원영의 10월 19일 FINAL-02 재현 묶음이다. 가이드는 김현경 final_pipeline의 짧은 commit 7db81eb을 사용했다고 적는다. 전체 원격 SHA는 별도로 확인하지 못했다. 원본 압축 파일 SHA256은 ee19febf228e9634391eb59cdad68d029e0dc837027483076a0db54b0491630c이다.

기존 최종 실험 보고서의 검토 배경·변경 조건·해석·한계 순서를 참고했다. 자료 근거는 제공 재현 가이드, run_config.json, five_metric_summary.csv와 all_scores.csv, 팀 실험 기록표, 교체 전 저장소 출처 문서다. 원본 RFP와 문항별 답변은 공개하지 않는다.

README에는 팀원별 실제 확인된 일지 링크를 제공하고 원문을 바꾸지 않았다. GitHub 목차·표·접기를 사용한다. VM 대시보드 종료에 대비한 개인별 정적 보존과 첨부 내보내기는 별도이며, 최신 운영 자료와 로컬이 동기화됐다고 단정하지 않는다.