코드잇 AI 엔지니어 부트캠프 13기 · 중급 프로젝트 · 파트3 2팀

# 공공입찰 제안요청서(RFP) 기반 RAG 질의응답 시스템 프로젝트 보고서

HWP·PDF 제안요청서 100건에서 근거를 찾아 답하는 '입찰메이트' 사내 RAG 시스템


| | |
|---|---|
| 팀 | 2팀 · 이민기(팀장), 김현경, 김민협, 권유진, 이원영 |
| 기간 | 2026. 9. 30. ~ 2026. 10. 22. |
| 최종 구성 | FINAL-02 · BGE-m3-ko + Kiwi BM25 하이브리드 검색 · BGE 재순위화 · Claude Haiku 4.5 |
| GitHub | github.com/mingilee97/rag-project-part3-2team-main |
| 실험 기록표 | Google Sheets · 실험 50건 기록 |


원본 RFP와 평가 질문·답변은 데이터 제공 조건에 따라 공개 저장소와 본 보고서에 싣지 않았다. 수치는 실험 기록표와 저장된 결과 파일(all_scores.csv)에서 가져왔다.

# 목차


## Part 1. 프로젝트 개요

1. 프로젝트 배경과 목표

2. 데이터와 과제의 어려움

3. 팀 구성과 진행 일정

## Part 2. 시스템 설계와 평가 체계

4. 최종 시스템 아키텍처(FINAL-02)

5. 평가 데이터와 지표

## Part 3. 실험과 개선 과정

6. 실험 운영 원칙과 전체 흐름

7. 단계별 실험과 결정

8. 최종 후보 비교와 선정

## Part 4. 결과와 성과

9. 최종 성능

10. 프로젝트 성과

## Part 5. 한계와 개선 사항

11. 한계와 개선 과제

12. 협업 방식과 회고

13. 결론

부록. 실험 목록 · 재현 방법 · 참고 자료

PART 1

# 1. 프로젝트 배경과 목표

## 1.1 배경

공공 입찰에 참여하려면 발주기관이 공개한 제안요청서(RFP)를 읽고 사업 기간, 예산, 기능 요구사항, 평가 기준, 제출 조건을 정확히 파악해야 한다. 제안요청서는 한 건이 수십~수백 쪽이고 대부분 HWP 형식이며, 핵심 요구사항이 표 안에 흩어져 있다. 과제는 입찰 컨설팅 기업 '입찰메이트'의 컨설턴트가 제안요청서 100건에 대해 질문하면, 문서에서 근거를 찾아 답하는 사내 RAG(Retrieval-Augmented Generation) 시스템을 만드는 것이다.

범용 챗봇에 질문만 하면 모델은 해당 사업의 문서를 읽지 않은 채 답하므로 수치가 틀릴 위험이 크다. 문서 전체를 한 번에 넣기에는 100건의 분량이 문맥 창을 크게 넘고, HWP는 일반 챗봇 서비스에 그대로 올리기도 어렵다. 따라서 문서를 읽고, 잘게 나누고, 질문에 필요한 부분만 찾아 생성 모델에 전달하는 시스템을 직접 설계했다.

## 1.2 목표와 평가 관점

| 목표 | 세부 내용 |
|---|---|
| 문서 처리 | HWP 96건·PDF 4건에서 본문과 표를 손실 없이 추출하고, 표 구조(요구사항 ID·명칭·내용)를 보존한다. |
| 정확한 근거 검색 | 질문이 가리키는 사업의 문서에서, 답에 필요한 근거 청크를 상위 순위로 찾는다. |
| 근거 기반 답변 | 검색한 근거만으로 답하고, 근거가 없으면 지어내지 않고 답변을 유보한다. |
| 정량 평가 체계 | 검색과 생성을 분리해 평가하고, 모든 실험을 기록표에 남겨 설정 변경의 효과를 비교한다. |
| 재현 가능성 | 최종 구성을 GitHub 저장소의 코드·설정·실행 명령만으로 다시 실행할 수 있게 정리한다. |

프로젝트 가이드가 제시한 평가 관점은 단일 문서의 정보 추출, 여러 문서의 종합, 후속 질문 처리, 문서에 없는 내용의 거절, 그리고 응답 속도다. 9.4절에서 최종 구성이 각 관점을 얼마나 충족했는지 정리했다.

# 2. 데이터와 과제의 어려움

| 항목 | 내용 |
|---|---|
| 원본 문서 | 공공기관 제안요청서 100건 (HWP 96건, PDF 4건) |
| 메타데이터 | data_list.csv: 공고번호, 사업명, 사업 금액, 발주기관, 공개 일자, 파일명, 일부 텍스트 |
| 추출 본문 분량 | 100건 합계 약 1,368만 자 (문서당 평균 약 13.7만 자) |
| 청크 수 (최종) | 1000/200 분할 기준 20,522개 (700/100 분할 기준 30,676개) |
| 평가 데이터 | dev_benchmark v1.1: 문서 100건·300문항, 독립 Holdout 30문항 (5장) |

### 확인한 어려움

- **CSV 텍스트만으로는 답할 수 없다.** CSV의 텍스트 열은 원문 앞부분만 잘린 것이었다. 예를 들어 한 문서는 CSV 5,952자, 원문 55,640자로 약 9배, 다른 문서는 2,450자와 232,655자로 약 95배 차이가 났다. 원본 파일을 직접

파싱했다.

- **HWP와 표 처리.** HWP 내부의 표·그림 제어 문자를 잘못 처리하면 글자가 깨지고, 표가 셀 단위로 풀리면 요구사항 ID와 내용의 대응이 끊긴다. HwpHwpxLoader로 표를 Markdown 표로 추출해 한 행이 한 줄에 남게 했다.
- **비슷한 문서 구조.** 제안요청서는 목차와 조항(평가 배점, 보안 위약금, 하자 보수 등)이 서로 비슷해, 전체 문서를 검색하면 다른 사업의 청크가 섞여 들어온다.
- **흩어진 근거.** 한 질문의 답이 문서의 여러 절에 나뉘어 있는 경우가 많다(평가셋의 multi_section 유형).
- **API 사용 한도.** 100건·300문항을 매번 생성·채점하면 한도를 넘으므로, 작은 묶음에서 먼저 비교하고 큰 묶음에서 확인하는 순서로 실험했다.

# 3. 팀 구성과 진행 일정

## 3.1 팀 구성과 역할

| 이름 | 주요 역할 | 담당 내용 |
|---|---|---|
| 이민기<br>팀장 | 프로젝트 관리 · 기준 파이프라인 · 발표 | 초기 기준 파이프라인(KURE-v1·Chroma·EXAONE, 질문 유형 분기와 숫자·날짜 검증) 구현, 40문항 평가셋과 채점기 구축, 팀원 모듈의 동일 조건 비교와 기술 리포트 작성, 팀 대시보드, 발표 자료·영상 제작, 최종 GitHub 저장소 정리 |
| 김현경 | 팀 공통 파이프라인 개발 · 검색 구조 실험 | 공통 파이프라인(final_pipeline) 개발: HWP·표 Markdown 로더, 하이브리드 검색(Dense+BM25+RRF), 사업별 검색, 정제·임베딩·리트리버 구성 비교(EXP-001~022), 공통 기준선과 프롬프트 v2, 질의 분해, FINAL-01 실행 |
| 김민협 | 개발 환경 · 평가 도구 · 검색 실험 | GCP VM 원격 접속(VS Code SSH) 환경 설정, 초기 기준 파이프라인 2종(로컬·API) 구현과 HWP 파서 오류 수정, RAGAS·LangSmith 평가 연결, 통합 평가 시스템 작성, BM25 변형 실험(EXP-024·032), parent-child 청킹 실험(EXP-033·036, RET-parent-child) |
| 권유진 | 평가 데이터셋 · 최종 진단 평가 | 공통 평가셋 dev_benchmark v1.1(문서 100건·300문항, 근거 인용문 포함) 구축, 독립 Holdout 평가셋 구축과 FINAL-02 기능별 진단 평가, 최종 성능 평가 보고서 작성 |
| 이원영 | 재순위화·청킹 실험 · 최종 구성 평가 | 초기 개인 파이프라인(파싱·청킹·임베딩·리랭커·사업 라우팅·후속 질문 재작성) 구현, 리랭커 교체·청크 헤더·청크 크기 실험(EXP-026~031), 근거 재현율·문서 혼입 분석 도구, 300문항 검색 전용 평가(RET), FINAL-02 실행·평가와 재현 패키지 작성, 프로젝트 보고서 작성 |

## 3.2 진행 일정

| 기간 | 단계 | 주요 내용 |
|---|---|---|
| 9/30 ~ 10/2 | 환경 구축과 기준 구현 | 가이드 분석, GCP VM(L4 GPU) 개발 환경, 원본 100건 확보·무결성 점검, 팀원별 기준 파이프라인 구현(로컬 모델과 API 모델 병행) |
| 10/4 ~ 10/8 | 검색 구조 탐색 | 하이브리드 검색, HyDE 비교, 검색·답변 분리 평가, 사업별 검색, 정제·임베딩 비교, RAGAS 도입 |
| 10/11 ~ 10/14 | 평가 체계 정비와 중간 점검 | 검색 구성 6종 비교, 공통 평가셋 우선 구축 결정(10/12), 통합 평가 시스템, 중간 발표(10/14) |
| 10/15 ~ 10/17 | 공통 기준 위 단일 변수 실험 | 기준 코드 통일(final_pipeline), 생성 Claude Haiku 4.5·채점 Gemini로 전환, 리랭커·청킹·헤더·parent-child·질의 분해 실험, 300문항 검색 전용 평가 |
| 10/19 ~ 10/20 | 최종 후보 비교와 선정 | FINAL-01·FINAL-02 300문항 평가, FINAL-02 채택, Holdout 진단 평가, 재현 패키지와 저장소 정리 |
| 10/21 ~ 10/22 | 제출과 발표 | GitHub 저장소·보고서 제출(10/21 19:00), 최종 발표, 협업일지 제출(10/22 23:50) |

PART 2

# 4. 최종 시스템 아키텍처 (FINAL-02)

시스템은 미리 한 번 실행하는 **문서 준비** 경로와, 질문마다 실행하는 **질문 처리** 경로로 나뉜다. 그림 1은 채택한 구성 FINAL-02의 흐름이다.

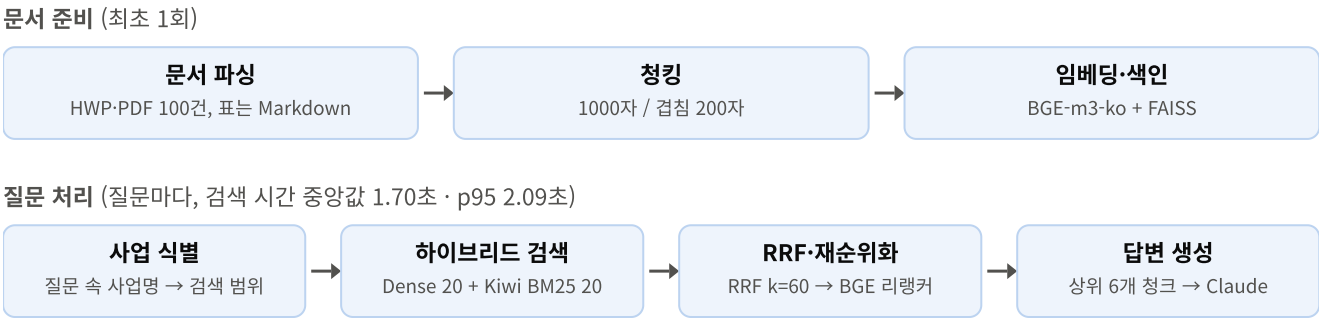



그림 1. FINAL-02의 문서 준비와 질문 처리 흐름. 답변에는 근거로 쓴 청크 번호가 함께 기록된다.

| 단계 | FINAL-02 설정 | 선택 이유 (근거 실험) |
|---|---|---|
| 문서 처리 | HwpHwpxLoader(표 → Markdown), pymupdf4llm, 파싱 결과 캐시 | 표의 행 구조 보존(EXP-002). 쪽번호·목차 정제는 효과가 없어 원문 유지(EXP-007, 010) |
| 청킹 | RecursiveCharacterTextSplitter 1000자 / 겹침 200자, 사업명 헤더 없음 | 필요한 근거를 모두 전달한 문항 241→259/297(RET-bge-1000) |
| 임베딩 | dragonkue/BGE-m3-ko, 정규화, FAISS | 네 임베딩 중 Factual Correctness 최고 0.895(EXP-014) |
| 사업 식별 | 질문 속 사업명·발주기관을 메타데이터와 대조해 검색 범위 한정, 실패·모호 시 전체 검색 | 다른 사업 근거 혼입 제거, FC 0.354→0.838(EXP-009) |
| 검색 | Dense 20 + Kiwi 형태소 BM25 20 → RRF(k=60) | Kiwi 적용 시 BM25 MRR@20 0.3906→0.6755(EXP-015) |
| 재순위화 | BAAI/bge-reranker-v2-m3 → 상위 6개 청크 | 300문항 Hit@5 0.8788→0.9428, 혼입 141→62문항(RET-bge-700) |
| 생성 | claude-haiku-4-5-20251001, 근거 기반 답변 프롬프트 v2 | FC 0.4807→0.5417(EXP-025). OpenAI 한도 소진 후 전환 |
| 평가 | Gemini 3.1 Flash-Lite Judge, RAGAS 0.3.9 Factual Correctness(FC)·Faithfulness | 생성 모델과 다른 회사의 모델로 채점 |

## 4.1 생성 모델 선택의 흐름

초기에는 사용료 없이 바로 시험할 수 있는 Hugging Face 로컬 모델(Qwen2.5-3B, EXAONE-3.5-7.8B)로 시작했다(가이드의 시나리오 A에 해당). 로컬 모델은 기본 검색에서는 정답을 냈지만 HyDE 실행에서 사업 기간을 놓치고 답변에 HTML이 섞였으며(EXP-002), 로컬 모델로 채점하자 형식 오류로 유효 점수를 얻지 못했다(EXP-006). 답변 한 번에 수 분이 걸리는 경우도 있었다. 같은 질문과 근거를 GPT-5 mini에 맡기자 사업 기간과 예산을

정확히 제시해(EXP-003), 이후 생성과 채점에 API 모델을 썼다(시나리오 B). 평가 문항이 늘면서 팀 공용 OpenAI 한도가 소진되어, 10월 15일부터 생성은 Claude Haiku 4.5, 채점은 Gemini 3.1 Flash-Lite로 통일했다. 로컬 27B급 모델과 GPT-5 mini를 같은 근거로 비교한 EXP-021에서도 답의 차이는 크지 않아, 시스템 개선의 초점을 검색 쪽에 두었다.

### 4.2 답변 예시

> 평가 데이터 보호를 위해 질문·답변 예시는 생략했습니다.

## 5. 평가 데이터와 지표

### 5.1 평가 데이터

| 데이터 | 규모 | 구성과 용도 |
|---|---|---|
| 초기 평가 질문 | 문서 99건 · 6~180문항 | 팀 초기 구현의 기능 확인용. 첫 10문항으로 설정을 비교(EXP-007~014) |
| 검색 구성 비교 세트 | 문서 3건 · 30문항 | BM25·Dense·리랭커 조합 비교(EXP-015~022) |
| dev_benchmark v1.1 (부분) | 문서 10건 · 30문항 | 공통 기준선과 단일 변수 비교(EXP-023~037) |
| dev_benchmark v1.1 (전체) | 문서 100건 · 300문항 | 검색 전용 실험(RET)과 최종 후보 비교(FINAL-01·02). 유형별 100문항: direct_fact, numeric_condition, multi_section |
| 독립 Holdout | 42문항 중 검증 완료 30문항 | 채택 구성의 기능별 진단. 핵심 사실 10, 복수 문서 10, 답변 불가 10 |

각 문항에는 정답 문장과 근거 인용문(evidence quote)이 정해져 있다. 근거 인용문 덕분에, 답변을 생성하지 않고도 “필요한 근거가 검색 결과에 들어왔는가”를 계산할 수 있었다. 이를 이용해 API 호출 없이 300문항 검색 성능을 반복 측정했다(RET 실험).

## 5.2 지표

| 지표 | 대상 | 정의 |
|---|---|---|
| Hit@5 | 검색 | 근거 인용문이 처음 나타난 청크의 순위가 5위 이내인 문항의 비율 |
| MRR | 검색 | 근거가 처음 나타난 순위의 역수 평균. 정답 근거가 앞에 있을수록 높다 |
| 근거 문장 재현율 | 검색 | 답변 모델에 넘긴 6개 청크에 들어간 근거 인용문의 비율 |
| 근거 전부 전달 | 검색 | 필요한 근거 인용문이 모두 6개 청크 안에 들어간 문항의 수 |
| LLM-as-Judge | 생성 | Gemini가 정답 문장과 비교해 사실 정확성·필수 항목 포함 여부를 0~1점으로 채점 |
| Factual Correctness(FC) | 생성 | RAGAS가 답변과 정답 문장을 주장 단위로 나눠 비교한 점수(후반부 실험은 F1 방식). 이하 FC |
| Faithfulness | 생성 | 답변의 주장이 전달한 근거에 의해 뒷받침되는 비율(환각 억제 지표) |
| 검색 시간 | 속도 | 사업 식별부터 재순위화까지의 시간. 최초 색인 구축 시간은 제외 |

**지표 해석에서 지킨 원칙**

- Hit@5와 MRR의 계산 단위는 실험 단계마다 달랐다(문서 단위, 청크 번호 단위, parent 청크 단위, 근거 문장 단위). **단위가 다른 수치는 같은 표에서 우열을 매기지 않았다.**
- Hit@5가 1이어도 근거가 모두 전달되지는 않는다. 10문서·30문항에서 Hit@5 1.000인 EXP-026도 근거 전부 전달은 26/30이었다. 그래서 후반부에는 근거 문장 재현율과 근거 전부 전달을 함께 봤다.
- Factual Correctness는 정답 수치를 담은 답변이 0점을 받는 채점 문제가 발견되어(EXP-011; EXP-028에서는 사업명으로 시작하는 답변이 0점), 후반부에는 LLM-as-Judge를 주 지표로, FC는 보조 지표로 사용했다.

PART 3

# 6. 실험 운영 원칙과 전체 흐름

## 6.1 실험 운영 원칙

- **한 번에 하나만 바꾼다.** 기준 실험을 정하고 변경 변수 하나의 효과를 본다. 두 조건이 함께 바뀐 실험은 조합의 결과로만 해석했다.
- **작은 묶음에서 비교하고 큰 묶음에서 확인한다.** 10문서·30문항에서 후보를 고른 뒤, 100문서·300문항에서 다시 측정했다. 실제로 1000/200 청킹과 사업명 헤더는 규모에 따라 결론이 달라졌다.
- **검색과 생성을 나눠 잰다.** 검색 전용 평가(RET)는 생성·채점 API를 부르지 않아 한도를 쓰지 않고 300문항을 반복할 수 있다.
- **모든 시도를 기록한다.** 실패하거나 채택하지 않은 시도도 실험 기록표에 남겼다. 기록표에는 날짜, 담당자, 기준 실험, 변경 변수, 가설, 지표, 관찰, 결정이 열로 정리되어 있다.

## 6.2 전체 흐름

| 기간 | 단계 | 실험 | 주요 결정 |
|---|---|---|---|
| 9/30 ~ 10/7 | 기본 RAG 구축과 평가 준비 | EXP-001 ~ 006 | HWP·표 Markdown 로더, Dense+BM25+RRF+리랭커 골격, API 생성 모델로 전환 |
| 10/8 | 검색 범위·정제·임베딩 | EXP-007 ~ 014 | 사업별 검색 도입, 정제 미적용, BGE-m3-ko 채택 |
| 10/11 ~ 10/13 | 검색 구성 비교 | EXP-015 ~ 022 | Kiwi BM25 유지, 700/100과 parent-child 차이 작음 |
| 10/15 ~ 10/16 | 공통 평가셋 단일 변수 비교 | EXP-023 ~ 037 | Claude·Gemini로 통일, 프롬프트 v2, BGE 리랭커, 1000/200 후보 |
| 10/16 ~ 10/17 | 300문항 검색 전용 검증 | RET 6건, EXP-038 | BGE 리랭커 채택, 1000/200 최종 후보, 헤더는 보류 |
| 10/19 ~ 10/20 | 최종 후보 비교 | FINAL-01, FINAL-02 | FINAL-02 채택, Holdout 진단 평가, 저장소 정리 |

# 7. 단계별 실험과 결정

## 7.1 기본 RAG 구축 (EXP-001 ~ 006)

PDF 한 건과 질문 하나로 기본 흐름을 만든 뒤(EXP-001), HWP 로더와 표 Markdown 변환을 추가했다(EXP-002). 질문 대신 가상의 답을 만들어 검색하는 HyDE와 Query Rewriting은 기본 질문보다 낫지 않았다. Rewriting은 무관한 청크를 끌어왔고, HyDE를 쓴 실행 한 번에서는 답변이 사업 기간을 빠뜨렸다. EXP-004에서 Dense 8개와 BM25 8개를 RRF로 합치고 재순위화로 상위 4개를 고르는 골격을 만들었으며, RRF 12위였던 관련 청크가 재순위화 후 1위로 오른 사례를 확인했다. 이후 검색 근거와 답변을 나눠 채점하는 평가를 도입했다(EXP-005, 006).

## 7.2 사업별 검색과 문서 정제 (EXP-007 ~ 010)

| 실험 | 변경 | Faithfulness | FC | 결정 |
|---|---|---|---|---|
| EXP-007 | 쪽번호·목차·빈 표 줄 정제 (원본 대비) | 0.633 → 0.617 | 0.342 → 0.323 | 미채택 원본 유지 |
| EXP-008 | 검색 후보 8→20, 전달 문맥 4→6 | 0.600 | 0.354 | 다른 사업 근거가 계속 섞임 |
| **EXP-009** | **질문의 사업명 식별 → 해당 사업 문서만 검색** | **1.000** | **0.838** | 채택 |
| EXP-010 | 사업별 검색 + 정제 | 0.971 | 0.909 | 문맥 60개 중 53개가 동일, 실질 효과로 보지 않음 |

표 7-1. 문서 99건·10문항, GPT-5 mini 생성·RAGAS 채점. 근거를 더 많이 넣는 것보다 다른 사업의 근거를 빼는 것이 효과가 컸다.

후보와 문맥을 늘려도 점수가 거의 오르지 않았고(EXP-008), 답변을 확인하니 다른 사업의 평가 배점·보안 위약금 조항이 섞여 있었다. 질문에 적힌 사업명을 메타데이터와 대조해 검색 범위를 그 사업으로 좁히자 Faithfulness가 1.000, FC가 0.838로 올랐다. 이 사업 식별은 최종 구성까지 유지했다. 다만 질문에 사업명이 정확히 들어 있어야 작동해, 300문항에서는 48문항만 식별되고 나머지는 전체 문서에서 검색했다. 이 점은 11장의 개선 과제로 이어진다.

## 7.3 임베딩 모델 (EXP-012 ~ 014)

| 임베딩 | FC | Context Precision | Context Recall | 결정 |
|---|---|---|---|---|
| Alibaba-NLP/gte-multilingual-base | 0.841 | 0.729 | 0.975 | 기존 |
| BAAI/bge-m3 | 0.783 | 0.709 | 0.875 | 미채택 |
| nlpai-lab/KURE-v1 | 0.776 | 0.671 | 0.875 | 미채택 |
| **dragonkue/BGE-m3-ko** | **0.895** | **0.725** | **0.975** | 채택 |

표 7-2. 사업별 검색 조건, 문서 99건·첫 10문항. 표본이 작아 일반적인 우위로 보지는 않았고, 이후 300문항 검색에서 드러난 약점이 임베딩이 아닌 문서 혼입·흩어진 근거였기 때문에 BGE-m3-ko를 유지했다.

## 7.4 하이브리드 검색과 한국어 형태소 BM25 (EXP-015 ~ 024, 032)

한국어는 “단말기는”, “단말기를”처럼 조사가 붙어 띄어쓰기 기준 BM25가 같은 단어를 다른 단어로 본다. 형태소 분석기 Kiwi로 조사를 떼어 BM25를 적용하자 BM25 단독 기준 Recall@20이 0.6365에서 0.8273, MRR@20이 0.3906에서 0.6755로 올랐다(문서 3건·30문항). Dense와 Kiwi BM25를 RRF로 합치고 리랭커를 더한 구성의 Recall@20이 0.8507로 가장 높았다.

공통 평가셋(10문서·30문항)에서 Kiwi를 빼면 FC가 0.4807에서 0.3460, Judge가 0.9383에서 0.9167로 떨어져(EXP-024) Kiwi BM25를 유지했다. 반면 BM25를 빼고 Dense만 쓴 EXP-032는 Hit@5 0.9667, MRR 0.8141로 기준선과 거의 같았다. 이 규모에서는 하이브리드 검색의 이득이 뚜렷하지 않았고, EXP-015에서도 답변 Judge는 일반 BM25 구성(0.7967)이 Kiwi 구성(0.7300)보다 높았다. 그래도 Kiwi 제거 시 FC가 크게 떨어졌고, 고유번호·수치처럼 정확한 표현은 키워드 검색이 보완할 것으로 판단해 하이브리드를 유지했다.

## 7.5 공통 기준선, 프롬프트, 재순위화 모델 (EXP-023 ~ 026, 034, RET)

10월 15일 팀은 공통 평가셋 dev_benchmark v1.1과 생성 Claude Haiku 4.5·채점 Gemini 3.1 Flash-Lite로 조건을 통일하고, 기준선 EXP-023(Hit@5 0.9667, MRR 0.8137, Judge 0.9383, FC 0.4807)을 정했다.

- **프롬프트 v2 (EXP-025).** 질문이 묻는 항목을 빠짐없이 답하고, 묻지 않은 사실과 추측을 줄이도록 규칙을 바꾸자 FC가 0.4807에서 0.5417로 올랐다.
- **재순위화 모델 교체 (EXP-026).** gte-multilingual-reranker-base를 BAAI/bge-reranker-v2-m3로 바꾸자 Hit@5가 0.9667에서 1.0000(29→30문항), MRR이 0.8137에서 0.8889로 올랐다. 프롬프트 v2와 결합한 EXP-034는 Judge 0.9533, FC 0.5673이었다.

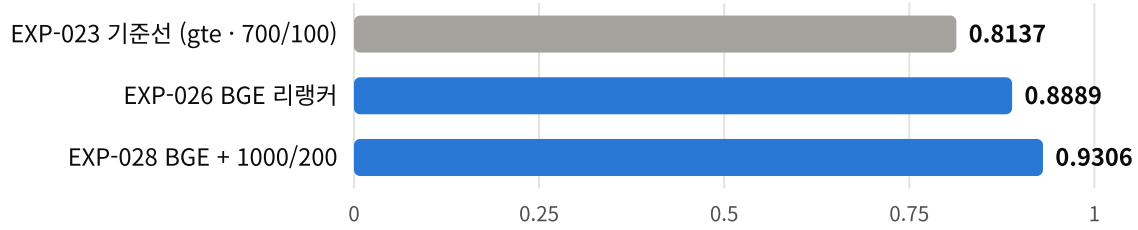



그림 2. 문서 10건·30문항에서 청크 단위 MRR의 변화. 정답 근거가 담긴 청크가 앞 순위로 올라왔다.

30문항에서는 이미 점수가 높아 차이가 잘 보이지 않았다. 그래서 문서 100건·300문항에서 검색만 다시 측정했다. 재순위화 모델을 BGE로 바꾸자 Hit@5가 0.8788에서 0.9428, MRR이 0.7569에서 0.8523, 근거 전부 전달 비율이 0.714에서 0.811로 올랐고, 다른 사업의 청크가 섞인 문항은 141개에서 62개로 줄었다(RET-gte-700 → RET-bge-700). 300문항 검색 실험 가운데 단일 변경으로는 가장 큰 개선이었다.

## 7.6 청크 크기 (EXP-011, 028, RET-bge-1000)

EXP-026에서 Hit@5는 1.000이었지만, 근거가 3~5개인 문항 4개는 필요한 근거가 모두 전달되지 않았다. 여러 근거가 한 청크에 함께 들어가도록 청크를 700/100에서 1000/200으로 키웠다(EXP-028). 근거 전부 전달이 26/30에서 28/30, MRR이 0.8889에서 0.9306으로 올랐고, 문맥 길이는 3,545자에서 5,122자로 늘었다.

10월 8일 첫 10문항 실험(EXP-011)에서는 1000/200의 FC가 0.838에서 0.813으로 낮아 700/100을 유지했었다. 그러나 이 실험은 표본이 작고 정답 수치가 있는 답변이 0점을 받는 채점 문제가 있었다. 300문항 검색에서 다시 측정한 결과 근거 전부 전달이 241에서 259/297로, multi_section 유형은 0.636에서 0.748로 올라(RET-bge-1000) 결론을 바꿨다. 같은 문맥 길이로 맞춰 봐도 1000/200 상위 6개(259/297, 5,079자)가 700/100 상위 10개(255/297, 5,890자)보다 효율적이었다.

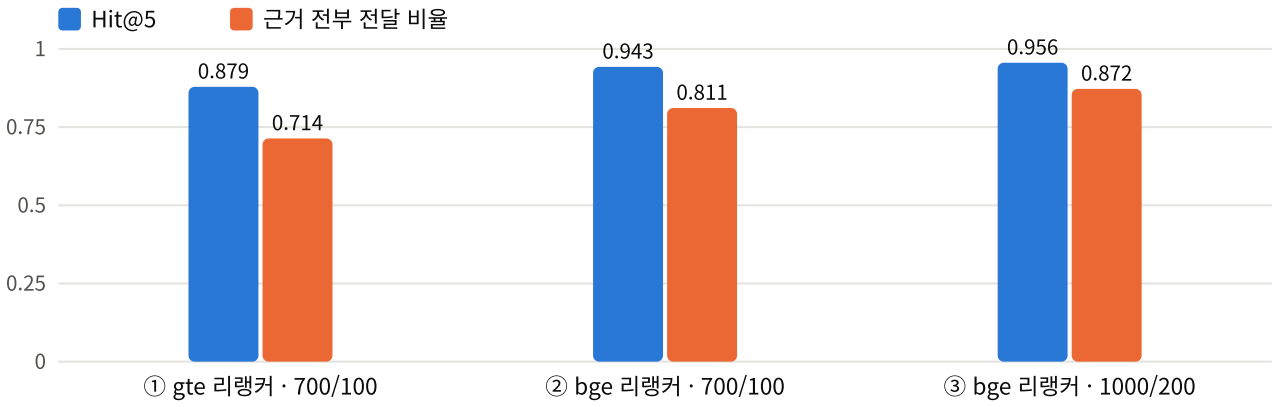



그림 3. 문서 100건·300문항 검색 전용 실험(RET)의 단계별 변화. ① RET-gte-700, ② RET-bge-700, ③ RET-bge-1000. 근거 전부 전달 비율은 근거 문장이 정렬된 297문항 기준(①은 기록표 값 0.7138, ② 241/297, ③ 259/297). 높을수록 좋다.

## 7.7 사업명 청크 헤더 (EXP-027, RET-*-header)

사업 식별에 실패해 전체 문서를 검색할 때도 같은 사업의 청크를 고르도록, 모든 청크 앞에 사업명과 발주기관을 붙였다. 다른 사업의 청크 혼입은 크게 줄었지만(10문서 3→0문항, 100문서 50→9문항), 같은 문서 안에서 정답 청크를 고르는 성능은 낮아졌다(10문서 Hit@5 1.000→0.933, 100문서 MRR 0.863→0.838). 모든 청크에 같은 사업명이 붙어 청크 사이의 구별이 흐려진 것으로 추정한다. 근거 전부 전달은 259에서 260/297로 거의 같아, 최종 구성에서는 헤더를 쓰지 않았다.

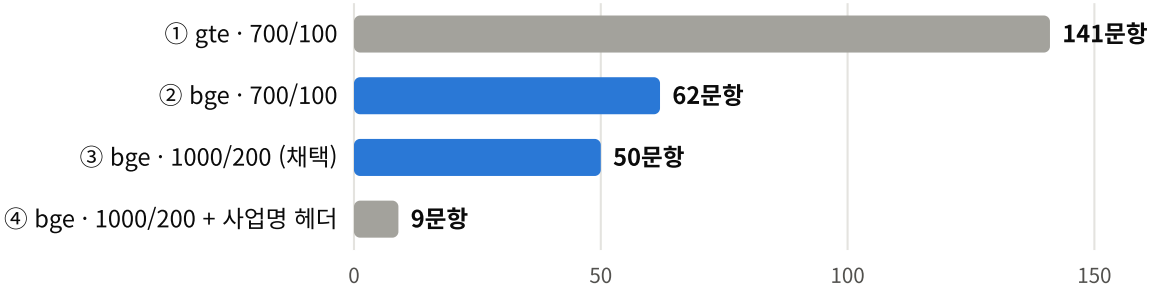



그림 4. 상위 문맥에 다른 사업의 청크가 섞인 문항 수(300문항 중). 낮을수록 좋다. ④는 섞임은 줄였지만 MRR이 0.863→0.838로 낮아져 채택하지 않았다.

## 7.8 parent-child 청킹과 질의 분해 (EXP-022, 033 ~ 038)

흩어진 근거를 모으기 위해, 350자 child 청크로 검색하고 그 청크가 속한 1400자 parent 청크를 생성 모델에 넣는 parent-child 방식과, 질문을 하위 질문으로 나눠 각각 검색하는 질의 분해를 시도했다.

| 실험 | 구성 (모두 BGE 리랭커·프롬프트 v2, 10문서·30문항) | Judge | FC | 관찰 |
|---|---|---|---|---|
| EXP-034 | 700/100 기준 | 0.9533 | 0.5673 | 비교 기준 |
| EXP-035 | + 질의 분해 | 0.9333 | 0.5070 | 단독으로는 모든 지표 하락 |
| EXP-036 | + parent-child | 0.9467 | 0.5737 | FC만 소폭 상승, Judge는 하락 |
| **EXP-037** | **+ parent-child + 질의 분해** | **0.9567** | **0.6073** | **30문항 최고. 문맥 6,884자로 증가 → FINAL-01** |

표 7-3. 두 방법은 함께 쓸 때만 효과가 있었다. EXP-022에서 700/100과 parent-child의 Judge 차이(0.0077)는 3회 반복의 회차 간 변동보다 작았다.

## 7.9 시도한 방법의 효과 요약

| 방법 | 결과 | 근거 수치 |
|---|---|---|
| 사업별 검색 범위 한정 | 채택 | Faithfulness 0.600→1.000, FC 0.354→0.838 (EXP-009) |
| Kiwi 형태소 BM25 | 채택 | BM25 MRR@20 0.3906→0.6755 (EXP-015); 제거 시 FC 0.4807→0.3460 (EXP-024) |
| BGE 재순위화 모델 | 채택 | 300문항 Hit@5 0.8788→0.9428, 혼입 141→62 (RET-bge-700) |
| BGE-m3-ko 임베딩 | 채택 | FC 0.895, 비교한 네 모델 중 최고 (EXP-014) |
| 프롬프트 v2 | 채택 | FC 0.4807→0.5417 (EXP-025) |
| 1000/200 청킹 | 채택 | 근거 전부 전달 241→259/297 (RET-bge-1000) |
| 문서 정제 | 미채택 | FC 0.342→0.323 (EXP-007) |
| HyDE · Query Rewriting | 미채택 | 정성 비교에서 기본 질문보다 나쁨 (EXP-001, 002) |
| 사업명 청크 헤더 | 미채택 | 혼입 50→9이지만 MRR 0.863→0.838 (RET-bge-1000-header) |
| 구조 기반 청킹 | 미채택 | Judge 0.6828 (700/100은 0.7316, EXP-022) |
| parent-child + 질의 분해 | 비교 후보 | 30문항 최고(Judge 0.9567)였으나 300문항에서 FINAL-02와 차이 없음 (8장) |
| 요구사항 표 단위 청킹 · OpenAI 임베딩 · 사업 카드 라우팅 | 보류 | 1000/200·헤더로 대부분 해결, OpenAI 한도 소진 (EXP-029~031) |

# 8. 최종 후보 비교와 선정

두 경로에서 나온 최종 후보를 같은 300문항, 같은 프롬프트·생성 모델·채점 모델로 비교했다. 텍스트 추출 방법, 임베딩, 하이브리드 검색, 재순위화 모델은 두 구성에 같다. 다만 두 실행은 서로 다른 환경(Colab과 VM)의 파싱 캐시를 썼고, 5개 문서(DOC013·026·040·042·065)는 추출 본문 길이가 달랐다. 이 5개 문서를 빼고 보면 근거 전부 전달은 FINAL-01 246, FINAL-02 243문항이다.

| 항목 | FINAL-01 | FINAL-02 |
|---|---|---|
| 출처 | 10문서 실험 최고 구성 EXP-037을 100문서로 확장 | 300문항 검색 실험 최고 조건 RET-bge-1000에 생성 추가 |
| 청킹 · 검색 | parent 1400/200 · child 350/50, 질의 분해 | 일반 청크 1000/200, 한 번 검색 |
| LLM-as-Judge | 0.920 | **0.930** |
| Factual Correctness(FC) | 0.551 | **0.575** |
| Faithfulness | 0.978 | **0.985** |
| 근거 전부 전달 | **257/300** | 252/300 |
| multi_section 근거 전부 전달 | **0.77** | 0.69 |
| 문항당 문맥 길이 | 6,982자 | **5,079자 (−27%)** |
| 검색 시간 중앙값 | 4.94초 | **1.70초** |
| 검색 시간 p95 | 7.18초 | **2.09초** |
| 문항당 Claude 호출 | 질의 분해 1회 + 답변 1회 | **답변 1회** |

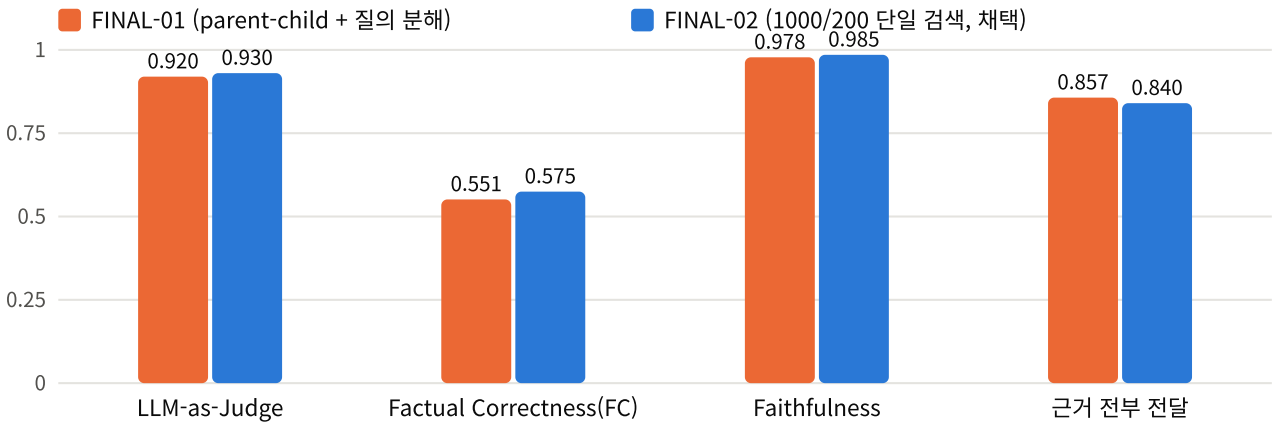



그림 5. 최종 후보 두 구성의 300문항 평가. 네 지표 모두 차이의 95% 신뢰구간이 0을 포함한다(문항 단위 부트스트랩).

답변 지표 세 개는 FINAL-02가 조금 높지만, 문항별 차이의 95% 신뢰구간이 모두 0을 포함했다(Judge +0.010 [−0.009, +0.030], FC +0.024 [−0.009, +0.058], Faithfulness +0.006 [−0.005, +0.019]). 두 구성은 각각 한 번씩 실행했으므로 0.01~0.02의 차이는 우연히 생길 수 있는 범위로 판단했다. 이는 두 구성이 같다는 증명이 아니라, 답변

점수로는 우열을 가릴 수 없다는 뜻이다. Hit@5와 MRR은 순위 단위(parent 1400자, 일반 청크 1000자)가 달라 비교하지 않았다.

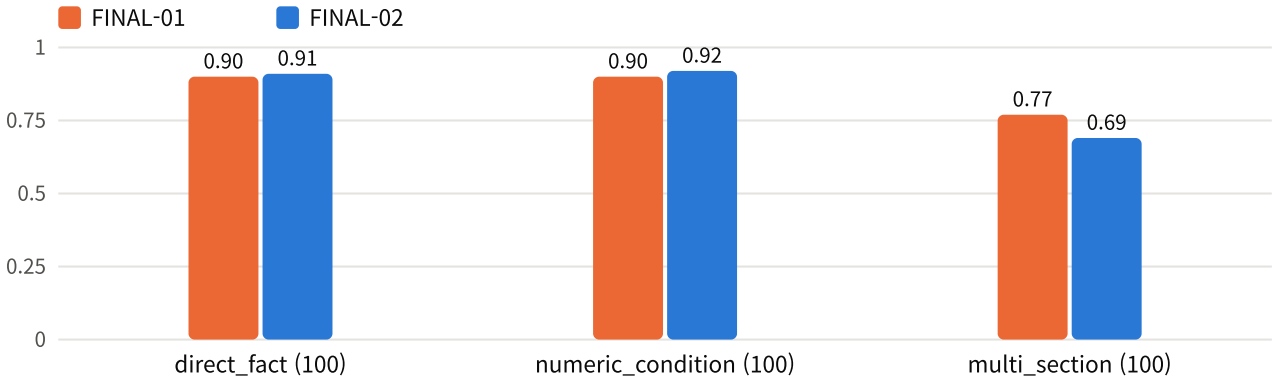



그림 6. 질문 유형별 '필요한 근거가 모두 답변 모델에 전달된 비율'. 여러 절에 흩어진 근거(multi_section)는 FINAL-01이 더 많이 모았다.

**선정 결과: FINAL-02 채택**

답변 품질이 통계적으로 같은 수준일 때, 실제 서비스에서 중요한 비용과 속도를 기준으로 삼았다. FINAL-02는 생성 모델에 넣는 문맥이 27% 짧아 사용 한도를 덜 쓰고, 검색 시간이 중앙값 기준 약 2.9배, p95 기준 약 3.4배 빠르며, 질의 분해 호출이 없어 문항당 Claude 호출이 한 번 적다. 구성도 단순해 재현과 유지보수가 쉽다. 반면 여러 절에 흩어진 근거를 모으는 데는 FINAL-01이 강해(0.77 대 0.69), 이 약점은 11장의 개선 과제로 남겼다. 두 구성은 청킹과 질의 분해가 함께 달라 어느 쪽이 이 차이를 만들었는지는 분리하지 못했다.

PART 4

# 9. 최종 성능

## 9.1 개발 평가셋 300문항 (FINAL-02)

| 0.930 | 0.985 | 0.955 | 1.70초 |
|---|---|---|---|
| LLM-as-Judge (300문항) | Faithfulness (300문항) | Hit@5 (근거 정렬 289문항) | 검색 시간 중앙값 (p95 2.09초) |

| 질문 유형 | Hit@5 | MRR | 근거 재현율 | 근거 전부 전달 | Judge | FC | Faithfulness |
|---|---|---|---|---|---|---|---|
| direct_fact (단일 사실) | 0.928 | 0.823 | 0.933 | 91/100 | 0.921 | 0.492 | 0.987 |
| numeric_condition (수치·조건) | 0.969 | 0.914 | 0.938 | 92/100 | 0.965 | 0.734 | 0.984 |
| multi_section (여러 절 종합) | 0.968 | 0.847 | 0.846 | 69/100 | 0.904 | 0.499 | 0.984 |
| **전체** | **0.955** | **0.862** | **0.906** | **252/300** | **0.930** | **0.575** | **0.985** |

표 9-1. Hit@5·MRR은 근거 인용문이 청크 본문과 정렬된 289문항 기준이며, 정렬되지 않은 11문항은 0점이 아닌 결측으로 처리했다. 근거 재현율·근거 전부 전달과 생성 지표는 300문항 기준이며, 이 11문항은 근거를 찾지 못한 것으로 계산되었다(정렬된 289문항만 보면 근거 전부 전달 252/289=0.872).

Judge 점수 분포를 보면 300문항 중 203문항이 만점(1.0), 57문항이 0.9였고, 0점은 4문항이었다. Faithfulness 0.985는 답변이 전달된 근거를 벗어난 내용을 거의 만들지 않았다는 뜻이다. 수치·조건 질문의 성능이 가장 높았고, 여러 절의 근거를 모아야 하는 질문은 근거 전부 전달이 69/100으로 가장 낮았다. 300문항의 검색·답변 생성·Judge 채점 단계는 L4 GPU VM에서 약 53분이 걸렸다(RAGAS 채점 제외).

## 9.2 검색 응답 시간

서비스에서는 평균적인 응답뿐 아니라 느린 질문의 응답 시간도 중요하므로, 중앙값과 함께 p95(전체 질문의 95%가 이 시간 안에 끝나는 값)를 함께 측정했다. 값은 결과 파일에 기록된 300문항의 문항별 검색 시간으로 계산했다.

| 구성 | 평균 | 중앙값 | p90 | p95 | p99 | 최대 |
|---|---|---|---|---|---|---|
| FINAL-01 (질의 분해 + parent-child) | 5.20초 | 4.94초 | 6.93초 | 7.18초 | 7.94초 | 8.89초 |
| **FINAL-02 (채택)** | **1.70초** | **1.70초** | **2.04초** | **2.09초** | **2.25초** | **2.63초** |

표 9-2. 문항별 검색 시간(300문항). 사업 식별부터 최종 문맥 선택까지이며, FINAL-01은 Claude 질의 분해 호출과 하위 질문별 검색·재순위화를 포함한다. 답변 생성 시간과 최초 색인 구축 시간은 포함하지 않는다.

FINAL-02는 p95가 2.09초, 가장 느린 문항도 2.63초로 응답 시간의 꼬리가 짧았다. 중앙값과 p95의 차이가 0.39초에 그쳐, 질문에 따라 응답이 크게 늦어지는 경우가 거의 없었다. 사업이 식별된 48문항은 검색 범위가 좁아 중앙값 1.44초, 전체 문서를 검색한 252문항은 1.73초였다. FINAL-01은 질의 분해를 위한 생성 모델 호출이 검색 단계에 들어가 p95가 7.18초였다. 다만 FINAL-01은 Colab, FINAL-02는 GCP VM에서 실행해 장비 차이가 일부 섞여 있을 수 있다.

## 9.3 독립 Holdout 30문항 진단 평가

개발 평가셋으로 구성을 고른 뒤, 선정 과정에 쓰지 않은 독립 Holdout 질문으로 채택 구성의 기능별 강점과 약점을 진단했다. 기준 정답 검증을 마친 30문항만 사용했고, FINAL-02의 모델·프롬프트·문맥 설정은 그대로 유지했다.




그림 7. 독립 Holdout 30문항 진단 평가(권유진). 답변 불가 문항은 정답 근거가 없어 검색 Hit@5를 계산하지 않으며(해당 없음), 적절한 거절은 10/10이다.

| 유형 | Hit@1 | Hit@5 | MRR | Correctness | Faithfulness | Relevancy |
|---|---|---|---|---|---|---|
| 핵심 사실 추출 (10) | 70% | 80% | 0.750 | 0.890 | 0.918 | 1.000 |
| 복수 문서 종합 (10) | 0% | 10% | 0.056 | 0.000 | 0.696 | 0.500 |
| 답변 불가 판단 (10) | - | - | - | 1.000 | 0.892 | 1.000 |
| **전체 (30)** | **35%*** | **45%*** | **0.403*** | **0.630** | **0.835** | **0.833** |

표 9-3. * 답변 가능 20문항 기준. Correctness는 Gemini Judge의 0~1점 평균이며 이진 정답률이 아니다. Holdout은 질문 구성과 집계 조건이 개발 평가셋과 달라 두 점수를 직접 비교하지 않는다.

단일 문서의 핵심 사실 추출(Correctness 0.890)과 근거가 없는 질문의 거절(10/10)은 양호했다. 반면 두 사업 이상을 비교하는 복수 문서 질문은 Correctness 0.000으로 실패했다. 최종 문맥에 필요한 문서가 모두 들어간 문항은 2/10, 필요한 근거 인용문이 모두 확보된 문항은 0/10이었고, 4문항은 사업 식별(라우팅) 때문에 필수 문서가 검색 대상에서 빠졌다. 검색 단계의 근거 누락이 복수 문서 답변 실패의 주요 요인으로 판단된다. 다만 자동 채점 결과만으로 모든 실패의 원인을 확정할 수는 없다.

### 9.4 가이드 평가 관점별 충족도

| 평가 관점 | 충족도 | 근거 |
|---|---|---|
| 단일 문서 정보 추출 | 양호 | 개발셋 direct_fact Judge 0.921, numeric_condition 0.965 · Holdout 핵심 사실 0.890 |
| 여러 절·여러 문서 종합 | 부족 | 한 문서 안의 여러 절은 Judge 0.904이나 근거 전부 전달 69/100 · Holdout 복수 문서 0.000 |
| 후속 질문(대화 맥락) | 미구현 | 최종 구성은 질문 하나 단위로 동작. 이전 대화를 반영한 질문 재작성은 초기 개인 구현(이민기 기준 파이프라인, 이원영 v1)에서만 시험 |
| 문서에 없는 내용 거절 | 양호 | Holdout 답변 불가 10/10 적절한 거절. 근거 밖 내용 생성도 적음(개발셋 Faithfulness 0.985) |
| 응답 속도 | 양호 | 검색 시간 중앙값 1.70초, p95 2.09초, 최대 2.63초(FINAL-01은 4.94초, 7.18초). 생성 시간은 별도로 집계하지 않음 |

## 10. 프로젝트 성과

최종 성능 수치는 9장에, 단계별 개선 수치는 7장에 정리했다. 이 밖에 프로젝트를 통해 다음 결과물을 만들었다.

- **HWP 표를 보존하는 문서 처리.** 100건 전체를 파싱하고, 표를 Markdown으로 추출해 요구사항 ID와 내용이 한 줄에 남게 했다.
- **근거가 붙은 답변.** 답변마다 근거 청크 번호가 기록되어, 컨설턴트가 문서를 한 건씩 열어 읽던 일이 근거를 확인하는 일로 바뀐다.
- **평가 체계.** 300문항 개발 평가셋, 독립 Holdout, 검색·생성·속도를 나눈 8개 지표, API 호출 없이 반복할 수 있는 검색 전용 평가를 만들었다.
- **실험 기록.** 실험 기록표에 50건의 실험을 기준 실험·변경 변수·가설·결과·결정과 함께 남겼고, 채택하지 않은 방법의 근거도 기록했다.
- **재현 가능한 저장소.** 최종 구성을 `rfp_rag/` 패키지로 정리하고, 설정·프롬프트·실행 명령·합성 단위 테스트 12개를 제공했다.

PART 5

# 11. 한계와 개선 과제

| 순위 | 한계 | 근거 | 개선 방향 |
|---|---|---|---|
| 1 | 복수 문서 종합 실패 | Holdout 복수 문서 Correctness 0.000, Hit@5 10%, 라우팅으로 필수 문서가 검색 대상에서 빠진 사례 4/10 | 질문 속 여러 사업명을 모두 인식하는 라우팅, 사업별로 따로 검색한 뒤 문맥을 사업 수만큼 나눠 배분 |
| 2 | 사업 식별 범위가 좁음 | 300문항 중 48문항만 사업 식별, 나머지는 전체 문서 검색 | 사업명 별칭·약칭 등록, 사업 카드(사업명·기관·요약) 점수 기반 라우팅(EXP-031로 계획) |
| 3 | 여러 절에 흩어진 근거 | multi_section 근거 전부 전달 0.69 (FINAL-01 0.77) | 상위 청크의 앞뒤 청크 확장(700/100 검색 실험에서 근거 전부 전달 241→268/297), parent-child를 multi_section 질문에만 선택 적용 |
| 4 | 후속 질문 미지원 | 최종 구성은 단일 질문 처리 | 최근 대화를 반영해 질문을 독립 질문으로 재작성한 뒤 검색하는 단계 추가 |
| 5 | 파싱 환경에 따른 결과 차이 | VM과 Colab에서 5개 문서 (DOC013·026·040·042·065)의 추출 본문 길이가 다름, DOC026 3문항 근거 정렬 실패 | 원문 대조로 올바른 추출을 확정하고 파싱 캐시를 버전 관리 |
| 6 | 평가의 신뢰도 | 단일 LLM Judge, 각 구성 1회 실행, Factual Correctness 채점 오류 사례 | 교차 Judge·사람 검수 표본, 반복 실행으로 분산 추정, 지표별 채점 오류 점검 |
| 7 | 로컬 모델 시나리오 비교 미완 | 초기 로컬 모델은 생성·채점 형식 문제로 정량 비교 전 전환 | 같은 검색 결과를 고정하고 로컬 생성 모델을 비교해 비용·보안 대안 확보 |
| 8 | 응답 속도 측정 범위 | 질문별 기록은 검색 시간만 있음. 생성 시간은 기록하지 않았고, 최초 색인 구축 (실행 기준 약 15분)은 검색 시간에서 제외 | 질문 단위 전체 응답 시간 기록, 색인 사전 구축·저장 |

# 12. 협업 방식과 회고

## 12.1 협업 방식

| 도구 | 사용 방식 |
|---|---|
| Discord | 일일 진행 공유, 모델·API 결정, 실험 분담과 결과 공유 |
| 실험 기록표 (Google Sheets) | 실험마다 기준 실험, 변경 변수, 가설, 지표, 관찰, 결정을 한 행으로 기록(50건) |
| 공용 시트 · 대시보드 | 일정, 개인 일지 탭, 단계별 후보·담당·상태, 접근법별 근거 비교 |
| GitHub | 공통 파이프라인 저장소와 개인 실험 브랜치, 최종 제출 저장소 |
| GCP VM · Colab | L4 GPU에서 임베딩·재순위화 실행, 장시간 평가는 tmux로 실행 |
| Notion · Google Docs · LangSmith | 개인 협업일지와 실험 노트, 실험 결과 조회·CSV 공유 |

## 12.2 협업 과정의 문제와 해결

| 문제 | 해결 |
|---|---|
| 초기에 팀원마다 평가 질문과 점수 척도가 달라 결과를 비교할 수 없었다. | 10/12에 “평가셋을 먼저 만들고 그 평가셋으로 실험한다”고 합의하고, 공통 평가셋 dev_benchmark v1.1을 만들었다. |
| 팀원별 기준 코드가 여러 개라 같은 실험이 코드마다 다르게 나왔다. | 10/15부터 기준 코드를 김현경의 final_pipeline 하나로 정하고, 변경 변수를 나눠 맡았다. 변경은 환경 변수 스위치로 넣어 기본 동작이 바뀌지 않게 했다. |
| 팀 공용 OpenAI 한도가 평가 도중 소진되었다. | 생성은 Claude Haiku 4.5, 채점은 Gemini로 통일하고, 생성 없이 측정할 수 있는 검색 전용 평가(RET)로 300문항 비교를 대신했다. |
| 점수 하나로는 설정의 우열이 분명하지 않았다(FC 채점 오류, Hit@5 포화). | 점수와 함께 문항별 채점 이유와 전달 문맥을 직접 확인하고, 근거 전부 전달·문서 혼입처럼 원인을 보여 주는 지표를 추가했다. |
| 실행 환경(VM과 Colab)에 따라 일부 문서의 파싱 결과가 달랐다. | 결과 파일에 문서별 원문 길이를 기록해 차이를 찾아냈고, 최종 결과와 함께 사용한 파싱 캐시를 보존했다. |

### 12.3 회고

**잘한 점**

- 채택하지 않은 시도까지 실험 기록표에 남겨, 결정마다 근거 수치를 댈 수 있었다.
- 검색과 생성을 나눠 평가해 개선이 필요한 지점을 찾았다.
- 작은 평가셋의 결론을 300문항에서 다시 확인해, 뒤집힌 결론(1000/200)을 바로잡았다.
- 답변 점수가 비슷할 때 비용·속도·단순성이라는 서비스 기준으로 최종 구성을 골랐다.

**아쉬운 점**

- 공통 평가셋과 기준 코드를 정하기 전에 각자 병렬 탐색한 기간이 길어, 초기 결과를 서로 비교하기 어려웠다.
- 실험 단계마다 Hit@5·MRR의 계산 단위가 달라 수치를 하나의 흐름으로 잇지 못했다.
- 최종 후보를 각각 한 번만 실행해 작은 차이의 원인을 분리하지 못했다.
- 복수 문서 질문과 후속 질문을 최종 구성에서 다루지 못했다.

## 13. 결론

본 프로젝트는 HWP 중심의 공공입찰 제안요청서 100건을 대상으로, 문서 처리부터 검색, 생성, 평가까지 갖춘 RAG 질의응답 시스템을 구현했다. 50건의 실험을 기록하며 사업별 검색, Kiwi 형태소 BM25, BGE 재순위화 모델, 1000/200 청킹을 단계적으로 채택했다. 300문항 검색 실험에서 BGE 재순위화 모델은 Hit@5를 0.8788에서 0.9428로 높였고, 1000/200 청킹은 필요한 근거를 모두 전달한 문항을 241개에서 259개(근거 정렬 297문항 중)로 늘렸다.

최종 후보 두 구성은 답변 품질에서 통계적으로 구분되지 않았고, 팀은 문맥이 27% 짧고 검색 시간이 중앙값 1.70초, p95 2.09초로 더 짧은 FINAL-02를 채택했다. FINAL-02는 300문항에서 LLM-as-Judge 0.930, Faithfulness 0.985를 기록했고, 독립 Holdout에서 핵심 사실 추출과 답변 거절이 양호했다.

가장 큰 교훈은 “근거를 더 많이 넣는 것”보다 “맞는 사업의 근거를 앞에 놓는 것”이 효과적이었다는 점, 그리고 작은 평가셋의 결론이 큰 평가셋에서 뒤집힐 수 있어 검색 전용 평가로 넓게 다시 확인하는 과정이 중요했다는 점이다. 남은 과제는 여러 사업과 여러 절에 흩어진 근거를 함께 모으는 것이며, 복수 사업 라우팅과 문서별 문맥 배분을 우선 개선할 계획이다.

# 부록

## A. 주요 실험 목록

| 실험 | 날짜 | 담당 | 범위 | 변경과 결과 |
|---|---|---|---|---|
| EXP-001~004 | 9/30~10/4 | 김현경 | 문서 1~99건 | 기본 RAG, HWP·표 Markdown, GPT-5 mini 전환, Dense+BM25+RRF+리랭커 골격 |
| EXP-005~006 | 10/5~10/7 | 김현경 | 99건 ·6~180문항 | 검색 근거·답변 분리 평가, 로컬 모델 채점 실패 |
| EXP-007~010 | 10/8 | 김현경 | 99건·10문항 | 정제 미채택, 사업별 검색 FC 0.354→0.838 |
| EXP-011~014 | 10/8 | 김현경 | 99건·10문항 | 1000/200(1차) 미채택, 임베딩 4종 비교 → BGE-m3-ko |
| EXP-015~022 | 10/11~10/13 | 김현경 | 3건·30문항 | BM25·Dense·리랭커 6구성, 생성 모델 비교, 청킹 방식 3종 ×3회 |
| EXP-023~025 | 10/15 | 김현경· 김민협 | 10건·30문항 | 공통 기준선, Kiwi 제거 시 하락, 프롬프트 v2 |
| EXP-026~031 | 10/15~10/16 | 이원영 | 10건·30문항 | BGE 리랭커, 청크 헤더, 1000/200, 029~031 보류 |
| EXP-032~037 | 10/15~10/16 | 김민협· 김현경 | 10건·30문항 | Dense 단독, parent-child, 질의 분해, EXP-037 최고 |
| RET 6건 | 10/16 | 이원영· 김민협 | 100건·300문항 | 검색 전용: 리랭커, 청크 크기, 헤더, parent-child |
| EXP-038 | 10/16~10/17 | 김현경 | 100건·300문항 | parent-child·질의 분해의 100문서 검색 |
| FINAL-01 | 10/19 | 김현경 | 100건·300문항 | parent-child + 질의 분해, Judge 0.920 |
| **FINAL-02** | **10/19** | **이원영** | **100건·300문항** | **1000/200 단일 검색, Judge 0.930 → 채택** |
| Holdout | 선정 후 | 권유진 | Holdout 30문항 | 채택 구성의 기능별 진단 평가 |

전체 50건의 조건·지표·결정은 실험 기록표에 있다. 기록표에는 EXP-026 번호가 김현경(100문서 평가)과 이원영(BGE 리랭커) 두 행에 쓰였으며, 본 보고서의 EXP-026은 이원영 행을 가리킨다.

## B. 재현 방법

```
git clone https://github.com/mingilee97/rag-project-part3-2team-main.git
cd rag-project-part3-2team-main
python -m venv .venv && source .venv/bin/activate
pip install -r requirements.txt
pip install --no-deps langchain-hwp-hwpx-loader==0.1.1
cp .env.example .env        # ANTHROPIC_API_KEY, GOOGLE_API_KEY 입력
# data/ 아래에 원본 100건, 파싱 캐시, data_list.csv, dev_benchmark_v1.1.json 배치
python -m rfp_rag ask --query "질문"     # 단일 질문
python final02.py base                   # 300문항 검색·답변·Judge
python final02.py ragas                  # Factual Correctness·Faithfulness
python final02.py summary                # 결과 표
```

원본 RFP·평가셋·파싱 캐시는 데이터 제공 조건에 따라 저장소에 포함하지 않는다. FINAL-02와 같은 결과를 얻으려면 실험에 사용한 파싱 캐시가 필요하다(11장 5번).

## C. 참고 자료

- GitHub 저장소: https://github.com/mingilee97/rag-project-part3-2team-main
- 실험 기록표: Google Sheets
- FINAL-02 최종 기술 리포트(2026-10-20), FINAL-02 최종 성능 평가 보고서(권유진), RAG 실험 분석 상세보고서(2026-10-16, 기록표 초기 조회본 기준), RAG 버전별 변경과 검증 결과(2026-10-12)
- 팀원별 협업일지: GitHub README의 협업일지 표
- LangChain, FAISS, Kiwi(kiwipiepy), RAGAS 0.3.9, Hugging Face 모델 카드(dragonkue/BGE-m3-ko, BAAI/bge-reranker-v2-m3)