RAG 캐시 기반 검색 비교

controlled-modules · 2026-10-12 · worktree candidate 33eb784 이후

> **판정:** 이 제한된 진단 비교에서는 김민협 청킹 개선을 채택하지 않았습니다. 두 방식 모두 문서 회수는 같았지만, 기존 gold 문구를 상위 5개 근거에서 찾은 수가 후보 청킹에서 줄었습니다. 사업명 선택기도 선택된 문서가 정답 문서 전체를 항상 담지 않아 독립 채택 근거가 부족합니다.

결과

조건	질문 중 ≥1개 Gold 문서 포함	문자 그대로 일치한 근거 / 가능한 근거	상태
메인 · fixed 1000/200	168/168	344/508 (67.7%)	선택기 미적용
김민협 청킹	168/168	277/508 (54.5%)	선택기 미적용
메인 + 사업명 선택기	168/168	346/508 (68.1%)	사업명 선택기 포함
김민협 청킹 + 사업명 선택기	168/168	278/508 (54.7%)	사업명 선택기 포함

분모: 168/168은 전체 168개 기존 질문 중 최소 1개 ID가 gold `answer_doc_ids`에 속한 문서가 상위 5개에 있는 질문 수입니다. 각 질문의 모든 gold 문서를 찾았다는 뜻이나 답변 정답률은 아닙니다. 508개 분모는 질문 데이터의 `evidence_quotes`에서 확인 규칙으로 추출한 고유 근거 문구 수입니다. NFC 정규화 후 공백을 제거하고 소문자화한 문자열의 포함 여부만 검사했으며 의미 일치는 판단하지 않았습니다.

후보 청킹은 메인 대비 상위 5개 근거의 문자 일치 수가 **-67**개 적었습니다. 선택기를 더해도 이 차이는 사실상 그대로였습니다. 이는 생성 답변의 정답률이 아니라 검색된 청크 텍스트 안의 검증 문구 수입니다.

선택기 진단

168개 기존 질문 중 선택기는 직접 매칭 82개, 기존 경로 우회 32개, 엄격 식별 거부 54개였습니다. 매칭된 질문에서 선택 문서가 gold 문서를 포함한 비율의 평균은 91.7%였습니다. 거부·우회는 기존 메인 이름 필터로 되돌려 검색을 이어갔습니다.

비교 방법과 범위

- 100개 문서, 기존에 사용된 168개 질문, 4조건 672행의 질문별 비교표를 CSV에 수록했습니다. 이 질문 집합은 이미 기존 분석에 사용됐으므로 신규 holdout이 아닙니다.
- 청크 크기 1000, overlap 200은 Python 문자열 길이 기준입니다. 메인의 RecursiveCharacterTextSplitter와 child splitter의 전체 100문서 출력이 현재 파서 결과에서 행 순서와 텍스트까지 각각 캐시와 일치했습니다. 두 임베딩 행렬은 같은 KURE-v1 revision·tokenizer/encoding 경로, 정규화, 1024차원입니다.
- 질문 벡터와 문서 벡터는 기존 KURE-v1 캐시만 사용했습니다. 현재 파서 출력 해시, 청크 텍스트 순서/해시, 행 수를 대조한 뒤 exact cosine으로 top 5를 뽑았습니다. 기존 운영 FAISS/Chroma ANN, reranker, query rewrite는 비교에 넣지 않았습니다.
- 상위 5개 청크 본문을 프롬프트 포맷 및 토큰 예산 자르기 전에 비교했습니다. gold 회수는 정답 문서 ID 포함 여부이며, 근거 회수는 NFC·공백 제거·소문자화 후의 문자열 포함 검사입니다. 의미적 정답률이나 실제 생성 답변 품질을 뜻하지 않습니다.
- 임베딩·reranker·답변 생성·judge·GPU·네트워크 호출은 모두 0회입니다. CSV의 generated_answer와 citations는 비어 있고 response_state는 not_executed입니다.

재현 출처

```
parser SHA-256: ed265fdea8d3ea7b34352664c020227faecca47fb391ccaccd82d2c301821145
questions SHA-256: c92f5abac57707ab256544b01013134664a09afac73151f69a08d423e018c9f9
query vectors SHA-256: 48eb6144df6a38e3db743ff24cee84dbd43b00c9c0a072559704b444302de383
main vectors SHA-256: 466b30c0ad36f41ae724576ac9e6a583ace5d207c427d805f740dfc2a94679b7
candidate vectors SHA-256: 3eb6699a8a50242e0bd03b9056df69bc577d1a09db9b8ff9d573cc70c2c14584
```

이 결과는 후보 branch 내부의 오프라인 검색 비교입니다. 전체 파서/색인/검색의 end-to-end 동등성이나 사업명 모듈의 네이티브 답변 품질을 확정하지 않습니다.

기존 답변 결과 재사용과 실행 상태

별도 DEV8 문맥 포맷 비교 · 현재 168문항 청킹 검색 결과와는 다른 실험

이미 완료된 8문항 쌍 비교

이전 로컬 보고서의 32개 완료 레코드는 DEV8 8개 질문(Q01, Q02, Q03, Q05, Q12, Q13, Q21, Q32)과 텍스트가 일치하고, 모델은 gpt-6-luna / low였습니다. 질문 본문을 재출력하지 않고 저장된 작업 프롬프트 끝부분과 현재 질문 텍스트를 해시 없이 내부 비교해 일치 여부만 확인했습니다.

이전 답변 조건	완료 레코드	found=true
메인 첫 답변 문맥 재생	8	6/8
child control	8	3/8
parent 8000	8	3/8
parent 4000 latest	8	3/8

parent 8000과 parent 4000 latest의 같은 질문 쌍에서 답변 제공 여부는 8/8 모두 같았고, grounding 분류는 7/8, 숫자·기간 분류는 6/8에서 같았습니다. 이것은 답변 제공 여부와 기존 검토 라벨의 비교입니다. 정답률이 아니며, 지금 비교한 chunking arms의 생성 답변으로 옮겨 쓰지 않았습니다.

CLI와 중복 방지

기존 Codex CLI의 읽기 전용 `login status` 확인은 성공해 ChatGPT 로그인 상태를 반환했습니다. controlled worktree의 providers에는 `subscription_cli` 어댑터가 없어 그 설정으로 pipeline을 부르면 fail-closed합니다. 별도 평가 worktree의 `scripts/native_subscription_host.py`와 `scripts/full_native_public_host_v005.py`는 동일 공식 CLI를 직접 부르는 기존 실행 경로입니다.

공식 세션 도구에서 **공개 모델 native 평가 마무리**가 active/inProgress이며 기존 host가 단일 writer로 남아 있습니다. 완료된 DEV8 결과를 재생성하지 않고 위 쌍 결과를 재사용했습니다. 현재 168개 검색 비교의 672행은 검색 집계이며, 새 모델 답변 호출 672회를 시작한 적은 없습니다.

남은 모듈 상태

모듈	현재 처리	다음 판단
김민협 `rag_chunking.py`	동일 문자 청크 조건의 진단에서 근거 문구 회수가 344→277로 감소	현재 최종 통합 후보에서 제외
김민협 `rag_context.py`	기존 parent 8000 대 parent 4000 paired answer 결과는 found 3/8 대 3/8	추가 개선 근거 없어 보류, 청킹 판단과 분리
김현경 사업명 식별기	별도 native 실행 세션이 진행 중; 이전 clarification/회귀 사례는 보존	세션 종료·인용 감사 전 통합 보류
권유진·이원영 소스	원본 저장소/소스 자산 미확보	미실행·미평가, 성능 실패로 간주하지 않음

현재 통합 승인 후보는 없습니다. 이 상태는 최종 선택을 확정하는 선언이 아니며, 진행 중인 native 감사와 원본 접근 가능성에 따라 다시 검토합니다.