01 유지한 구성과 결론

현재 평가 자료로 유지할 구성은 메인 07_verify다.

선정의 의미: 새 모델의 절대 우위를 확정한 것이 아니라, 대체 후보의 전체 개선이 입증되지 않아 기존 기준을 유지한 결정이다.

2026-10-12 PDF는 52개 변경·제출·판단 기록을 설명한다. 이 문서는 그 기록을 다시 나열하지 않고 유지한 구성 하나의 작동 방식과 선택 이유를 설명한다. PDF 이후 저장된 원문 재구축 평가도 별도 근거로 반영했다.

역할	유지한 선택	이 문서에서 설명할 이유
한글·PDF 읽기	HWP: olefile / PDF: PyMuPDF	본문과 표를 읽는 방식, 팀원 파서와의 차이
청크	fixed 1,000자 / 겹침 200자	fixed 선택 근거와 크기 선택의 미검증 범위
임베딩·색인	nlpai-lab/KURE-v1 / Chroma	과거 검색 비교와 현재 재구축 결과
검색기	dense / similarity / k=5	질문 종류에 맞춘 검색과 문서 범위 제한
리랭커	사용하지 않음	enabled:false; 과거 재순위 비교의 결과
답변 처리	route·verify·use_enriched 켬	대화 처리·숫자 검증·문서별 요약
최신 공통 생성	gpt-6-luna / low	후보 간 생성 조건을 맞추기 위한 평가 조건

생성 모델과 RAG 구성을 구분해야 한다

저장된 기본 실행 설정의 생성 모델은 exaone3.5:7.8b다. 최신 비교에서는 이를 gpt-6-luna / low로 바꿔 실행했다. 따라서 이 문서는 "EXAONE가 Luna 평가에서 이겼다" 또는 "Luna가 다른 생성 모델보다 우수하다"는 결론을 내리지 않는다.

최신 원문 재구축 비교는 같은 DEV8 8문항을 6구성에 적용한 48건이다. 정상 처리 38건과 소스 오류 10건을 보존했다. 메인은 8/8 처리했으나 답변의 누락과 범위 오류가 남아 있다. 정상 처리는 정답 판정과 다르다.

근거: 제공 PDF 1·3·9~10쪽 [S1]; 최신 전체 native 보고서·구성별 결정 [S2·S3].

02 질문에서 답변까지의 과정

단순 검색 한 번으로 모든 질문을 처리하지 않는다.

문서는 미리 준비한다

단계	처리	남기는 정보
1. 추출	olefile·PyMuPDF로 원문을 읽는다.	문서 ID·기관·사업명·추출 방식·실패 여부
2. 청킹	본문을 fixed 1,000/200으로 나눈다.	청크 ID·원본 문서 ID·[기관] 사업명 접두부
3. 색인	KURE-v1 벡터를 Chroma에 저장한다.	임베딩·청킹 구성별로 분리한 색인
4. 요약	문서별 목적·기간·범위를 요약한다.	CSV 값과 생성 요약을 구분한 100문서 요약

질문이 들어오면 대화와 질문 종류를 먼저 확인한다

"그 사업의 세부 요구는?"처럼 앞 대화를 가리키면 독립적인 질문으로 다시 쓴다. 그다음 기관·사업명과 질문 표현으로 single, meta, compare, search를 고른다. 규칙으로 결정하지 못하는 경우만 모델 분류를 사용한다.

질문 종류	모으는 근거와 답변 방식	이 방식을 둔 목적
single 한 사업 내용	해당 문서에서 dense 상위 5개를 찾고 문서 요약을 앞에 붙인다.	세부 근거와 사업 전체 윤곽을 함께 준다.
meta 예산·마감 등	CSV의 값을 근거로 사용한다.	목록에 있는 정확한 값을 본문 검색으로 우회하지 않는다.
compare 여러 사업 비교	각 문서에서 따로 답한 뒤 비교 요약을 만든다.	서로 다른 기관의 금액·기간이 섞이는 문제를 줄인다.
search 사업 목록 탐색	100문서 요약을 임베딩해 관련 요약을 찾는다.	한 청크에 없는 문서 전체 주제를 찾는다.

agency_filter:false가 문서 범위를 전혀 좁히지 않는다는 뜻은 아니다. 별도 검색기 옵션은 꺼져 있지만, route와 pipeline이 식별한 문서 ID로 single·compare 검색 범위를 좁힌다.

모델은 answer·found·evidence_ids를 반환한다. 코드는 JSON 형식과 인용을 확인하고 숫자·날짜를 근거와 대조한다. 검증은 의미 판단의 일부만 맡으며 답변의 완전성을 보장하지 않는다.

근거: 메인 기술문서 3·13·15절, pipeline.py·retrieve.py·chunk.py [S4·S5].

03 왜 한글 읽기에 olefile을 유지했나

olefile로 한글 내부 데이터를 열고, 자체 코드가 문단과 표를 해석한다.

말씀하신 "Only File"에 해당하는 코드 이름은 olefile이다. 라이브러리 하나가 표를 완성하는 구조는 아니다. 메인 코드가 FileHeader와 BodyText를 읽고 압축을 푼 뒤 PARA_TEXT 레코드를 해석한다. 표의 칸은 " | ", 행은 줄바꿈으로 이어 검색할 본문을 만든다.

선택·대안	확인한 장점	확인 범위와 한계
메인 olefile	필요한 본문·표 레코드를 직접 읽는다. 최신 원문 100문서 파싱에서 메인 실패는 0건이다.	텍스트·표 칸 관계를 남긴다. 그림 속 글자와 전체 시각적 배치의 보존은 보장하지 않는다.
hwp5html	표 구조를 HTML로 표현할 수 있다.	과거 기록에서 큰 HWP 한 건에 46~129초. 메인은 이를 사용하지 않았다.
김현경 로더	HwpHwpxLoader와 pymupdf4llm로 HWP·PDF를 읽는다.	원본 A는 HWP 제어문자 처리 정체로 99/100. 이후 수정한 B는 100/100.
김민협 파서	HWP parser를 사용하며 제어문자 관련 수정 코드가 있다.	그 수정은 김현경 후보 B에 실제 적용했다. 메인 파서의 교체는 하지 않았다.

선택 이유는 속도 기록과 현재 파싱 결과다

메인 과거 EDA 기록에서 olefile의 HWP 처리 중앙값은 문서당 0.02초, 최대 0.04초, 96건 합계 1.7초였다. 이는 당시 자료의 수치다. hwp5html의 큰 파일 사례와 표본·조건이 같지 않으므로 정확한 배수나 현재 성능으로 비교하지 않는다.

팀원의 개선을 실제로 채택한 사례

후속 평가에서 김민협 원본 notebook cell9의 파서 수정만 김현경 파서에 적용했다. 원본 A 99/100 → 후보 B 100/100으로 바뀌었다. A에서 성공한 99문서는 원래 공백 정리 후 본문이 모두 같았다. 수정된 B를 원본 A의 성공으로 계산하지 않았다.

> 메인은 자체 파서에서 실패가 없었다. 그래서 이 수정을 메인에 추가하지 않았다. 팀원 도구가 열등해서 전부 제외한 결정이 아니라, 필요한 후보에 검증된 수정을 적용한 결정이다.

잠금·열기 실패 시 CSV 텍스트를 대신 쓰는 경로도 있다. CSV는 원문 전체가 아니므로 대체 사용을 기록한다. 최신 결과만으로 모든 HWP/HWPX·그림·복잡한 표에 호환된다고 주장할 수는 없다.

근거: 메인 기술문서 6절·load.py [S4·S5]; 최신 보고서와 parser B 코드·보존 기록 [S2·S8].

04 검색기와 리랭커를 고른 이유

dense similarity k=5를 유지하고, 리랭커는 끈 상태다.

dense 검색은 질문과 청크를 의미 벡터로 비교한다. BM25는 단어 일치를 이용한다. RRF는 여러 검색 결과의 순위를 합친다. 리랭커는 찾은 후보를 질문과 함께 다시 읽어 순서를 바꾼다. 메인에는 이 기능들이 있지만 07_verify에서 모두 활성화된 것은 아니다.

과거 검색 비교에서 얻은 근거

검색 조건	사실 포함률	유지·보류 이유
dense, k=5	0.731	기준. hit@5 0.967, MRR 0.917.
dense+BM25 혼합	0.712	정답 문서 1위 비율과 MRR도 기준보다 낮았다.
BM25 단독	0.579	검색한 근거의 필수 사실 포함이 부족했다.
Multi-Query	0.659	질문을 늘렸지만 사실 포함은 개선되지 않았다.
MMR	0.613	다양성 확보가 필수 사실 보존으로 이어지지 않았다.
dense, k=10	0.816	검색 포함은 늘었으나 과거 답변 개선은 작고 지연이 늘었다.

이 수치는 전처리 전 개발 30문항의 검색 결과다. 최신 Luna 답변 정답률이나 모든 문서의 성능은 아니다. k=10의 과거 답변 정확성 점수는 3.8333→3.8667, p95는 9.645→13.178초였다. 당시 속도 대비 개선이 작아 k=5를 유지했다.

리랭커는 이름만 남아 있고 실행하지 않는다

설정에 BAAI/bge-reranker-v2-m3가 있으나 enabled:false다. 한국어 모델, 후보 20/50개, 입력 한도 512/1,024/8,192토큰을 비교한 후속 검색 실험에서도 채택 기준을 충족하지 못했다.

후속 재순위 조건	정답 문서 내 사실 포함률	전체 문서 검색 중앙 시간
리랭커 끔	0.888	0.04초 / 질문
BGE 후보20 / 한도8192	0.789	0.15초 / 질문
한국어 BGE 후보20	0.802	0.15초 / 질문

이 결과로 모든 리랭커가 불필요하다고 결론내리지 않는다. 팀원의 GTE 재순위는 다른 파서·임베딩·사업 선택기와 함께 평가됐으므로 효과를 하나만 분리한 비교가 아니다.

근거: 메인 기술문서 13·13.1절 및 검색 결과 JSON [S4·S6]; 제공 PDF 13쪽 [S1].

05 왜 KURE-v1 임베딩을 유지했나

유지 이유는 한국어 모델이라는 설명보다 해당 데이터의 검색 비교 결과다.

임베딩 모델과 생성 모델은 역할이 다르다. KURE-v1은 원문 청크와 질문을 검색용 벡터로 바꾼다. Luna는 찾아온 근거로 답을 쓴다. 생성 모델을 Luna로 통일해도 임베딩·파서·검색 차이가 없어지지 않는다.

과거 동일 검색 조건	hit@1	hit@5	사실 포함률
KURE-v1	0.867	0.967	0.731
BAAI/bge-m3	0.900	0.933	0.636



과거 dev30 · 전처리 전 · fact_recall · 0~1

bge-m3가 정답 문서를 1위로 찾는 비율은 더 높았다. KURE-v1은 상위 5개에 정답 문서를 넣는 비율과 답변에 필요한 사실을 포함하는 비율이 더 높았다. 여러 사실을 근거로 답하는 용도에서 이 차이가 KURE 유지의 기록된 근거다.

팀원의 임베딩은 어떻게 다뤘나

모델	실제 후속 평가 범위	현재 판단
Alibaba-NLP/gte-multilingual-base	김현경 archive 후보에서 새 색인과 Luna 답변을 실행했다.	Q02 장점이 있으나 Q21 세부·Q13 기간 누락이 남았다.
dragonkue/BGE-m3-ko	김현경 basic·kiwi 후보에서 실행했다.	사업 선택기의 5건 오류가 남았다. 임베딩 단독 열위로 해석하지 않는다.
nlpai-lab/KoE5	김민협 local dense·hybrid 후보에서 실행했다.	다른 사업 근거 혼입과 비교 누락이 남았다.
text-embedding-3-small	김민협 OpenAI 원본 검색은 미실행이다.	문서·질문 벡터, ID 대응, parent/docstore가 필요하다.

KURE-v1을 GTE·KoE5·한국어 BGE 모두보다 우수하다고 확정한 단일 변수 실험은 없다. 새 후보의 전체 개선이 입증되지 않았으므로 기존 검색 구성을 유지했다.

색인 저장소는 메인의 Chroma를 유지했다. 팀원은 FAISS를 사용하지만 두 저장소만 바꾼 품질·속도 비교는 없다. Chroma 유지의 근거는 기존 구현과 검증된 연결을 보존하는 것이며, FAISS보다 우수하다는 판정은 아니다.

데이터셋도 구분한다. 최신 원문은 HWP 96개·PDF 4개다. DEV8는 서로 다른 8문항이며 Q32는 답이 없는 질문이다. 과거 dev30 검색 점수와 팀원의 한 사업 10문항 RAGAS 점수는 서로 다른 평가다.

근거: 메인 기술문서 12~13절·임베딩 결과 JSON [S4·S6]; 최신 구성별 결정 [S2·S3].

06 청크 크기와 겹침을 유지한 이유

fixed 방식의 근거는 있지만, 1,000/200이 최적이라는 근거는 없다.

청크는 검색을 위해 나눈 본문 조각이다. 메인은 RecursiveCharacterTextSplitter로 본문을 최대 1,000자, 겹침 최대 200자로 나눈다. 문단 경계에 따라 실제 길이는 더 짧을 수 있다. 앞에 붙이는 [기관] 사업명은 본문 크기와 별개다.

구성	검색용 청크	최신 구축 청크 수	처리 특징
메인	fixed 1,000/200자	10,922	dense k5와 문서별 요약을 함께 사용
김현경 계열	700/100자	30,676	dense/BM25·재순위 및 사업별 검색 계열
김민협 local	500/100자	45,495	KoE5 dense 또는 dense/BM25 혼합
김민협 OpenAI	child 800/150자 parent 8,000자	미실행	원본 전체 검색은 미실행. 작은 조각 검색 뒤 큰 parent를 답변에 제공

청크 수가 많거나 적다는 사실만으로 품질을 판단하지 않는다. 파서가 뽑은 본문도 서로 다르므로 위 숫자는 청크 크기만의 효과가 아니다. 문자 단위 청킹과 모델 입력의 토큰 한도도 구분해야 한다.

fixed를 section보다 선택한 근거

과거 dev30 검색에서 fixed의 hit@5는 0.967, 사실 포함률은 0.731이었다. 제목·목차 기준 section은 각각 0.933, 0.526이었다. 같은 상위 5개 근거를 제공하는 조건에서 fixed가 필수 사실을 더 많이 포함했다.

1,000/200을 고른 최초 이유는 기록에 없다

메인 기술문서는 크기와 겹침을 바꾼 실험이 없다고 명시한다. 겹침은 경계의 문맥을 일부 남기지만 200자가 충분한지 검증하지 않았다. 과거 요구사항 4,935개 중 1,816개가 경계에서 나뉘었으며, 이 문제의 개선도 확인되지 않았다.

김현경의 별도 700/100→1,000/200 실험은 청크 수 30,265→20,247을 보고했다. 정답성 평균은 0.838→0.813이었지만 맞게 답한 수량 문항에 0점이 매겨진 사례가 있다. 이 자료로 메인의 1,000/200 최적성을 주장하지 않는다.

parent 한도 축소는 청크 크기 변경과 다르다

별도 문맥 진단은 전체/parent 입력 한도를 8,000/2,000→4,000/1,000토큰으로 줄였다. 문맥 토큰 합은 26,416→16,129로 감소했지만 답변 제공은 3/7로 같았고 Q21 근거가 빠졌다. 입력 감소를 품질 개선으로 채택하지 않았다.

근거: 메인 기술문서 11절·chunk.py [S4·S5]; 제공 PDF 51·67~68쪽 [S1]; 최신 구축 결과 [S2].

07 채택·유지·보류를 한눈에 보기

팀원 코드의 도입과 메인에서 발견한 결함 수정을 구분한다.

항목과 출처	판단	실제로 달라진 점과 이유
메인 JSON 응답 검사	메인에 반영	answer 문자열, found boolean, evidence_ids 정수 목록을 검사한다. 잘못된 타입·구조를 정상 응답으로 통과시키지 않는다.
메인 detail 항목별 인용	메인에 반영	각 항목이 인용한 근거만 검사한다. 다른 항목의 숫자가 잘못된 근거를 대신하는 문제를 고쳤다.
김민협 HWP 파서 수정	김현경 후보 B에 적용	HWP 제어문자 문제를 수정해 99/100→100/100. 메인은 같은 결함이 없어 도입하지 않았다.
김현경 사업명 식별	메인 도입 보류	정식 제목의 질문에는 범위를 좁히는 장점이 있다. 약칭·후속·비교 질문의 차단과 단일 사업 선택 실패가 남았다.
김현경 Kiwi BM25	추가 채택 근거 없음	메인에는 Kiwi 코드가 이미 있다. 현재 dense 경로에서 새 BM25 개선을 활성화한 것은 아니다.
김민협 parent 확장·한도 축소	메인 도입 보류	기존 메인 청크와 parent 직접 연결 부족, 원본 검색 자산 미확보, 축소 시 근거 손실이 남았다.
팀원 GTE/BGE/KoE5 검색 구성	대체 보류	최신 재구축 비교에서 강점은 있으나 메인 전체를 대체할 개선은 입증되지 않았다.

메인에 반영한 오류 수정은 이렇게 검증했다

수정 전 동일 회귀 검사는 11실패·2오류로 결함을 재현했다. 수정 후 8개 회귀 검사와 필수 4개 자체 검사를 통과했다. 과거 answer 이벤트 14개에서도 answer·found·인용 순서·given의 호환성을 확인했다. 반영 커밋은 9f7c5ce, 근거 정리는 60b2f9b다.

JSON·detail 수정은 비교 중 발견한 메인 오류를 고친 것이다. 팀원 검색 알고리즘을 이식한 개선으로 설명하지 않는다. 특히 detail은 07_verify에서 기본적으로 꺼져 있으므로 모든 질문의 답변 정확도가 올랐다고 말할 수 없다.

빈 evidence_ids에 과거 방식대로 전체 근거를 대신 사용하는 호환 동작도 남아 있다. 이것은 실제 문장별 인용을 입증하지 않는다. 검증 통과와 의미 정확성은 구분해야 한다.

근거: 제공 PDF 69~71쪽·Version45 [S1]; 모듈 통합 기록 [S7]; 최신 파서 B 결과 [S2·S8].

08 마지막 평가에서 실제로 확인한 결과

PDF 이후의 6구성 재구축 비교에서도 메인을 유지했다.

원문 100문서에서 파싱·청킹·색인을 다시 구축했다. 메인 문서 요약 100개도 Luna로 준비했다. 이후 각 구성에 같은 DEV8 8문항을 적용했다. 생성은 gpt-6-luna / low로 통일했으며 원래 EXAONE·KULLM3의 생성 성능을 재현한 비교는 아니다.

구성	정상 처리	소스 오류	전체를 대체하지 않은 이유
메인 07_verify	8/8	0	기준 유지. Q21 세부조건 누락·Q12 기관 범위 문제는 남음.
김민협 dense	8/8	0	Q21 다른 사업 근거 혼입, Q13 기간·Q12 탐색 누락.
김민협 hybrid	8/8	0	일부 수량은 회복했지만 혼입 지속. Q13 GIST 검색 누락.
김현경 archive B	8/8	0	Q02 목적 설명의 장점. Q21 상세·Q13 기간은 부족.
김현경 basic B	3/8	5	사업명 식별 오류와 한 사업만 고르는 비교 실패.
김현경 kiwi B	3/8	5	같은 사업명 오류·비교 실패. Kiwi 개선이 입증되지 않음.

정상 처리에는 올바른 거절도 포함된다. 8/8은 정확도 100%가 아니다. basic·kiwi의 생성 전 ValueError 10건은 실패를 감추지 않고 분모에 보존했다.

앞선 두 비교는 별도의 결과다

비교	관측	포함하지 않은 범위
문맥 4조건 × 8문항 32건	답변 가능한 7문항: 메인 첫 answer 재생 6/7; child·두 parent 각 3/7.	첫 answer 재생이며 원본 dense/RRF/BGE 전체 검색과 후속 병합은 아님.
부분 native 2구성 × 8문항 16개 흐름·19생성	답변 제공: 메인 7/7, 사업명 후보 3/7. 후보 재질문 4건.	기존 문서·색인·요약을 재사용. 원문부터 새 구축한 평가는 아님.

DEV8의 Q32는 문서에 없는 최종 수주업체를 묻는 별도 거절 항목이다. 앞선 비교의 분모 7은 실패를 뺀 숫자가 아니다. 32건·16개 흐름·최신 48건은 실험 범위가 달라 합산 성능으로 만들지 않는다.

최신 질문 단계 생성은 메인 12회, 후보 합계 30회로 총 42회다. 사전 요약 100회를 더하면 142회다. 반복되는 같은 8문항이므로 48개의 독립 질문을 평가한 것으로 세지 않는다.

근거: 최신 전체 native 보고서·version-decisions.csv [S2·S3]; 제공 PDF 3·72~74쪽 [S1].

09 유지한 메인의 강점과 남은 문제

비교·사업 범위·후속 대화의 결과를 구체적인 문항으로 설명한다.

문항	최신 메인에서 확인한 결과	선택 판단에 주는 의미
Q03 한 사업의 값	사업비 157,300,000원, 계약일부터 5개월 이내, 계약 방법의 세 사실이 원문과 일치했다.	검색 후보에 다른 사업이 있어도 답변 근거는 목표 사업에 대응했다.
Q13 두 기관 비교	고려대 24개월 이내와 GIST 5개월 이내를 각각 올바르게 귀속했고 두 예산도 일치했다.	문서별 답변 후 병합하는 메인 구조를 유지할 근거다. 반복 안정성은 미검증이다.
Q21 Q01의 후속	국민연금 문서의 근거로 답했고 다른 기관 CMS 요구는 섞이지 않았다.	후속 대화 연결의 장점. 30~40분·50%·146개 조건 누락은 해결되지 않았다.
Q12 다른 기관 탐색	다른 기관 5곳과 함께 제외해야 할 국민연금도 나열했다.	의도에 맞는 기관 제외와 목록 완전성을 더 확인해야 한다.
Q32 답이 없는 질문	found=false로 최종 수주업체를 만들지 않았다.	확인 불가를 거절한 사례다. 모든 부재 질문의 안전성을 보장하지 않는다.

왜 후보의 장점을 인정하고도 메인을 유지했나

김현경 사업별 검색은 목표 문서만 보게 하는 장점이 있다. archive는 목적 설명과 인용에서 장점을 보였다. 김민협 hybrid는 일부 요구 수량을 회복했다. 하지만 대화·여러 사업 비교·목록 탐색을 포함하면 차단과 혼입·누락이 남았다. 이번 용도는 이 흐름을 함께 처리해야 하므로 부분 장점만으로 전체 구성을 교체하지 않았다.

후속 검증을 한다면 우선 확인할 세 가지

우선 확인	구체적인 확인 내용
근거 완전성	Q21처럼 필요한 조건을 항목별로 대조한다. 숫자 존재 검사만으로 누락을 통과시키지 않는다.
사업 귀속·목록 의도	Q12의 제외 기관, Q13의 기관별 기간·예산, 다른 사업 근거 혼입을 확인한다.
독립적인 선택 효과	파서·청킹·검색·생성 조건을 고정하고 바꾸려는 모듈 하나를 분리한다. 새 질문과 반복 실행으로 변동을 확인한다.

이 항목은 문서에 남긴 후속 검증 제안이다. 이번 작업에서 새 모델 호출·재채점·코드 변경을 실행한 것은 아니다.

근거: 최신 전체 native 기술 보고서의 main_07 문항별 검토·구성별 보류 이유 [S2].

10 근거와 판단 범위

과거 수치·최신 관측·미검증 이유를 분리해 읽는다.

근거	이 문서에 사용한 범위
S1 · 제공 PDF (77쪽)	최종 구성 유지, 32문맥·16부분 native, 버전별 보류, JSON 수정, parent 진단.
S2 · 최신 전체 native 기술 보고서	PDF 이후 6구성48건, 원문 재구축, 문항별 검토, 파서 A/B, 최신 반영 결정.
S3 · version-decisions.csv	구성별 시도·정상·소스 오류·생성 호출·임베딩·청크 수.
S4 · 메인 docs/기술문서.md	olefile 선택 이유, fixed/section, KURE/BGE, 검색·리랭커, 질문 처리 설명과 미기록 이유.
S5 · 메인 코드와 설정	load.py·chunk.py·retrieve.py·pipeline.py·base.yaml·07_verify.yaml의 실제 동작.
S6 · results/retrieval_*.json	과거 전처리 전 dev30 검색 지표와 후속 리랭커 비교를 기술문서와 대조.
S7 · module-integration-20261011	메인 JSON·detail 수정, 회귀 검사와 과거 이벤트 호환성.
S8 · full-native-public v004 파서 자료	김민협 원본 cell9 수정 → 김현경 B 적용 및 기존 성공 문서 보존.

이 문서에서 확정하지 않은 사항

통계적으로 가장 좋은 모델, 최신 전체 정확도, 1,000/200의 최적성, GTE·KoE5·한국어 BGE에 대한 KURE 단독 우위, 실제 비용 절감은 확정하지 않았다. 최신 생성은 요청당 한 번이고 temperature·seed를 고정하지 않았으므로 작은 차이에 인과 설명을 붙이지 않는다.

권유진·이원영은 접근 가능한 소스·고정 commit·결과가 확보되지 않았다. 제외는 성능 열위 판정이 아니다. 김민협 OpenAI parent 경로도 원본 벡터·ID 매핑·docstore 부족으로 전체 검색이 남아 있다. 공개 가중치 확보와 원본 결과 복원은 다른 일이다.

이번 문서 작업의 범위

원본 PDF, PDF 이후 저장된 평가 보고서·CSV, 메인 코드와 기술문서를 읽어 본문을 재구성했다. 원문 RFP와 전체 비공개 답변을 새 문서에 옮기지 않았다. 기존 원본·코드·설정·평가 결과를 변경하지 않았으며 외부 연구와 새 모델 실행은 하지 않았다.

결정과 다음 작업

설명 대상은 메인 07_verify 하나로 정했다. 팀원 후보는 그 선택을 이해하는 데 필요한 변경만 설명했다. 원본 77쪽은 보존하고 별도 기술 리포트를 저장했다. 현재 요청에 필요한 추가 결정은 없다. 팀 공유·발표용 수정을 원하면 원하는 독자와 분량을 알려주면 이 문서를 기준으로 조정할 수 있다.

근거 기준일: 평가 기록 2026-10-12 / 문서 재구성 2026-10-13. 실행 커밋과 문서 정리 커밋은 구분한다.