선정 구성을 유지하며, 개선 효과를 재현한다

이 리포트는 기존 **07_verify**의 구성과 선택 이유를 설명한다. 신설 기초 파이프라인은 각 개선 요소의 효과를 다시 검증하기 위한 실험 기준선이다.

목표와 현재 결정

제안요청서에서 근거를 찾아 답하고, 팀원 코드의 개선 요소를 공통 조건에서 비교해 채택·보류 이유를 남긴다. 대체 구성이 기존 선정 구성보다 유리하다고 검증될 때만 교체한다. 그렇지 않으면 기존 구성을 유지한다.

구분	확인한 상태
기존 선정 구성	EXAONE 3.5:7.8b · KURE-v1 · Chroma · 1,000/200 · Dense Top-5 · rerank off
신설 실험 기준선	Haiku 4.5 + TF-IDF 기본. GPT-5 mini + OpenAI 임베딩은 별도 옵션. 기존 선정 구성의 대체 확정 아님.
최근 팀 비교	6구성 × 공통 DEV 8문항. 48회 시도 중 38회 정상 처리 ·10회 오류. 정확도로 해석하지 않음.
이번 제작 범위	로컬 설정·코드·집계·기존 발표 대조. 새로운 모델/API 호출이나 새 품질 실험 없음.

선정 근거를 읽는 방법

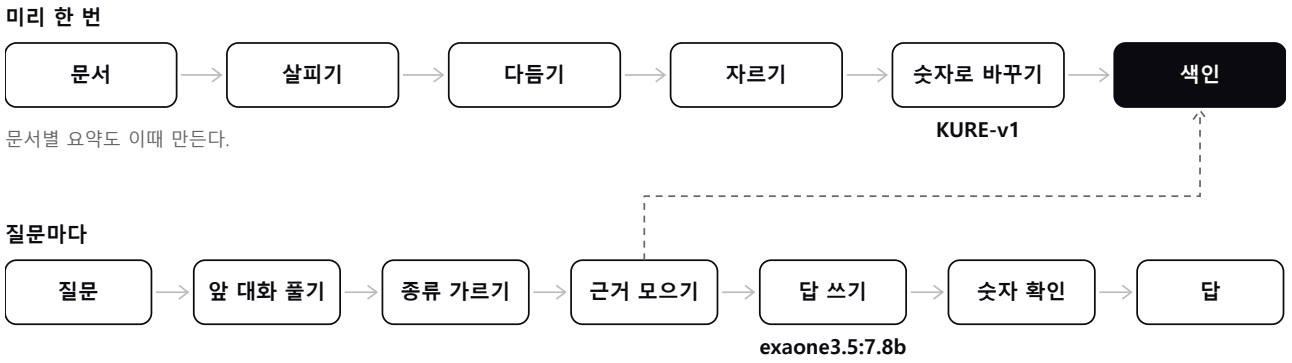
검색 지표, 자동 심판 점수, 실행 완료 건수는 서로 다른 증거다. 과거 한정 실험의 관찰은 현재 구성 유지의 이유로 쓰되, 모든 데이터에서 최적이라는 주장으로 확장하지 않는다.

핵심 결론

KURE의 근거 포함률, 고정 길이 청킹의 관찰값, 리랭커 후속 실험, EXAONE의 지연·거절 지표를 종합해 기존 구성을 유지한다. 일부 경쟁 구성이 더 나은 지표도 있으며, 최신 팀 비교에서 전체 교체 우수성은 입증되지 않았다.

> 발표 본편 12장, 부록 4장. 본 리포트 12쪽은 선택 이유·반례·예상 질문·미검증 범위를 보완한다. 원본 RFP 본문과 개인 작업 경로는 포함하지 않았다.

아키텍처와 실제 처리 경로



채점하는 Claude는 개발할 때만 쓴다.

문서 준비 단계

HWP/PDF 텍스트를 추출하고 제어문자·공백 등을 정리한다. 문장을 우선하는 경계로 청크를 나누고 제목·기관 정보를 부가한다. KURE로 벡터를 만든 뒤 Chroma에 저장한다. 문서별 요약 등 보강 정보는 질문 시 사용할 별도 문맥이다.

질문 처리 단계

이전 대화가 필요한 질문을 풀어 쓰고 질문 유형을 분류한다. 단일 사업 질문은 해당 문서 범위를 좁혀 검색한다. 저장된 `agency_filter=false`는 모든 경로에서 문서 제한을 하지 않는다는 뜻이 아니다. 단일 문서 경로의 문서 ID 제한은 별도로 작동한다.

기본 Dense 검색은 Top-5다. 요약을 함께 붙이면 생성기에 전달하는 근거 수는 5개보다 많을 수 있다. 검색 점수 기준과 답변 거절·숫자 검증을 거친다. 각 규칙이 의미 수준의 진실성까지 보장하지는 않는다.

역할	저장 구성·의미
임베딩	nlpai-lab/KURE-v1 · 문서와 질문의 벡터 표현
색인	Chroma · 기존 구현의 벡터 저장·검색
생성	local exaone3.5:7.8b · 근거를 읽고 답과 근거 ID 작성
개발 평가	Claude 자동 심판 · 서비스 답변 생성기와 분리

> 기존 Claude 3판 26쪽 도식을 재사용했다. 별도의 최신 비교에서 실제 실행된 생성 모델은 gpt-6-luna/low이므로 이 도식의 EXAONE 결과로 혼합하지 않는다.

입력과 파싱: 빠른 추출과 충실도는 별도 문제

확인한 코퍼스는 HWP 96개와 PDF 4개, 총 100개다. 기록상 100개 모두 텍스트를 추출했다. 이 성공은 문서의 표·순서·레이아웃·의미를 완전히 복원했다는 검사가 아니다.

HWP	→ 본문 접근	→ 문자 처리	→ 텍스트
OLE 컨테이너	압축·레코드	표 셀·줄	청킹으로 전달

왜 olefile인가

olefile은 OLE 저장소를 읽는 도구다. 코드가 HWP 헤더와 압축 플래그를 확인하고 BodyText의 Section을 풀어 PARA_TEXT 레코드를 읽는다. 표 셀은 구분자로 이어 붙이고 줄을 보존하는 별도 처리를 한다. 머리말·꼬리말·각주 등을 생략하는 동작은 누락 위험과 함께 이해해야 한다.

기술 기록에는 HWP 문서별 중앙값 약 0.02초, 최대 약 0.04초, 전체 약 1.7초가 남아 있다. 기존 HTML 변환 도구의 큰 파일 처리 46–129초 관찰도 있으나, 전 문서를 같은 장비·출력 품질로 통제한 비교가 아니다. 이를 보편적인 속도 배수나 동일 충실도의 우위로 발표하지 않는다.

PDF와 실패 경로

PDF는 PyMuPDF로 텍스트를 뽑는다. 이미지 PDF의 OCR은 구현 범위 밖이다. 잠김·손상 등에는 CSV 대체 경로가 있으나 해당 코퍼스의 사용 기록은 0건이다.

확인된 것	아직 확인하지 못한 것
파일 100/100 텍스트 추출	원본 표와 추출 결과의 셀·순서·계층 대조
팀 후보 일부 제어문자 수정 후 추출 성공	모든 서식·비정상 HWP·스캔 PDF의 범용 처리
기존 메인은 이미 100/100	후보 파서가 메인보다 의미 보존에 유리한지

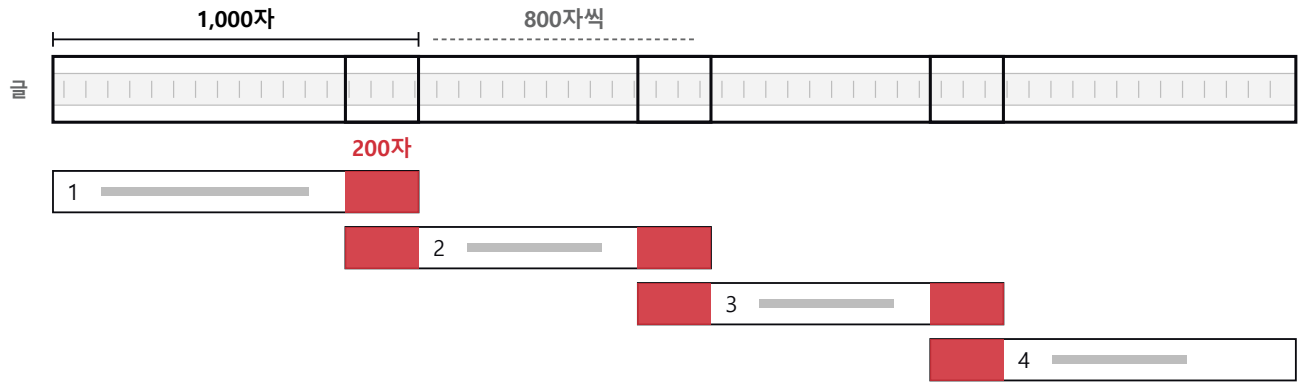
다음 검증

문서 유형별 표본을 고정하고 원본의 표·번호·제외 조건과 추출 텍스트를 대조한다. 그 뒤 같은 질문의 근거 포함률과 답변 오류까지 연결해 파서 변경의 실제 효과를 판단한다.

청킹과 임베딩: 선택 이유와 미확인 범위

1,000/200은 현재 유지값이며 최적값이 아니다

RecursiveCharacterTextSplitter가 빈 줄·줄바꿈·공백·문자 순으로 경계를 찾는다. 본문 청크는 최대 1,000자, 겹침은 최대 200자이며 실제 길이는 달라진다. 제목/기관 접두어는 바깥에 붙어 전체 청크가 1,000자를 넘을 수 있다.



DEV 30 검색 비교	고정 길이	절 단위
fact_recall	0.7312	0.5261
Hit@5	0.9667	0.9333

전처리 후 고정 길이 청크 10,922개, 절 단위 18,445개 기록. 크기·겹침 탐색 실험과 1,000/200의 최초 설정 근거는 확인되지 않았다. 절 경계가 항상 불리하다는 결론은 아니다.

KURE는 근거 포함률을 우선해 유지

DEV 30 검색 지표	KURE-v1	BGE-m3
fact_recall	0.7312	0.6355
Hit@1	0.8667	0.9000
Hit@5	0.9667	0.9333

같은 비교에서 BGE는 Top-1이 더 높다. KURE는 Top-5와 근거 포함률에서 유리했다. 다른 임베딩 모델 전체를 포함한 우승이나 한국어 전반의 우위를 입증한 결과가 아니다. 임베딩이 달라지면 색인을 따로 재구축해야 한다.

> 벡터 차원 표기가 자료 간 일치하지 않아 수치로 단정하지 않았다. 재현 시 실제 모델 출력·인덱스 차원을 확인한다.

검색과 리랭커: 복잡성보다 확인된 효과를 우선

현재 경로

기본값은 Dense 유사도 Top-5다. 질문 분류·사업 식별로 문서 범위를 제한하고 필요하면 문서 요약을 보강한다. Chroma는 구현의 저장소 선택이며 FAISS 등보다 낫다는 통제 비교는 없다.

과거 DEV 30 검색 실험	fact_recall
Dense k=5	0.731
Hybrid / BM25	0.712 / 0.579
MultiQuery / MMR	0.659 / 0.613
Dense k=3 / k=10	0.623 / 0.816

k=10은 검색 근거 포함률이 높았으나 생성 품질·문맥량·지연의 절충을 고려해 k=5를 유지한 기록이다. 검색 한 지표의 최대값만으로 전체 시스템을 선택하지 않는다. 위 표와 아래 후속 리랭커 실험은 별도 실행이므로 기준값이 다르다.

리랭커 후속 실험

조건	문서 17문항 fact_recall	전체 30문항 fact_recall
off	0.8882	0.7572
on · 후보 20	0.7892	0.7123

후보 수 50, 입력 길이 512/1,024, 한국어 후보 설정을 바꾼 후속 기록도 있다. 문서 범위 지표 +0.02, 개선 문항이 악화보다 많음, Hit@5 유지, 추가 지연 1초 이내라는 당시 채택 기준 중 핵심 품질 조건을 충족하지 못했다. 따라서 rerank off를 유지했다.

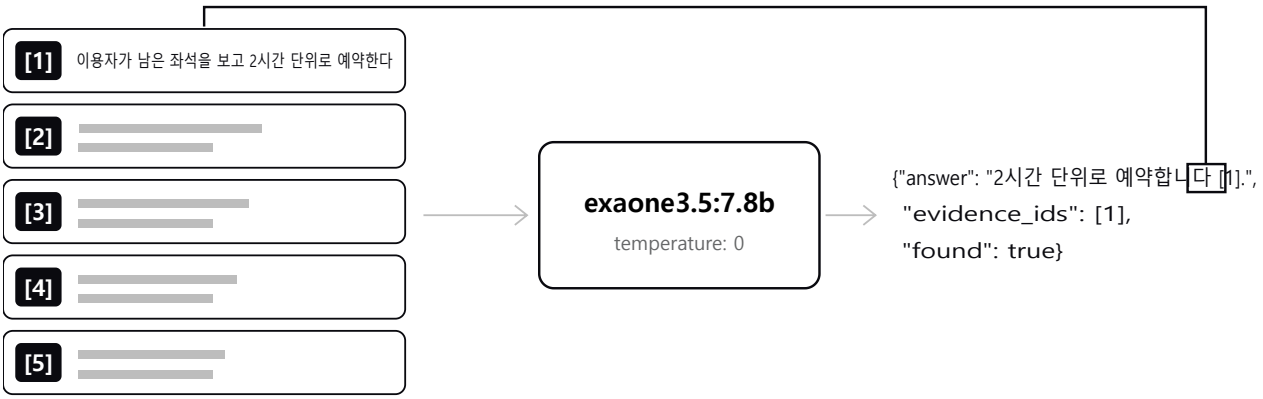
후보 20 비교의 검색 중앙 지연은 off 약 0.04초, on 약 0.15초였다. 이는 전체 응답 시간이 아닌 해당 검색 단계 기록이다. 다른 리랭커나 다른 문서 집합의 잠재적 효과를 배제하지 않는다.

남은 검증

문서 범위와 후보 수를 고정하고, 중요 사실·제외 조건·복수 사업 질문에서 근거 회수와 답변 품질을 함께 측정한다. 변경한 단계 하나의 이득과 비용을 분리해 기록한다.

생성과 검증: 제한된 근거 위에서 답을 조립한다

저장 생성기는 exaone3.5:7.8b다. temperature 0, num_ctx 8192, reasoning false가 설정되어 있다. 시드가 없으므로 temperature 0만으로 모든 환경에서 재현성이 보장되지는 않는다.



위 문장과 근거는 기존 도식의 설명용 가상 예시이며 원본 RFP 인용이 아니다.

출처와 검증의 실제 범위

생성기는 answer, evidence_ids, found를 반환한다. 코드가 JSON·근거 ID를 확인하고 숫자/날짜의 근거 대응을 검사하며 재시도·제거·거절 규칙을 적용한다. 근거 ID가 비었을 때 전체 근거를 붙이는 과거 보완 경로도 있어, 출처 정확성은 별도로 검증해야 한다.

규칙은 수치 오류 일부를 막는 방어 장치다. 의미 왜곡, 제외 조건 반전, 검색 누락, 인용과 개별 주장 사이 완전한 대응을 보장하지 않는다.

DEV 30 / 심판 2판	EXAONE	Qwen
정확성 / 5	3.8333	3.7667
충실도 / 5	4.2333	4.7333
거절률 · 답 없는 7문항	1.0000	0.8571
응답 p95 · 초	9.645	14.027

EXAONE을 유지한 이유는 지연과 거절 동작 등을 함께 고려했기 때문이다. Qwen의 충실도 점수가 더 높다는 반대 증거도 남긴다. 작은 자동 점수 차이를 통계적 우승으로 말하지 않는다. 메모리 부족으로 실행하지 못한 모델은 낮은 품질이 입증된 모델이 아니다.

평가: 무엇을 비교했고, 어디까지 말할 수 있는가

평가 묶음	자료·조건	해석 가능한 범위
과거 검색	DEV 30 · 검색된 문서/청크와 사실 지표	검색 구성의 한정 관찰. 답변 정확도와 다름.
과거 생성	DEV 30 + 보류 10 · 자동 심판	답변 점수·거절·지연 관찰. 보류 2문항 과거 노출.
최근 팀 버전	100문서 재구축 · 6구성 × 공통 8질문 gpt-6-luna/low	38/48 정상 처리. 품질 우승·인과 개선 입증 아님.

최근 팀 버전의 실행 상태

구성	정상 처리 / 시도
기존 main / Dense / Hybrid / 보관 B	각 8 / 8
기초 B / Kiwi B	각 3 / 8
합계	38 / 48 · 나머지 10은 실행 오류

48건은 48개의 독립 질문이 아니라 같은 8문항을 6구성에 반복한 시도다. main은 v005, 나머지는 v004 기록으로 버전 차이도 있다. 공통 생성 모델을 사용했더라도 온도·시드가 충분히 고정되지 않았고 파서·청킹·검색 등 복수 요소가 함께 달라 엄밀한 단일 요인 비교가 아니다.

자동 평가의 한계

심판 2판과 3판은 기준이 다르므로 같은 척도로 합산하지 않는다. 같은 답을 다시 채점해도 판정이 바뀐 기록이 있으며 공식적인 사람 평가 보정이 충분하지 않다. DEV를 반복 보며 선택한 결과는 새 데이터에 그대로 일반화할 수 없다.

공통 조건의 최소 기록

문서·질문 ID와 버전, 정답 기준, 파서·청킹·인덱스 해시, 프롬프트, 모델 및 실제 호출 설정, 온도·가능한 시드, 평가기 버전, 하드웨어·캐시, 실패 처리, 반복 횟수를 고정·기록한다. 답변 내용 평가와 실행 성공률은 별도 표로 보고한다.

> 과거 보류셋 점수 상승 기록도 독립적인 대규모 검증은 아니다. 새로운 보류 질문과 사람 검토가 필요한 이유다.

팀원 코드의 개선 요소: 채택과 보류를 구분

항목	판단	근거·다음 조건
메인 상세 응답 JSON 처리	수정 반영	회귀 8개와 추가 검사 4개 기록. 알고리즘 품질 개선 채택과 구분.
Dense / Hybrid 후보	전체 대체 보류	부분 장점과 사실 누락·다른 사업 혼입 등이 공존. 새 공통 조건 평가 필요.
후보 파서 보완	대체 미채택	제어문자 처리 후 추출 성공 개선은 확인. 메인은 이미 100/100이며 의미 충실도 우위 미입증.
부모 문맥 확장	통합 보류	원본 벡터·docstore 매핑 등 자산이 불완전해 동일 입력 재현이 부족.
확보하지 못한 후보 소스	판단 보류	실행 가능한 고정 원본을 얻기 전 품질 판단 금지.

정상 실행과 정답을 혼동하지 않는다

메인도 최신 공통 질문에서 세부 요구 누락과 제외 대상 혼입이 남았다. 8/8 정상 처리만으로 완성된 답변 또는 정확도를 주장하지 않는다. 팀 후보의 개별 유리한 답변도 전체 모듈 교체의 충분한 증거는 아니다.

채택 기록의 단위

팀원 전체 시스템을 한 번에 순위 매기기보다 파서, 청킹, 임베딩, 검색, 사업 식별, 프롬프트, 출처 검증 단위로 나눈다. 변경 모듈·동일 조건·질문별 차이·지연/비용·실패·채택/보류 이유를 한 항목으로 기록한다.

사람 검토가 필요한 실패 범주

중요 요구 누락, 포함/제외의 반전, 사업 간 혼입, 기간·금액의 불일치, 근거 ID와 주장 불일치를 별도로 확인한다. 총점이 올라도 이런 치명적 오류가 늘면 자동으로 채택하지 않는다.

> 개인 이름·계정·작업 경로·원본 질문 문구는 이 발표 자료에 옮기지 않았다. 판단을 재현할 원본 위치와 해시는 제작 관리 기록에서 따로 보존한다.

신설 기준선과 단계별 개선·교체 계획

역할	기존 선정 구성	신설 실험 기준선
기본	07_verify 유지	Haiku 4.5 + TF-IDF
문서 표현·검색	KURE / Chroma / Top-5	JSON 색인 / Top-3
청킹	1,000/200	800/100
추가 처리	분류·요약·문맥·검증	최소 연결부터 단계적으로 추가

신설 기준선의 별도 옵션은 GPT-5 mini + text-embedding-3-small이다. 모델별 색인을 구분한다. PR #2 병합, 합성 2문서의 Haiku 연결 성공, 오프라인 검사 13개 기록은 확인했지만, 실제 RFP 전체 공통 평가는 아직 끝나지 않았다. OpenAI 첫 임베딩 요청의 401 이후 실제 생성 성공도 미확인이다.

단계적 개선 순서 — 다음 실험 제안

입력 검증 파싱·청킹 → **근거 회수** 임베딩·검색 → **답변 처리** 분류·생성 → **검증 강화** 출처·숫자

각 단계에서는 한 요소만 바꾸고 이전 단계·기존 선정 구성을 같은 평가 틀로 비교한다. 모델 계열 자체가 달라지는 비교는 시스템 비교라고 명명하고, 모듈의 순수 효과와 구분한다.

교체 전에 통과할 조건

조건	판정 원칙
품질	독립 보류 질문에서 사전에 정한 중요 사실·출처·거절 기준 충족
퇴행	치명적 누락·혼입·수치 오류의 악화 없음
실용성	지연·비용·실패율을 함께 보고, 허용 범위 충족
재현	설정·데이터·실행 기록 고정, 반복 및 사람 검토 가능

> 구체 임계값과 반복 횟수는 실험 전에 확정해야 한다. 개선이 검증될 때만 반영하며, 근거가 부족하거나 퇴행이 있으면 기존 선정 구성을 유지한다.

운영 지원과 일반화 한계

LangSmith의 현재 범위

최신 운영 인계 범위는 **646 runs · 451 scores**의 운영 반영과 시간당 수집 첫 성공이다. 본 제작 작업에서는 운영 서버나 모델을 새로 호출하지 않았으며, 이 수치는 제공된 운영 기록의 범위로 인용한다.

상태	내용
운영 인계에서 확인	646 runs·451 scores, 시간당 수집 첫 성공
미검증으로 남김	팀 계정 로그인 후 UI 조회와 CSV 클릭
현재 없음	모델 버전 필터
이 수치가 뜻하지 않는 것	646개 독립 평가 질문, 451개 공통 조건 점수, 모델 품질 우승

run과 score는 관측 기록이다. 서로 다른 데이터·질문·생성 모델·평가기 버전이 섞여 있을 수 있으므로 수집 건수만으로 모델 품질을 결론 내릴 수 없다. 향후 실험 ID와 데이터·구성·모델·평가기 버전을 함께 식별해야 한다.

현재 결과의 적용 범위

선정 이유는 보유 문서와 작은 평가 질문 집합에서 관찰한 결과다. 다른 기관·서식·스캔·표 구조·긴 복합 질문·실시간 갱신·동시 사용 부하까지 검증했다고 말하지 않는다. 100문서 입력 성공과 모든 실제 RFP 질문 평가 완료도 서로 다르다.

우선 남길 검증 항목

1. 원본 대비 표·조건·순서가 보존되는지 표본 대조
2. 독립 보류 질문과 사람 검토 기준 확정
3. 생성기·온도·시드·평가기 조건을 고정한 단계별 비교
4. OpenAI 옵션 실제 연결과 오류 처리 검증
5. 팀 로그인 UI·CSV 및 모델 버전별 관측 범위 확인

> 이 목록은 중간발표의 한계를 숨기지 않기 위한 것이다. 이후 검증 결과에 따라 채택·보류 결정과 발표 수치를 갱신한다.

예상 질문 14개와 답변 위치

질문	짧은 답	근거
왜 RAG인가?	문서 갱신·근거 추적·근거 부족 시 거절을 지원한다. 검색 누락·환각은 남는다.	2·6쪽 / E1
입력은 어떻게 읽는가?	HWP 96개는 OLE 본문, PDF 4개는 텍스트 추출. OCR 없음.	3쪽 / E1·E2
왜 olefile인가?	내부 본문에 직접 접근해 변환 부담을 줄인다. 의미 파싱은 별도 코드이며 충실도 우위는 미검증.	3쪽 / E1·E2
왜 1,000/200인가?	고정 길이는 절 단위보다 유리한 관찰. 이 크기 자체의 최초 근거·최적 탐색은 미확인.	4쪽 / E2
왜 KURE인가?	30문항에서 fact_recall·Hit@5 우세. BGE의 Hit@1 우세도 함께 기록.	4쪽 / E3
검색은 어떻게 하나?	Dense Top-5에 질문 분류·문서 범위를 적용. Chroma의 타 DB 대비 우위는 미검증.	2·5쪽 / E1·E2
리랭커를 왜 껐나?	문서 17·전체 30문항 후속 비교에서 채택 품질 조건 미충족. 다른 조건의 효과는 미확인.	5쪽 / E3
생성 모델은 무슨 역할인가?	근거를 요약·통합해 답/근거 ID 반환. 저장 EXAONE, 최근 비교는 Luna로 구분.	6·7쪽 / E1·E4·E5
출처와 답을 보장하나?	ID·JSON·숫자/날짜 등 일부 검증. 의미·개별 주장 인용의 완전성은 미보장.	6쪽 / E1
무슨 조건으로 평가했나?	과거 30/10, 최근 6×8. 온도·시드·복수 변경 한계. 38/48은 정상 처리 수.	7쪽 / E4·E5
팀 개선은 무엇을 반영했나?	상세 JSON 결함 수정은 반영. 전체 대체·재현 자산 부족·미확보 후보는 보류.	8쪽 / E5
신규 baseline이 메인인가?	아니다. 기존 선정 구성을 유지하며 신규는 단계별 효과를 검증할 기준선.	1·9쪽 / E7
언제 교체하나?	공통 조건 품질·퇴행·실용성·재현 게이트 통과 때. 구체 임계값 사전 확정 필요.	9쪽 / 제안
다른 RFP에도 일반화되나?	소규모 관찰의 범위를 넘는 일반화는 미검증. 새 문서·보류셋·사람 검토가 필요.	7·10쪽 / E2·E4

> 각 답은 확인한 사실·한정 관찰·제안을 구분한다. 질의응답을 돕는 목록이며 모든 추가 질문이나 검증 필요성을 제거했다는 뜻은 아니다.

출처와 제작 원칙

ID · 자료	확인 대상·한계
E1 · 저장 구성과 처리 코드	configs/base.yaml + configs/exp/07_verify.yaml; rfp_rag의 load·chunk·index·retrieve·pipeline·answer 선정 구성·실제 처리 규칙 확인. 저장 설정과 실험 실행 모델은 별개.
E2 · 입력·청킹·검색 기술 기록	기술문서.md, 6·11–14·16·19·24절; retrieval_chunk_*.json 100문서 파싱, 청킹·검색 실험. 원문 시각 충실도 및 크기 최적화 미검증.
E3 · 임베딩·리랭커 원시 집계	retrieval_embedder_{kure,bge-m3}.json; retrieval_rr_{off,on_p20}_{doc,corpus}.json DEV 30문항 및 문서범위 17문항. 검색지표를 답변 정확도로 치환하지 않음.
E4 · 생성·검증 및 보류셋 집계	07_verify.json; 07_verify_qwen.json; 00_baseline.holdout.json; 07_verify.holdout.json 자동 심판 2판. 소표본, 고정 시드 없음, 심판 변동·보류셋 노출 한계.
E5 · 최근 팀 버전 비교·결정	full-native-public-20261012.md; version-decisions.csv 원본 100문서로 6구성 재구축, 공통 DEV 8문항. gpt-6-luna/low 실행. 복수 요소 변경·온도/시드 통제 한계.
E6 · 선정 이유 요약	RAG_선정구성_기술리포트_20261013.pdf, 10쪽 및 대응 본문 검증 근거·선정 이유·실패 사례·남은 검증을 재구성. 독립 실험을 추가한 문서가 아님.
E7 · 신설 기초 파이프라인 기록	신설 모듈러 파이프라인 README·설정·인계; PR #2 병합 기록 Haiku/TF-IDF 기본 및 OpenAI 옵션. 합성 2문서 연결·오프라인 검사 범위. 실제 RFP 공통 평가 미완료.
E8 · LangSmith 최신 운영 인계	2026-10-14 제공 운영 범위; 2026-10-13 운영 보고서의 수집 건수 646 runs·451 scores, 시간당 수집 첫 성공. 본 제작 중 새 운영 접속 검사는 하지 않음.
V1 · Claude 3판, 55장	19·26·30쪽의 SVG 도식 정적 SVG로 추출하고 표시 글꼴을 교체. 청킹·전체 흐름·근거 응답 도식 재사용.
V2 · Claude 5판, 54장	4쪽 전체 구조 장면 기존 HTML 최종 프레임 캡처. 과거 결론·비교 주장은 재사용하지 않음.

출처는 로컬 원본을 대조했다. 이 배포본은 원본 실험 JSON·RFP·개인 작업 기록을 포함하지 않는다. 도식은 기존 Claude 자료에서 추출해 재사용했고, GPT 10쪽 기술 요약의 선정 논리와 원시 집계를 교차 확인했다.

수치는 표에서 소수 3~4자리로 표시했다. 비율을 정확도나 통계적 유의성으로 바꾸지 않았다. 최신 사용자 결정에 따라 기존 선정 구성을 발표 중심으로 정정했다.

START로 돌아가기 · 중간발표 HTML · 중간발표 PDF