팀원 자료를 모듈로 바꾸고 평가한 과정

작성일: 2026-10-14 · 과거 기획, 평가 코드, 결과 파일과 현재 로컬 저장소를 대조한 설명 문서

1. 먼저 설명해야 할 결론

팀원 GitHub에서 받은 자료는 **접수하고 모듈로 변환한 후보**이며, 그 자체로 메인에 채택된 구현은 아니다. 기존 메인과 같은 조건에서 비교하고, 답변의 누락·잘못된 근거·대화 처리·실행 오류를 확인한 뒤 반영 여부를 판단하도록 설계했다. 현재 팀원 구성이 메인을 전부 대체하지 않은 이유는 전체 개선이 입증되지 않았고 일부 후보에서 회귀나 자료 부족이 남았기 때문이다.

다만 "아무것도 반영되지 않았다"는 설명도 정확하지 않다. 비교 중 발견한 메인의 JSON 응답 처리와 항목별 근거 검증 결함은 2026-10-11 로컬 메인 커밋 9f7c5ce에 반영했다. 이것은 팀원 모델의 품질 우승을 인정한 변경이 아니라, 재현 가능한 코드 결함을 고친 변경이다. [E4]

최근 새로 만든 rag-project-part3-2team-modular는 또 다른 목적의 저장소다. 팀원이 공정을 교체하며 검증할 수 있도록 **빈 폴더와 공통 입출력 규약에서 시작한 최소 파이프라인**이다. 이전 평가의 최종 구성을 그대로 이식하지 않았으며, 이전 결과가 새 저장소의 기본 설정으로 이어지지 않은 것은 이 범위 결정에 따른 것이다. [E8]

2. 어떤 자료를 어떻게 받아 비교했나

출발점은 이미 작동하던 메인 07_verify였다. 팀원마다 파서, 청크 크기, 임베딩, 검색 방식, 생성 모델이 달랐다. 노트북을 그대로 실행해 나온 점수만 비교하면 어떤 변경이 영향을 주었는지 구분하기 어려웠다. 그래서 다음 순서를 정했다. [E1, E2]

1. **제출 출처를 고정한다.** GitHub 주소, 제출 버전, 정확한 커밋 SHA, 파일 해시와 기준 메인 커밋을 기록한다. 이후 변경된 HEAD를 같은 제출로 취급하지 않는다.
2. **후보 A를 만든다.** 노트북 셀을 파싱·청킹·검색·생성 모듈에 배치하고 입출력과 경로를 연결한다. 원래 알고리즘과 파라미터를 보존하는 것이 목적이다.
3. **후보 B를 만든다.** A에서 발견한 버그나 제한된 개선을 별도로 적용한다. 팀원 원래 구현과 통합자가 추가한 변경을 구별한다.
4. **M↔A, M↔B, A↔B를 비교한다.** M은 고정한 메인이다. 동일 질문·원본 데이터·평가 코드·생성 조건에서 비교하되, 후보 고유 청크와 색인은 후보 산출물로 기록한다.
5. **실패와 미반영도 남긴다.** 실행되지 않은 결과는 오류 또는 미측정으로 기록한다. 성공이나 품질 0점으로 임의 변환하지 않는다.
6. **승인 후 반영한다.** 결과는 반영·부분 반영·미반영·평가 보류로 나눈다. 자동 채점이나 모듈 접수만으로 메인을 바꾸지 않는다.

예를 들어 김현경 원본 A는 100문서 중 99문서가 파싱됐다. 별도 B에서는 100문서가 읽혔고, A에서 읽힌 99문서는 공백 정리 뒤 동일함을 확인했다. 따라서 B의 성공을 A의 원래 성능으로 소급하지 않았다. 메인 자체 파서는 실패가 없어 이 파서 수정을 메인에 추가하지 않았다. [E5]

2026-10-11 비교에서는 김현경 제출 17614c5..., 김민협 제출 10882e3...를 고정했다. 원본 또는 접근 가능한 제출본을 확보하지 못한 권유진·이원영에 대해서는, 이 문서가 참고한 평가 기록만으로 품질을 판정할 수 없다. 두 사람의 코드가 낮은 점수로 탈락했다고 설명해서는 안 된다. [E4, E5]

3. 평가 지표는 무엇이었나

평가는 "검색이 필요한 근거를 가져왔는가"와 "답변이 그 근거를 정확하게 사용했는가"를 분리했다. 여기에 대화 처리, 실행 실패, 속도와 자원 사용을 함께 보았다. 이 프로젝트의 주 평가는 자체 코드와 Claude 심판을 사용했다. 팀원 제출에 RAGAS가 있다고 해서 메인의 모든 비교가 RAGAS 점수였던 것은 아니다. [E2, E3, E6]

구분	지표·검토 항목	실제 정의 또는 확인 내용	해석할 때 주의할 점
정답 문서 검색	hit@k	검색 결과의 문서 ID를 중복 제거한 뒤 상위 k개 문서에 정답 문서가 하나라도 있으면 성공	여러 정답 문서를 모두 찾았다는 뜻은 아니다. 입력 검색 청크 수와 문서 순위 k를 구별해야 한다.
여러 문서 검색	recall@k	정답 문서 중 상위 k개에 들어온 문서의 비율	비교 질문에서는 hit만으로 놓치는 누락을 드러낸다.
정답의 순위	MRR	첫 정답 문서 순위의 역수를 문항별로 평균한다. 1등이면 1, 2등이면 0.5, 없으면 0	단순 평균 순위와 다르다.
검색 근거의 내용	검색 fact_recall	정답에 필요한 핵심 사실 표현 중 검색 청크 본문에 포함된 비율	공백·쉼표 정규화와 대체 표현을 사용하는 문자열 검사다. 의미를 완전히 이해하는 지표는 아니다.
답변 내용	답변 fact_recall	핵심 사실 표현 중 생성 답변에 포함된 비율	검색 fact_recall과 이름은 같지만 검사 대상이 다르다. 숫자가 있어도 관계가 틀릴 수 있다.
답변의 품질	정확성·의도·근거 충실도	Claude 심판이 5점 척도로 평가한다. 질문에 맞게 답했는지, 필수 내용을 담았는지, 근거에 충실한지 확인한다	채점 프롬프트의 판과 심판 모델이 같아야 직접 비교할 수 있다.
거절	refusal_accuracy	답이 없는 질문에서 올바르게 답을 거절한 비율	답이 있는 질문의 거절을 함께 보아야 한다.
과도한 거절	false_refusal_rate	답이 있는 질문인데 거절한 비율	명확화를 위한 되묻기는 일반 거절과 구별한다.
환각	halluc_answer_rate	주장 단위 채점이 있는 답 중 근거에 없거나 어긋나는 주장이 하나라도 있는 답의 비율	3판 주장 채점이 없는 옛 결과는 이 지표의 분모에서 제외한다.
근거의 일치	근거와 어긋나는 주장 수, wrong_doc_rate	주장과 근거의 관계, 정답 문서와 답이 의존한 문서의 겹침을 확인한다	문서 ID가 맞아도 구체적인 내용은 틀릴 수 있다.

구분	지표·검토 항목	실제 정의 또는 확인 내용	해석할 때 주의할 점
답변의 최소 유용성	fact_answer_rate	답이 있는 질문 중 핵심 사실을 하나라도 담고 실제 답한 문항의 비율	"모든 사실을 정확하게 답한 비율"이 아니다. 거절만으로 안전성 점수를 올리는 것을 막는 지표다.
운영 조건	지연 p50·p95, 메모리, 모델 호출 수·비용, 소스 오류	같은 장비·캐시·실행 조건에서 부담을 기록한다	완료 건수와 정확도는 다르며, 캐시 응답 시간은 신규 생성 시간과 다르다.

초기 평가 질문은 40개였고, 개발 30개와 확인 10개로 나눴다. 개발 30개에는 답이 있는 질문 23개와 답이 없는 질문 7개가 있었다. 한 문서 조회·여러 문서 종합·후속 질문·근거 없는 질문을 포함했다. 이후 168문항 검색 비교와 DEV8 답변 비교는 목적과 조건이 다른 별도 실험이다. 서로 합쳐 하나의 최종 정확도로 만들지 않았다. [E3, E6]

4. 어떤 기준으로 채택·보류했나

4.1 초기 검색 설정을 고르는 기준

검색 사다리 코드의 우선순위는 hit@5 → fact_recall → MRR → recall@5였다. 앞 지표가 같으면 다음 지표를 보고, 끝까지 같으면 먼저 적은 더 단순한 설정을 유지했다. 따라서 "가장 높은 단일 점수를 고른 것"이 아니라, 문서 회수와 핵심 사실 회수를 우선하는 순차 기준이었다. [E7]

재순위를 다시 검토할 때는 별도 기준을 정했다. 문서 안에서의 사실 포함률이 0.02 이상 올라야 하고, 개선 문항 수가 악화 문항 수보다 많아야 하며, 전체 문서 검색의 hit@5가 내려가지 않고 추가 지연이 1초 이하여야 했다. 시험한 조합이 앞의 두 조건을 통과하지 못해 재순위를 꺼 두었다. 이 숫자는 해당 재순위 실험의 기준이며 모든 팀원 후보에 자동 적용한 공통 합격선은 아니다. [E3]

4.2 초기 답변 파이프라인의 목표

Claude 최초 계획은 확인용 10문항에서 최종 설정이 00_baseline보다 평균 0.5점 이상 높고, 같은 근거를 받은 ref_claude와 평균 차이가 0.5점 이내인지 보도록 했다. 기술문서의 2판 정확성 결과는 3.0 → 3.7이었고 Claude 참조는 3.9였다. 이 표에서는 두 조건을 만족한다. [E0, E3]

다만 확인용 10개 중 2개를 개발 중 이미 보았다는 기록이 있다. Claude 참조에도 메인이 찾은 같은 근거를 제공했다. 따라서 이 결과는 작은 표본에서의 생성 능력 비교이며, 독립된 전체 검색 성능이나 완전히 보지 않은 시험의 성능을 보장하지 않는다.

4.3 환각 개선 계획의 기준

후속 환각 개선 계획에서는 개발 30문항으로 다음을 모두 만족하도록 정했다. [E0, E3]

- 환각이 있는 답의 비율이 당시 Claude 참조 0.067 이하일 것.
- 근거와 어긋나는 주장이 0개일 것.
- 답이 없는 질문을 모두 올바르게 거절할 것.
- 답이 있는 질문 중 핵심 사실을 하나라도 담은 답의 비율이 당시 11_base 0.913의 70%, 약 0.639 이상일 것.

마지막 조건은 거절만 해서 나머지를 통과하는 것을 막기 위해 두었다. 70%는 제안을 사용자가 확정한 값으로 기록돼 있다. 이것은 계획상의 목표다. 현재 후보 전체가 이 조건을 충족했다고 검증한 결과로 읽으면 안 된다.

4.4 팀원 모듈의 반영 기준

팀 버전 관리에서는 처음부터 모든 후보를 자동 채택하는 하나의 최소 개선 폭을 정하지 않았다. 기준 실행과 채점 변동을 보고 결정하도록 했고, 같은 평가 조건, 회귀, 실패, 유지보수 부담과 사용자 승인을 요구했다. "+몇 점이면 무조건 합격"이라는 숫자를 사후에 만들어 설명할 근거는 없다. [E1]

5. 실제로 무엇을 보고 보류했나

2026-10-12에는 원본 100문서를 다시 파싱·청킹·색인한 6구성으로 DEV8을 처리했다. **48건 중 정상 답변 38건, 소스 오류 10건**이었다. 이는 처리 결과이지 정확도 79.2%가 아니다. 생성은 공통 gpt-6-luna/low로 통제했으므로 팀원의 원래 EXAONE·KULLM3 생성기를 그대로 재현한 실험도 아니다. [E5]

구성	정상 / 시도	판단에 사용한 구체적인 문제	결정
메인 07_verify	8/8	Q21 세부조건 누락과 Q12 기관 범위 문제가 남았다. 후보 전체의 개선은 확인하지 못했다.	비교 기준 유지
김민협 dense	8/8	후속 Q21에 다른 기관 요구가 섞였고, Q13 기간 및 Q12 탐색 범위가 부족했다.	보류
김민협 hybrid	8/8	일부 수량은 회복했으나 기관 혼입이 남았고 Q13에서 비교 대상 검색이 빠졌다.	보류
김현경 archive	8/8	Q02의 목적·근거는 충실했지만 Q21 상세조건과 Q13 기간이 빠졌다. 원본 A 파싱 실패와 B 수정도 구별했다.	보류
김현경 basic	3/8	5건에서 사업명 인식 오류가 발생했다. 후속 대화 상태와 다중 사업 비교도 부족했다.	보류
김현경 Kiwi	3/8	basic과 같은 5건 오류와 비교 실패가 남았다. Kiwi 변경만의 개선을 입증하지 못했다.	보류

이 판단은 "팀원 방법이 일반적으로 나쁘다"는 뜻이 아니다. 해당 데이터·질문·변환본·생성 조건에서 메인을 교체할 근거가 부족하다는 뜻이다. 메인도 완전하지 않으며, 기준을 유지하는 결정과 최종 품질 우승 판정은 다르다.

다른 실험인 2026-10-09의 168문항 비교에서는 부모·자식 청크와 BGE 재순위의 검색 이점을 살폈다. 그러나 독립 의미 채점과 등록된 전체 파이프라인 확인 시험은 없었다. 12입력 생성 파일럿의 성공 역시 연결 확인이며, 전체 504입력 생성은 첫 입력 전에 보류됐다. 검색 지표가 나아진 후보를 곧바로 서비스의 최종 우승으로 선정하지 않은 이유다. [E6]

6. 왜 지금 반영되지 않은 것처럼 보이나

평가 결과와 실행 설정은 별개다

후보 코드·버전 목록·대시보드에 결과를 등록해도 런타임 기본값은 자동으로 바뀌지 않는다. 공개 실행 저장소의 versions/selection.json은 여전히 pending이며 adopted_new_candidate는 비어 있다. 이 파일의 기준 시점은 2026-10-09이고, 더 뒤의 10-12 평가 경위는 별도 보고서에 남았다. 따라서 선정 파일 하나로 모든 후속 평가가 없었다고 판단해서도 안 된다. [E6, E9]

세 저장소의 목적이 다르다

저장소	역할	이전 평가가 나타나는 방식
rfp-rag-test	기존 구현·평가·팀원 접수 기록의 원본 작업 공간	평가 결과와 후보 이력, 로컬 통합 기록이 있다.
rag-project-part3-2team-main	기존 실행 코드와 공개 가능한 비교·재현 도구	07_verify를 유지하며 후보·집계를 검토 자료로 제공한다. 비공개 원본 전체를 복제한 저장소는 아니다.
rag-project-part3-2team-modular	공통 규약에서 새로 시작한 팀 공동작업용 최소 기준선	과거 우승 구성을 복사하지 않았다. 품질 평가·분류·기억·내용 검증은 아직 구현하지 않았다.

현재 로컬에서 공개 메인 체크아웃은 review/rag-main-versions-dashboard-20261013, HEAD cf4171e이고, 최소 모듈러 체크아웃은 feature/mingilee97/pipeline-basic, HEAD 55773b3이었다. 이 문서는 읽은 로컬 상태와 기록에 근거한다. 최신 원격 브랜치와 현재 운영 서버의 실제 적재 상태는 이번 작업에서 조회하지 않았다.

일부 기능은 이미 메인에 있었다

하이브리드 검색의 순위 결합과 한국어 BM25용 Kiwi는 메인에도 있었다. 같은 기능을 가져온 것을 새 개선으로 계산하지 않았다. parent-child 문맥 확장은 별도 후보 가치가 있지만 부모 매핑·토크나이저 예산·동일 조건 답변 검증이 필요해 전체 통합을 보류했다. [E4]

새 기본값은 품질 우승이 아니라 연결 확인으로 정했다

최소 모듈러 저장소는 Haiku 4.5 + 로컬 TF-IDF의 합성 2문서 실행이 성공한 경로를 기본으로 둔다. GPT-5 mini + text-embedding-3-small은 첫 임베딩 요청의 HTTP 401로 생성까지 확인하지 못해 별도 설정으로 유지했다. 이 결정은 KURE·EXAONE보다 정확도가 높다는 평가 결과가 아니다. [E8]

7. 발표나 설명 문서에서 사용할 문장

"팀원들의 코드는 정확한 GitHub 버전을 고정해 받아 공정별 후보로 변환했다. 원래 동작을 보존하는 후보와 통합 과정에서 수정한 후보를 나누고, 고정된 메인과 같은 조건에서 비교했다. 검색 지표뿐 아니라 답변 누락, 기관 혼입, 기간 해석, 후속 질문과 실행 실패를 확인했다. 일부 후보의 장점은 있었지만 전체 개선과 회귀 해소를 입증하지 못해 메인 구성은 유지했다. 재현 가능한 응답 처리 결함은 별도로 반영했다. 이후 만든 최소 모듈러 저장소는 팀원이 부품을 바꿔 시험하기 위한 새 기준선이므로, 이전 후보를 자동으로 기본값에 이식하지 않았다."

8. 근거와 이번 문서의 범위

이번 작업은 문서 작성과 근거 대조만 수행했다. 새 모델 실행·평가·코드 변경·커밋·push·배포는 수행하지 않았다. Claude 원본 기획 파일은 읽기만 했고 수정하지 않았다. 보류를 해소하려면 후보별로 남은 회귀를 고치고, 같은 평가기·질문·데이터·생성 조건에서 전체 답변을 다시 비교해야 한다. 이 후속 실험을 이미 수행한 것처럼 설명하지 않는다.

ID	읽은 원본	뒷받침하는 내용
E0		최초 설계 방향, 질문 40개, 검색 사다리, 확인 시험과 환각 목표
E1	팀 버전 관리 검토	M/A/B, 승인과 비교 조건, 자동 합격선 부재
E2	평가 지표 코드, 평가 관리 코드	지표 실제 정의와 오류·버전 관리
E3	기술문서	16~22절 평가, 판별 한계, 재순위 기준과 초기 결과
E4	모듈 통합 기록	정적 비교, 기존 기능, 실제 결함 수정과 로컬 통합
E5	전체 native 기술 보고서, 구성별 결정 CSV	6구성 DEV8 48건, 문항별 검토와 보류 사유
E6	공개 비교 근거, 168문항 검색 집계	검색·생성 구분, 전체 선정에 부족한 검증
E7	검색 사다리 코드	TIE 선택 순서, 검색 사실 포함률 계산
E8	최소 모듈러 README, 인수인계	새 기준선의 목적, Haiku 기본값과 OpenAI 미검증
E9	선정 상태, 공개 메인 README	후보 채택과 버전 표시의 분리