RAG 실험, 무엇을 바꾸었고 무엇이 좋아졌나

한국어 제안요청서 질의응답 시스템 · 기술 보고서 개정본 · 2026년 10월 16일

1. 먼저 볼 결과

이번 실험에서 분명하게 좋아진 부분은 **답변에 쓸 근거를 찾는 순위와, 필요한 근거를 빠짐없이 전달하는 범위**다. 리랭커를 바꾼 뒤에는 정답 근거가 상위 5개 안에 들어온 질문이 30개 중 29개에서 30개로 늘었다. 문서를 더 큰 조각으로 나눈 실험에서는 필요한 근거를 모두 전달한 질문이 26개에서 28개로 늘었다.

검색이 좋아졌다고 답변까지 같은 만큼 좋아진 것은 아니다. 리랭커 교체 전후의 답변 평가 점수는 비슷했다. 문서 조각을 키운 실험에서는 답변 작성 지시문도 달라졌으므로, 답변 점수의 변화를 청킹의 효과만으로 설명할 수 없다.

무엇을 바꿨나	무엇이 달라졌나	현재 판단
근거의 순서를 다시 정하는 모델 교체	상위 5개에 정답 근거가 있는 질문 **29 → 30개**	검색 개선. 채택 후보
문서 조각의 크기 확대	근거를 모두 전달한 질문 **26 → 28개**	근거 누락 감소. 문맥 길이도 증가
각 조각에 사업명·기관명 추가	다른 사업의 근거 혼입 **3 → 0개**, 정답 근거 검색 **30 → 28개**	장단점이 엇갈려 해당 조건에서는 미채택

위 비교는 10개 문서·30개 질문을 사용한 실험 기록에 따른다. 이번 개정본은 최초 보고서 작성 때 확인한 시트와 사용자 설명을 다시 정리했다. 수치가 기록된 실험과 결과가 없는 계획을 구분했으며, 새로운 실험을 실행하지는 않았다.

2. 이 시스템은 어떤 순서로 답하는가

제안요청서(RFP)는 사업에 필요한 기능과 수행 조건 등을 적은 문서다. 이 프로젝트의 목표는 문서 내용에 질문하면, 관련 근거를 찾아 답하는 시스템을 만드는 것이다. RAG는 질문에 필요한 자료를 먼저 찾고, 그 자료를 답변 모델에 제공하는 방식이다.

문서 준비: PDF·HWP 읽기 → 표 추출 → 조각 나누기 → 검색용 정보 저장

질문 처리: ① 사업 확인 → ② 근거 검색 → ③ 순서 재정렬 → ④ 답변 작성

사업 식별에 실패하면 전체 문서를 검색하는 경우도 있다.

이 과정에서 서로 다른 세 가지 문제가 생길 수 있다. 엉뚱한 사업의 문서를 고를 수 있고, 맞는 문서에서도 필요한 부분을 놓칠 수 있다. 근거를 제대로 제공했어도 답변 모델이 일부 내용을 빠뜨릴 수 있다. 그래서 이 보고서는 **어느 문서를 찾았는지, 필요한 근거를 모았는지, 답변이 올바른지**를 나누어 설명한다.

보고서를 읽는 데 필요한 용어

용어	이 보고서에서의 뜻
문서 조각, 청크	검색하기 좋게 나눈 문서의 일부. 문단이나 표의 일부가 들어갈 수 있다
청킹	문서를 조각으로 나누는 작업. 700/100에서 앞 숫자는 조각 크기, 뒤 숫자는 이웃 조각과 겹치는 길이를 뜻한다. 기록에는 길이 단위가 없어 글자 수나 토큰 수로 단정하지 않았다
임베딩·Dense 검색	문장의 의미를 숫자로 표현하고, 질문과 의미가 비슷한 문서 조각을 찾는 방식
BM25 검색	질문과 문서에 나타난 단어를 바탕으로 관련 자료를 찾는 방식
Kiwi BM25	한국어 형태소 분석기 Kiwi로 단어를 나눈 뒤 BM25 검색에 사용하는 구성. 시트의 '일반 BM25'는 Kiwi를 사용하지 않은 구성이다
하이브리드 검색	이 실험에서는 Dense 검색과 BM25 검색의 결과를 함께 사용하는 방식
리랭커	검색된 후보를 다시 살펴보고, 질문에 더 맞는 근거가 앞에 오도록 순서를 정하는 모델
문맥	답변 모델에 실제로 전달하는 근거 묶음. 검색한 모든 후보가 최종 문맥에 들어가는 것은 아니다
프롬프트	답변 모델에 주는 지시문. 무엇을 포함하고 어떤 형식으로 답할지 정한다

Kiwi의 역할은 개발자의 공식 저장소를 기준으로 설명했다. 각 실험에서 어떤 단어·품사를 사용했는지는 시트만으로 확인되지 않는다.

숫자는 어떻게 읽으면 되는가

보고서의 표현	원래 지표	읽는 방법
정답 근거가 상위 5개 안에 있는 질문	Hit@5	30개 질문 중 29개면 96.7%. 필요한 근거를 전부 찾았다는 뜻은 아니다
첫 정답 근거가 얼마나 앞에 있는가	MRR	0~1 점수이며 높을수록 좋다. 예를 들어 첫 정답이 1위면 1점, 2위면 0.5점으로 계산해 평균한다. 실제 코드의 계산 범위는 미확인이다
필요한 근거 문장이 얼마나 포함됐는가	근거 문장 재현율	일부 근거만 찾은 경우도 구분한다. 표에서는 읽기 쉽게 백분율로 표시한다
필요한 근거를 전부 전달한 질문	근거 전부 전달	여러 근거가 필요한 질문에서도 빠진 근거가 없는지 본다
평가 AI가 매긴 답변 점수	LLM-as-Judge	평가 AI의 판단값이며, 정답률로 읽지 않는다
기준 답변과 사실이 얼마나 일치하는가	Factual Correctness	RAGAS 평가 점수. 계산 방식 설정이 기록되지 않아 단순 정답률이나 F1로 부르지 않는다

예를 들어 필요한 근거가 세 개일 때 한 개만 상위 5개에 들어와도 Hit@5는 성공으로 처리될 수 있다. 그러나 나머지 두 근거가 빠졌다면 완전한 답변을 만들기는 어렵다. 이 차이가 후반 실험에서 '근거 전부 전달'을 추가로 살핀 이유다. Factual Correctness의 계산 설정은 RAGAS 공식 설명을 참고했다.

3. 초기 실험은 왜 이 순서로 이어졌나

3.1 기본 동작을 만들고, 낮은 답변 품질의 원인을 나눠 봤다

EXP-001 | 기본 동작 구현. 처음에는 PDF 한 개로 문서를 읽고, 근거를 찾고, 답변하는 흐름을 만들었다. KoE5 임베딩, Qwen2.5-3B 답변 모델, 500/100 청킹을 사용했다. 시트에는 BGE 검색기와 BGE 리랭커 비교도 적혀 있다. 이 단계의 성과는 기본 기능의 구현이다. 초기 설정은 임의로 정했으며 성능 수치는 없다.

EXP-002 | 표 처리와 질문 변환 시도. PDF뿐 아니라 HWP도 읽고, 표를 Markdown으로 추출하도록 바꿨다. 표의 행과 열을 텍스트로 표현해 구조를 유지하려는 시도였다. GTE 임베딩, EXAONE AWQ, 700/100 청킹을 사용했다. 동시에 HyDE와 일반 질문을 비교하려 했지만, 답변 품질이 낮고 불필요한 근거가 검색되어 비교를 마치지 못했다.

HyDE는 질문에 대한 가상의 답변 문서를 먼저 만든 뒤, 그 문서와 비슷한 실제 자료를 찾는 방법이다. 일반 질문을 그대로 검색하는 방식과 다른 점은 검색의 출발점이 질문에서 가상 문서로 바뀐다는 것이다. HyDE 원 논문

EXP-003 | 모델을 바꿔 품질 문제를 확인. 답변 모델을 GPT-5 mini로, 임베딩을 시트 표기의 text-3 embedding으로 바꾸자 품질이 크게 좋아졌다고 기록했다. 다만 두 모델을 동시에 바꿨고 수치도 없어 각각의 기여도는 구분할 수 없다. 임베딩의 정확한 모델 ID 역시 미기록이다.

EXP-004 | 이전 모델로 돌아가 검색 구조를 점검. 모델 교체만으로 문제를 해결하면 검색 방식의 효과를 알기 어렵다. 그래서 GTE·EXAONE으로 돌아가, Dense와 BM25에서 각각 8개 후보를 찾은 뒤 리랭커로 상위 4개를 고르는 구성을 시험했다. HyDE도 개선됐지만 일반 질문과 큰 차이가 없었다고 기록해, 이후 일반 질문을 사용하기로 했다. HyDE가 나쁘다는 결론이 아니라 이 조건에서 추가 이점을 확인하지 못했다는 뜻이다.

3.2 답변을 평가하는 절차를 만들었다

EXP-005에서는 AI가 검색 근거와 답변을 평가하는 기능을 넣었다. EXP-006에서는 Qwen2.5-1.5B-Instruct를 사용한 RAGAS 평가 코드를 구현했다. 두 실험의 성과는 **평가 절차를 만든 것**이다. 점수 상승을 확인한 실험은 아니며, 문항별 결과도 기록되지 않았다.

3.3 검색량보다 검색 범위가 문제일 수 있음을 확인했다

EXP-007에서 정제를 적용했지만 품질이 낮아 효과를 판단하기 어려웠다. EXP-008에서는 검색할 조각 수를 늘렸다. 그러나 품질은 나아지지 않았고, 다른 사업의 근거가 섞이는 문제가 나타났다. EXP-009는 이 문제를 해결하기 위해 질문의 사업을 먼저 확인하고, 해당 사업의 문서 안에서 검색하도록 바꿨다.

실험	바꾼 내용	사실 일치 점수	기록에서 읽을 수 있는 결과
EXP-007	정제 적용	미기록	품질이 낮아 비교하지 못함
EXP-008	검색하는 조각 수 확대	0.813	개선 없음. 다른 사업의 근거 혼입 발견
EXP-009	사업별로 검색 범위 제한	0.838	혼입 감소 관찰. 직전 점수보다 0.025 상승
EXP-010	사업별 검색에 정제 재적용	0.909	설명은 '큰 차이 없음'. 점수와 설명의 관계 확인 필요
EXP-011	청킹 700/100 → 1000/200	0.354	설명은 '큰 차이 없음'. 큰 점수 하락과 설명이 맞지 않음

이때 '정제'가 구체적으로 어떤 처리를 뜻하는지는 기록에 없다. 불필요한 문자를 지운 것인지, 근거를 재작성한 것인지 임의로 채워 넣지 않았다. EXP-008의 검색 개수 변경 전후 값도 미기록이다.

이 구간에서 확인한 것은 검색량을 늘리는 것보다 **질문과 관련 있는 사업으로 범위를 좁히는 일이 중요할 수 있다**는 점이다. 다만 EXP-010·011은 설명과 수치가 맞지 않아 정제와 청크 크기의 효과를 확정하지 않았다. 초기 EXP-011과 후반 EXP-028은 모델과 평가 조건이 다르므로, 같은 청크 크기의 반복 검증으로 보지 않는다.

3.4 임베딩 후보를 비교했다

실험	임베딩 모델	사실 일치 점수
EXP-012	BGE-M3	0.783
EXP-013	KURE-v1	0.776
EXP-014	한국어 BGE-M3	**0.895**

세 행은 모두 700/100 청킹과 10개 질문 평가로 기록돼 있다. 한국어 BGE-M3의 점수가 가장 높아 후속 실험의 후보가 됐다. 다만 이것은 답변의 사실 일치 점수다. 검색 모델만의 성능을 직접 측정한 결과는 아니며, 생성 모델과 문항 집합이 완전히 같았는지도 원본 실행 자료로 확인해야 한다.

4. 한국어 키워드 검색을 더하면 좋아지는가

4.1 검색 구성을 여섯 가지로 나눠 비교했다

EXP-015~022에서는 답변 모델을 GPT-5 mini로 유지한 채 키워드 검색과 의미 기반 검색을 어떻게 조합할지 살폈다. 시트는 여덟 개 실험 번호를 A~F 여섯 행으로 묶어 두었으므로, 개별 번호를 임의로 다시 배정하지 않았다.

기록 구분	검색 구성	확인된 결과
EXP-015~022-A	Kiwi BM25만 사용	정답 조각을 높은 순위에 놓았다고 기록. 점수 없음
EXP-015~022-B	일반 BM25만 사용	개별 결과 미기록
EXP-015~022-C	Dense + Kiwi BM25	개별 결과 미기록
EXP-015~022-D	Dense + 일반 BM25	개별 결과 미기록
EXP-015~022-E	Dense + Kiwi BM25 + GTE 리랭커	유력 후보. 300개 질문의 점수 있음
EXP-015~022-F	Dense + 일반 BM25 + GTE 리랭커	점수 원본 미확인

초기 관찰에서는 Kiwi BM25 단독과 Kiwi를 사용한 하이브리드·리랭커 조합이 좋았다. 하지만 여섯 구성의 점수가 모두 있지는 않아 정량 순위를 매길 수 없다.

4.2 300개 질문에서는 정답 문서를 잘 찾았다

평가 항목	EXP-015~022-E의 기록값
데이터 규모	문서 100개·질문 300개
상위 5개 안에서 정답 문서를 찾은 비율	**99.33%** — 질문 300개를 분모로 환산하면 298개
첫 정답의 검색 순위 점수, MRR	0.9670
평가 AI의 답변 점수, Judge	0.7699
기준 답변과의 사실 일치 점수	0.5991

이 결과는 **답이 있는 문서를 잘 찾았다**는 의미다. 필요한 근거를 모두 찾았다거나 답변 정확도가 99.33%라는 뜻은 아니다. 시트가 해당 값을 문서 기준으로 정정했기 때문에, 아래의 30개 질문·청크 검색 결과와 같은 그래프에 넣지 않았다.

4.3 30개 질문에서는 검색 구성을 바꿔도 순위 점수가 비슷했다

이후에는 문서 10개·질문 30개로 비교했다. 기준 구성인 EXP-023은 한국어 BGE-M3, Dense + Kiwi BM25, GTE 리랭커, 700/100 청킹이다. 답변에는 Claude Haiku 4.5, 평가에는 Gemini를 사용했다. EXP-024는 Kiwi를 일반 BM25로 바꿨고, EXP-032는 BM25를 빼고 Dense만 사용했다.

검색 구성	상위 5개에 정답이 있는 질문	첫 정답 순위 점수, MRR
기준: Dense + Kiwi BM25 · EXP-023	29/30	0.8137
Dense + 일반 BM25 · EXP-024	29/30	0.8139
Dense만 사용 · EXP-032	29/30	0.8141

검색 지표는 거의 같지만, 답변 점수는 다음처럼 달랐다.

검색 구성	평가 AI 점수, Judge	사실 일치 점수
기준: Dense + Kiwi BM25 · EXP-023	0.9383	0.4807
Dense + 일반 BM25 · EXP-024	0.9167	0.3460
Dense만 사용 · EXP-032	0.9433	0.4727

일반 BM25를 쓴 구성은 답변 점수가 낮게 기록됐다. 다만 EXP-024는 청킹과 임베딩 칸이 비어 있어, 모든 조건을 같게 유지했는지는 확인이 필요하다. Dense 단독은 기준과 비슷한 결과를 보였다. 따라서 **이 작은 평가 집합에서 Kiwi 하이브리드가 Dense 단독보다 일관되게 좋았다고 말하기는 어렵다.**

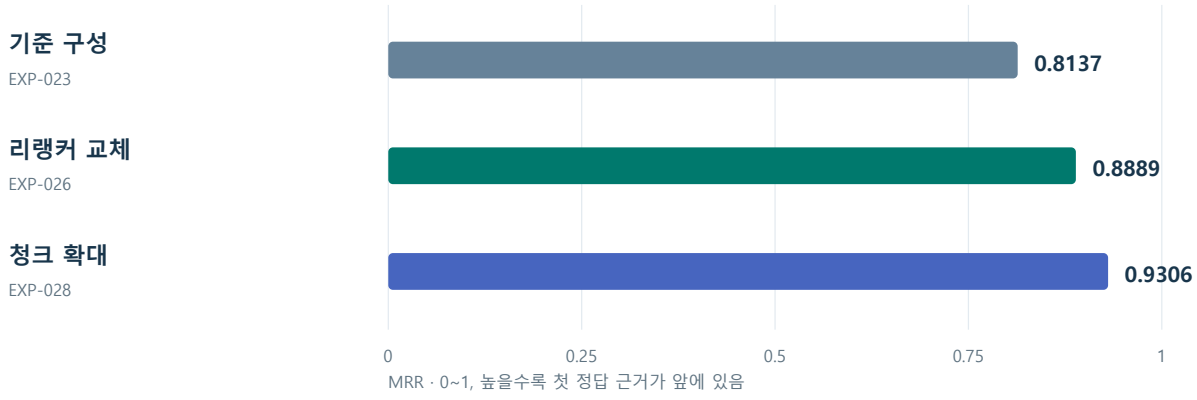
또한 EXP-023은 점수와 '완료' 상태가 있지만 설명에는 '아직 미실행'이 남아 있다. 후속 실험들이 기준으로 인용하므로 점수는 비교에 사용하되, 이 상태 충돌은 부록에 표시했다.

5. 무엇을 바꿨을 때 근거 검색이 개선됐나

5.1 리랭커 교체: 정답 근거가 더 앞에 놓였다

EXP-026에서는 기준 구성의 GTE 리랭커를 BGE 리랭커로 바꿨다. 목적은 이미 검색한 후보 중 답변에 맞는 근거를 더 앞에 놓는 것이었다. 그 결과 상위 5개에 정답 근거가 들어온 질문이 29개에서 30개로 늘었고, MRR은 0.8137에서 0.8889로 상승했다.

그림 1. 리랭커와 청크 크기를 바꾼 뒤 정답 근거의 순위가 올랐다



기준 구성 → BGE 리랭커 → BGE 리랭커·1000/200 청킹. 가로축은 0부터 시작한다. 출처: Sheet1 22·25·27행.

그림 1은 리랭커 교체와 후속 청크 확대를 **검색 순위 지표로만** 비교한다. EXP-028에서는 답변 지시문도 바뀌었지만, 그 변화가 섞일 수 있는 답변 점수는 이 그래프에 넣지 않았다. 비교 조건은 시트 기록에 따른 것이며 원본 코드의 동일 조건을 재검증한 것은 아니다.

답변 평가 항목	교체 전 · EXP-023	교체 후 · EXP-026
평가 AI 점수, Judge	0.9383	0.9367
사실 일치 점수	0.4807	0.4860

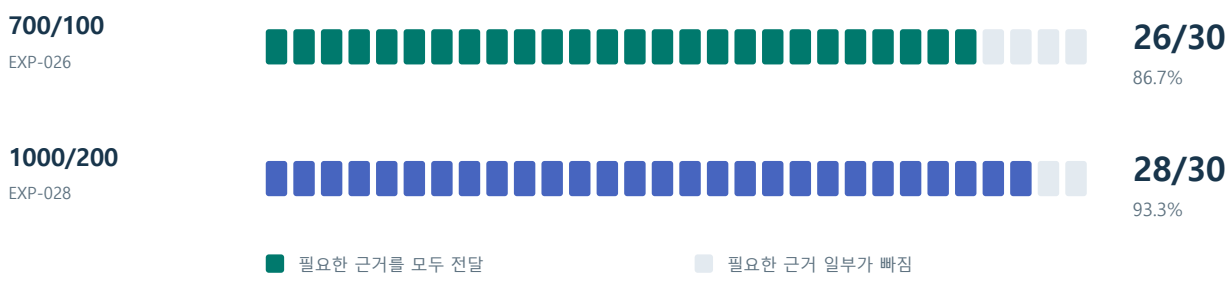
답변 점수는 거의 같았다. 따라서 이 실험의 성과는 **검색 순위 개선**으로 정리한다. 시트에는 사실 일치 지표를 점검 중이며 재채점했다는 기록도 있어, 답변 품질의 개선은 확정하지 않았다.

5.2 청크 확대: 필요한 근거가 빠지는 질문이 줄었다

EXP-026은 모든 질문에서 정답 근거를 하나 이상 찾았지만, 네 질문은 필요한 근거의 일부를 놓쳤다. 근거가 여러 개 필요한 질문에서는 정답 조각 하나만 찾는 것으로 충분하지 않았던 것이다.

EXP-028은 이 문제를 줄이려고 청킹을 700/100에서 1000/200으로 바꿨다. 한 조각에 더 넓은 문맥이 들어가면 함께 필요한 근거도 한꺼번에 전달할 수 있을 것으로 봤다. BGE 리랭커는 유지했고, 답변 단계에서는 새 프롬프트 v2를 사용했다.

그림 2. 필요한 근거를 모두 전달한 질문이 두 개 늘었다



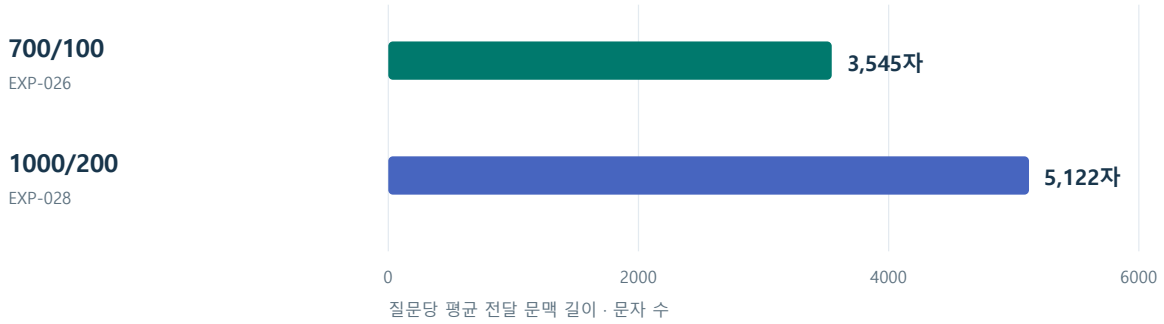
각 칸은 질문 1개를 뜻한다. 칸의 순서는 실제 질문 ID와 무관하다. 출처: EXP-026·028의 근거 전달 분석.

근거 전달 지표	700/100 · EXP-026	1000/200 · EXP-028
필요한 근거를 전부 전달한 질문	26/30, 86.7%	**28/30, 93.3%**
상위 5개 결과의 근거 문장 재현율	92.00%	**96.67%**
답변 모델에 전달한 근거 문장 재현율	93.67%	**96.67%**
첫 정답 순위 점수, MRR	0.8889	**0.9306**

큰 조각을 검색하면 정답 내용이 조각 안에 포함되기 쉬워질 수 있다. 그래서 순위 점수와 함께 실제 근거 문장과 전체 근거의 전달 여부도 확인했다. 이 지표들도 좋아졌다는 점에서 EXP-028은 단순한 Hit@5 상승보다 구체적인 개선 근거를 남겼다.

5.3 근거를 더 많이 전달하는 데는 입력 길이 증가가 따랐다

그림 3. 근거를 더 담으면서 질문당 문맥 길이는 약 44.5% 늘었다



3,545자 → 5,122자. 문자 수를 비교했으며 실제 토큰·비용·지연 증가율은 아니다. 출처: EXP-028의 EXP-026 대비 분석.

질문당 전달 문맥은 평균 3,545자에서 5,122자로 늘었다. **약 44.5% 더 긴 근거를 읽히고, 근거 누락 질문을 두 개 줄인 셈**이다. 기록으로 확인한 것은 문자 수다. 실제 토큰 사용량, 비용, 응답 시간의 증가율은 측정되지 않았다.

답변 AI의 평가 점수는 EXP-028에서 0.9467로 기록됐지만, EXP-026과는 프롬프트가 다르다. 따라서 이 상승을 청크 크기의 효과로만 설명할 수 없다. RAGAS도 생략했으므로 사실 일치 점수가 개선됐는지는 아직 모른다.

5.4 아직 남은 문제: 여러 섹션에 흩어진 근거

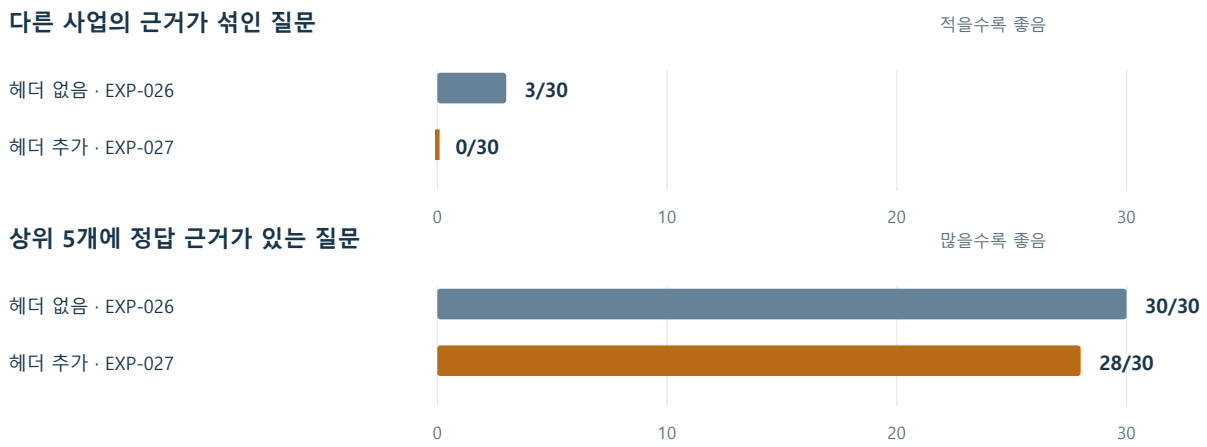
한 부분에서 답을 찾는 direct_fact 유형의 근거 누락은 해결됐다고 기록했다. 그러나 여러 섹션을 함께 읽어야 하는 multi_section 유형의 재현율은 0.90으로 같았다. DOC001-Q03은 필요한 근거 세 개 중 두 개, DOC010-Q03은 세 개 중 한 개만 전달했다.

즉 조각을 키우는 것으로 가까이 있는 근거는 함께 담을 수 있었지만, 떨어진 위치의 근거를 모으는 문제는 남았다. 이 결과가 요구사항 단위 청킹과 질문을 나눠 검색하는 후속 검토로 이어진다. 질문 분해 검색은 제안 단계이며 완료된 실험이 아니다.

6. 혼입을 없앴는데 왜 채택하지 않았나

EXP-027은 EXP-026의 각 청크 앞에 사업명과 발주기관을 붙였다. 질문에서 사업을 확실히 찾지 못해 전체 문서를 검색하더라도, 올바른 사업의 청크를 찾는 데 도움이 되기를 기대했다. 이 실험은 EXP-028과 별도의 시도이며, EXP-028이 헤더를 이어받았다고 해석하지 않는다.

그림 4. 헤더는 혼입을 줄였지만 정답 근거를 놓치는 질문도 만들었다



두 그래프의 분모는 모두 질문 30개다. 위 지표는 낮을수록, 아래 지표는 높을수록 좋다. 출처: EXP-026·027.

다른 사업의 근거가 섞인 질문은 3개에서 0개로 줄었다. 그러나 정답 근거를 상위 5개에서 찾은 질문도 30개에서 28개로 줄었다. 맞는 문서의 자료만 가져와도, 그 안에서 엉뚱한 부분을 고르면 답변에 필요한 근거는 빠질 수 있다.

추가 확인 항목	헤더 없음 · EXP-026	헤더 추가 · EXP-027
상위 5개 결과의 근거 문장 재현율	92.00%	87.17%
답변 모델에 전달한 근거 문장 재현율	93.67%	91.33%
근거를 전부 전달한 질문	26/30	26/30
질문에서 사업을 식별하지 못한 경우	28/30	28/30

사업을 식별하는 문제는 그대로였고, 필요한 근거를 고르는 성능은 낮아졌다. 그래서 10개 문서 조건에서는 채택하지 않았다. 모든 조각에 같은 사업명이 붙어 서로 구별하기 어려워졌다는 설명은 기록자의 추정이다. 원인이 직접 검증된 것은 아니다.

이 결과의 의미는 '헤더가 쓸모없다'가 아니다. **다른 사업의 자료를 섞지 않는 것과, 필요한 근거를 정확히 고르는 것을 함께 평가해야 한다**는 것이다. 문서 수가 많아져 혼입 문제가 커지는 조건에서는 다시 살펴볼 수 있다.

7. 현재 결론과 다음 확인 사항

현재까지 확인한 성과

개선한 부분	확인한 변화	적용 판단
문서 처리	PDF 한 개에서 HWP·표 처리로 확장	기능 구현. 추출 정확도 상승률은 미측정
평가 방법	정성 관찰에서 순위·답변·근거 전달 평가로 확대	실패 원인을 더 구체적으로 설명할 수 있게 됨
근거 순위	BGE 리랭커로 Hit@5 29/30 → 30/30	검색 개선 후보
근거 누락	청킹 확대 후 전체 근거 전달 26/30 → 28/30	문맥 길이 증가를 고려할 채택 후보
혼입 방지	헤더로 타 사업 근거 혼입 3/30 → 0/30	근거 검색 손실 때문에 해당 조건에서 미채택

현재 기록에서 우선 검토할 수 있는 구성은 한국어 BGE-M3 임베딩, Dense + Kiwi BM25, BGE 리랭커, 1000/200 청킹이다. 근거 전달 결과가 좋은 **후보 구성**이며, 최종 운영 채택을 확인한 것은 아니다. Dense 단독과 비슷했던 작은 평가 집합의 결과도 함께 고려해야 한다.

프롬프트의 효과는 아직 확정하지 않았다

EXP-025에는 프롬프트 개선 후 사실 일치 점수가 0.4807에서 0.5417로 높아진 값이 적혀 있다. 하지만 상태는 '계획', 설명은 '아직 미실행'이다. 따라서 완료 성과로 포함하지 않았다. EXP-034는 새 프롬프트와 새 리랭커를 결합하는 진행 중 실험이며 점수가 없다.

EXP-028의 답변 품질을 판단하려면 새 프롬프트와 BGE 리랭커를 동일하게 유지한 700/100 결과가 필요하다. 그래야 프롬프트의 영향과 청킹의 영향을 나눠 비교할 수 있다.

다음 실험이 해결하려는 문제

실험	하려는 일	확인하려는 문제
EXP-029 · 계획	요구사항 표 하나를 한 조각으로 유지	요구사항이 조각 경계에서 잘려 빠지는가
EXP-030 · 계획	임베딩만 OpenAI 모델로 교체	답변 모델을 바꾸지 않아도 검색이 나아지는가
EXP-031 · 계획	사업별 요약 정보에 점수를 매겨 검색 범위 선택	정식 사업명이 없는 질문에서도 사업을 찾을 수 있는가
EXP-033 · 계획	작은 조각으로 찾고, 더 큰 상위 문맥을 전달	검색의 세밀함과 답변의 문맥을 함께 확보할 수 있는가
EXP-034 · 진행 중	새 프롬프트와 새 리랭커 조합	찾은 근거를 답변에 빠짐없이 반영하는가

후속 비교에서는 질문과 문서 버전을 고정하고 한 번에 한 요소만 바꿔야 한다. 특히 EXP-029는 기준 실험의 BGE 리랭커와 달리 계획 칸에는 GTE 리랭커가 적혀 있어 먼저 통일해야 한다. 그래야 청킹의 효과만 비교할 수 있다.

이 보고서가 뒷받침하는 결론은 검색 순위와 근거 전달이 개선됐다는 것이다. 답변의 사실적 정확성까지 개선됐는지는 같은 프롬프트와 평가 설정에서 추가로 확인해야 한다. 남은 핵심 문제는 질문의 사업을 찾는 일과, 여러 섹션에 흩어진 근거를 한 답변에 모으는 일이다.

부록 1. 실험 조건과 모델 이름

본문은 이해를 돕기 위해 짧은 모델 이름을 썼다. 정확한 식별자와 비교 범위는 아래와 같다.

본문의 이름	시트의 모델 식별자
BGE-M3	BAAI/bge-m3
KURE-v1	nlpai-lab/KURE-v1
한국어 BGE-M3	dragonkue/BGE-m3-ko
GTE 리랭커	Alibaba-NLP/gte-multilingual-reranker-base
BGE 리랭커	BAAI/bge-reranker-v2-m3
Claude Haiku 4.5	기준행의 claude-haiku-4-5-20251001. 일부 후속행은 제품 이름만 기재
Gemini 평가 모델	gemini-3.1-flash-lite
후속 OpenAI 임베딩 후보	text-embedding-3-small

300개 질문 집단은 100개 문서와 GPT-5 mini 생성·평가를 사용한 기록이다. 30개 질문 집단은 10개 문서와 Claude·Gemini를 사용한 기록이다. 정답 판정도 문서 단위와 청크 단위가 달라 두 집단의 점수를 직접 연결하지 않았다. 초기 10개 질문 집단은 생성 모델 등 일부 설정이 미기록이다.

부록 2. 확인이 필요한 기록

위치	기록의 문제	보고서에서 처리한 방법
EXP-010·011	'큰 차이 없음'과 사실 일치 점수 0.909 → 0.354가 맞지 않음	수치와 관찰을 함께 보존. 청크 크기 효과는 판단 보류
EXP-012·013	'개별 점수 미기록'이라는 설명과 점수 칸이 함께 있음	점수 칸 인용. 문항별 원본은 미확인
EXP-015~022	여덟 번호가 A~F 여섯 행으로 묶임	개별 실행 번호를 임의로 채우지 않음
EXP-015~022-E·F	옛 열 문자와 수정된 열 문자가 섞임	실제 열 제목을 기준으로 점수 대응
EXP-023	완료·점수와 '아직 미실행'이 공존	후속 비교의 기준값으로 인용하고 상태 충돌 표시
EXP-024	청킹·임베딩 칸이 공란	기준 설정을 그대로 썼다고 단정하지 않음
EXP-025	계획·미실행과 점수가 공존	잠정 기재값으로만 인용. 개선 성과에서는 제외
EXP-023 이후	열 제목은 문서 Hit@5, 행 설명은 청크 기준	300개 질문의 문서 지표와 구분. 계산 코드 확인은 필요
EXP-028	입력 토큰 약 1.4배라는 설명, 실제 기록은 문맥 문자 수	문자 수 44.5% 증가로 표현. 비용 증가율은 미측정
EXP-029	비교 기준은 BGE, 계획 칸은 GTE 리랭커	한 요소 비교 전에 설정 통일 권고

사용자 설명의 '23번 청킹 비교는 미실행'은 과거 계획에 관한 설명이다. 시트의 현재 EXP-023은 후속 실험의 기준행으로 쓰인다. 요구사항 단위 청킹은 EXP-029, 작은 조각·상위 문맥 결합은 EXP-033에 따로 기재돼 있어 이를 구분했다.

부록 3. 수치 원문과 출처

본문의 점수는 주로 소수 넷째 자리, 질문 비율은 소수 첫째 자리로 반올림했다. 아래에는 시트 행 번호와 상세값을 남겼다. '미기록'과 '평가 생략'은 0점이 아니다. EXP-023은 시트의 '반올림값 / 상세값' 중 뒤의 상세값을 썼다.

초기 10개 질문의 사실 일치 점수

실험	시트 행	사실 일치 점수
EXP-008	9	0.813000
EXP-009	10	0.838000
EXP-010	11	0.909000
EXP-011	12	0.354000
EXP-012	13	0.783000
EXP-013	14	0.776000
EXP-014	15	0.895000

검색 지표 상세값

실험 · 시트 행	Hit@5	MRR
EXP-015~022-E · 20행	0.993333	0.967000
EXP-023 · 22행	0.966667	0.813675
EXP-024 · 23행	0.966667	0.813889
EXP-025 · 24행	0.966667	0.813675
EXP-026 · 25행	1.000000	0.888889
EXP-027 · 26행	0.933333	0.886667
EXP-028 · 27행	1.000000	0.930556
EXP-032 · 31행	0.966667	0.814141

답변 평가 상세값

실험	Judge	사실 일치 점수
EXP-015~022-E	0.769900	0.599100
EXP-023	0.938333	0.480667
EXP-024	0.916667	0.346000
EXP-025	0.940000	0.541667
EXP-026	0.936667	0.486000
EXP-027	0.936667	평가 생략
EXP-028	0.946667	평가 생략
EXP-032	0.943333	0.472667

주자료: 중급 프로젝트 실험 기록표 · Sheet1. 최초 보고서 작성 시 2026년 10월 16일에 확인한 32개 실험 행을 기준으로 개정했다.

보충자료: 사용자가 제공한 초기 실험 설명. 개정 작업에서는 새 실험 결과를 추가하지 않았다.

용어 설명: HyDE 논문, Kiwi 공식 저장소, RAGAS 공식 문서.

보존 자료: 상위 폴더의 원본시트_스냅샷.json과 실험기록_스냅샷.csv. 개정본의 그래프는 같은 기록에서 만들었다.

확인 범위: 원본 기록과 수치 대응, 주요 계산, 문서 표현과 구조, 그래프·표 표시. 원본 실험 코드 실행, 문항별 CSV 재계산, 통계 검정은 수행하지 않았다.

이 개정본은 설명 순서·한국어 표현·그래프·표를 다시 구성한 문서다. 최초 보고서는 상위 폴더에 보존했다.