RAG 실험 결과 분석

한국어 제안요청서 기반 질의응답 시스템 · 상세 기술보고서 · 2026년 10월 16일

1. 핵심 결과

후반부 30문항 실험에서는 리랭커 교체와 청크 크기 확대에 따라 검색 성능이 개선되었다. 다만 개선된 항목은 서로 다르다. 리랭커 교체는 정답 청크의 순위를 높였고, 청크 확대는 생성 모델의 입력에 포함되는 정답 근거의 범위를 넓혔다.

표 1. 주요 변경 실험의 결과와 적용 판단

변경 조건	핵심 결과	해석
리랭커 교체: EXP-023 → 026	Hit@5 0.9667 → 1.0000; MRR 0.8137 → 0.8889	검색 순위 개선. 생성 응답 평가값은 유사
청크 확대: EXP-026 → 028	전체 정답 근거 포함 문항 26/30 → 28/30	근거 누락 감소. 입력 문맥 길이는 약 44.5% 증가
헤더 추가: EXP-026 → 027	타 사업 문서 포함 문항 3/30 → 0/30; Hit@5 1.0000 → 0.9333	문서 혼입은 감소했으나 정답 청크 검색 성능 하락

현재 기록은 검색 순위와 정답 근거 포함 범위의 개선을 뒷받침한다. 그러나 생성 프롬프트가 함께 변경되었거나 평가 설정이 미기록인 경우가 있어, 생성 응답의 사실적 정확성 향상은 별도로 검증해야 한다.

2. 실험 목적과 분석 범위

제안요청서에는 사업별 기능 요구사항과 수행 조건이 포함된다. 이러한 문서를 대상으로 하는 질의응답 시스템은 질의와 관련된 문서를 선택하고, 문서 내에서 응답에 필요한 근거를 검색해야 한다. 검색 증강 생성(Retrieval-Augmented Generation, RAG)은 외부 문서를 검색한 뒤 그 결과를 생성 모델의 입력에 포함하는 방식이다. 국내 RAG 연구에서도 문서 전처리, 청크 구성 및 검색 방식이 주요 설계 요소로 다루어지며, 검색 성능과 생성 응답의 품질을 구분하여 평가한다[3,4].

분석 대상 시스템은 PDF 한 개를 이용한 기본 구현에서 시작하여 HWP 및 표 처리, 하이브리드 검색, 자동 평가, 사업별 검색 범위 제한으로 확장되었다. 이후 임베딩 모델과 검색 구성을 비교하고, 정답 근거의 누락을 분석하기 위해 리랭커와 청크 크기를 변경하였다. 본 보고서의 목적은 이 과정에서 수행된 실험의 조건과 결과를 정리하고, 개선이 확인된 항목과 판단이 유보되는 항목을 구분하는 데 있다.

분석에는 실험 기록표의 2026년 10월 16일 최초 조회본과 사용자가 제공한 초기 실험 설명을 사용하였다[1,2]. EXP-015~022가 여섯 개 구성으로 묶여 있어 실제 분석 단위는 32개 기록 행이다. 본 보고서 작성 과정에서는 실험을 새로 수행하지 않았다. 따라서 제시된 결과는 기록된 측정값의 분석이며, 원본 실행 코드와 문항별 결과 파일을 이용한 재현 실험 결과는 아니다.

3. 실험 구성과 평가 방법

3.1 시스템 구성

문서 처리 단계는 PDF·HWP 로드, 표의 Markdown 변환, 청크 분할 및 임베딩 생성으로 구성된다. 질의 처리 단계에서는 사업을 식별하여 검색 범위를 정하고, 밀집 검색(Dense Retrieval)과 BM25 기반 희소 검색을 수행한다. 검색된 후보는 리랭커를 통해 재순위화되며, 선택된 청크가 생성 모델에 입력된다. 사업 식별에 실패한 질의는 전체 문서를 대상으로 검색하는 경우가 있었다.

밀집 검색은 임베딩으로 표현한 질의와 청크 사이의 의미적 유사도를 이용한다. BM25는 단어의 출현 정보를 이용하는 검색 방식이며, 본 기록에서는 한국어 형태소 분석기 Kiwi를 적용한 구성과 적용하지 않은 구성을 구분하였다. 리랭커는 검색된 후보와 질의의 관련성을 다시 평가하여 순서를 조정하는 모델이다.

청킹 설정은 기록표의 표기인 '청크 크기/중첩 길이'를 따른다. 예를 들어 700/100은 청크 크기 700과 중첩 길이 100을 의미한다. 다만 원본 기록에는 길이의 단위가 명시되지 않아 문자 수 또는 토큰 수로 확정하지 않았다. 후반부 실험에서 사용한 PDF·HWP 처리 도구는 pymupdf4llm과 HwpHwpxLoader로 기록되어 있다.

3.2 평가 데이터와 비교 범위

평가 집단의 구성은 표 2와 같다. 초기 10문항, 300문항 및 후반부 30문항의 결과는 데이터 규모와 평가 조건이 다르므로 별도로 분석하였다. 특히 300문항 실험은 문서 단위의 정답 검색 여부를 평가한 것으로 정정되어 있으며, 후반부 실험은 청크 단위의 검색 평가로 설명되어 있다. 두 결과를 동일한 성능 추이로 연결하지 않았다.

표 2. 평가 집단별 데이터 구성 및 평가 조건

구분	분석 대상	데이터 및 평가 조건
초기 구현	EXP-001~007	문서 수와 문항 수 일부 미기록. 기능 구현 및 정성적 관찰 중심
초기 정량 평가	EXP-008~014	10문항. RAGAS·GPT-5 mini 평가로 기재. 생성 모델 등 일부 설정 미기록
검색 구성 비교	EXP-015~022-A~F	여섯 구성 비교. E는 문서 100개·문항 300개, GPT-5 mini 생성·평가
후반부 정량 평가	EXP-023~034	주로 문서 10개·문항 30개. Claude Haiku 4.5 생성, Gemini 평가

3.3 평가 지표

실험 기록표에는 검색 성능 지표로 Hit@5와 평균 역순위(Mean Reciprocal Rank, MRR)가 제시되어 있다. Hit@5는 상위 5개 검색 결과에 정답 청크가 포함된 문항의 비율이며, MRR은 첫 정답 청크의 순위 역수를 문항별로 평균한 값이다. 문서 단위로 평가한 실험에서는 정답 청크 대신 정답 문서를 기준으로 해석하였다. 원본 구현의 순위 절단 범위와 실패 처리 방식은 확인되지 않았다.

검색 결과에 정답 청크가 하나 포함되더라도 응답에 필요한 근거가 모두 확보되는 것은 아니다. 이에 후반부 실험에서는 근거 문장 재현율과 모든 정답 근거를 포함한 문항 수를 추가로 분석하였다. 후자의 비율은 해당 문항 수를 전체 평가 문항 수로 나눈 보조 지표로 사용하였다. 주요 지표의 의미는 표 3에 정리하였다.

표 3. 검색 및 생성 응답의 평가 지표

평가 대상	지표	본 보고서의 해석
검색 결과	Hit@5	상위 5개 결과에 정답 대상이 포함된 문항의 비율
검색 순위	MRR	첫 정답 대상의 순위 역수 평균. 값이 높을수록 정답이 앞에 위치
근거 포함 범위	근거 문장 재현율	정답 근거 문장이 검색 결과 또는 생성 모델 입력 문맥에 포함된 정도
근거 포함 범위	모든 정답 근거를 포함한 문항 수	문항별로 요구되는 근거가 모두 포함된 문항의 수. 비율의 분모는 30
생성 응답	LLM-as-Judge	평가 언어 모델이 부여한 응답 평가 점수
생성 응답	Factual Correctness	생성 응답과 기준 응답의 사실적 정확성을 비교하는 RAGAS 점수

Factual Correctness는 설정에 따라 정밀도, 재현율 또는 F1으로 계산할 수 있다[6]. 본 실험의 세부 설정이 기록되지 않았으므로 이를 일반적인 정답률이나 특정 계산 방식의 F1로 단정하지 않았다. 또한 LLM-as-Judge와 Factual Correctness는 서로 다른 평가값으로 구분하였다. 본문은 점수를 소수 넷째 자리까지 표시하되, 필요한 경우 원래 기록값을 병기하였다.

4. 시스템 구축과 검색 구조 개선

4.1 기본 시스템 구축과 검색 구조 변경

기본 RAG 구현 · EXP-001 PDF 한 개를 대상으로 기본 RAG 시스템을 구현한 실험이다. KoE5 임베딩, Qwen2.5-3B 생성 모델 및 500/100 청킹을 사용하였다. 기록표의 검색 항목에는 BGE 리트리버가, 재순위화 항목에는 BAAI/bge-reranker-v2-m3의 적용 전후 비교가 기재되어 있다. 초기 설정은 임의로 결정되었으며 정량 평가값은 기록되지 않았다.

문서 처리 확대와 HyDE 비교 · EXP-002 PDF와 HWP의 표를 Markdown으로 추출하도록 처리 범위를 확장하고, HyDE와 일반 질의를 비교하였다. HyDE는 질의에 대응하는 가상 문서를 생성한 뒤 이를 검색에 활용하는 방식이다. GTE 임베딩, EXAONE AWQ 및 700/100 청킹을 사용하였으나, 생성 품질 저하와 불필요한 청크 검색으로 질의 변환의 효과를 평가하지 못하였다.

생성·임베딩 모델 교체 · EXP-003 생성 모델을 GPT-5 mini로, 임베딩을 기록표의 text-3 embedding으로 변경하였다. 전체 품질이 향상되었다는 정성적 관찰이 있으나, 두 모델이 동시에 변경되어 각각의 기여도를 분리할 수 없다. 임베딩의 정확한 모델 식별자도 기록되지 않았다.

하이브리드 검색 적용 · EXP-004 GTE·EXAONE 구성으로 복귀하여 검색 구조의 영향을 검토한 실험이다. Dense 검색과 BM25 검색에서 각각 후보 8개를 확보한 뒤, 재순위화를 거쳐 상위 4개를 선택하였다. HyDE의 검색 결과는 개선되었으나 일반 질의와의 차이가 크지 않은 것으로 기록되었다. 이에 후속 실험에서는 일반 질의를 사용하기로 하였다. 이 결과는 해당 조건에서 HyDE의 추가 효과를 확인하지 못한 것으로 해석하였다.

4.2 자동 평가 및 검색 범위 제한

평가 절차 도입 · EXP-005~006 EXP-005에서는 AI 기반의 검색 근거·응답 평가 기능을 구현하였다. EXP-006에서는 Qwen2.5-1.5B-Instruct를 사용한 RAGAS 평가 코드를 구현하였다. 두 실험은 평가 절차를 도입한 단계이며, 성능 향상을 나타내는 문항별 점수는 기록되지 않았다.

검색 범위 제한 · EXP-007~011 EXP-007에서는 정제 단계를 적용했으나 전체 품질이 낮아 효과를 비교하지 못하였다. EXP-008에서는 검색 청크 수를 늘렸지만 개선이 관찰되지 않았고, 타 사업 문서의 청크가 포함되는 문제가 나타났다. EXP-009는 이를 완화하기 위해 사업을 식별한 후 해당 사업의 문서로 검색 범위를 제한한 실험이다. 이후 정제 재적용(EXP-010)과 청크 크기 확대(EXP-011)를 검토하였다. 정제의 세부 처리 방식과 검색 청크 수의 변경 전후 값은 기록되지 않았다.

4.3 임베딩 및 검색 구성 비교

EXP-012~014에서는 BGE-M3, KURE-v1 및 한국어 BGE-M3를 비교하였다. EXP-015~022에서는 생성 모델을 GPT-5 mini로 유지하고 Kiwi 적용 여부, Dense·BM25 결합 및 리랭커 사용 여부에 따른 검색 구성을 비교하였다. 이 단계의 목적은 생성 모델의 차이를 줄인 상태에서 검색 구성의 영향을 관찰하는 것이었다.

후반부 30문항 실험에서는 검색 구성 변경(EXP-024·032), 프롬프트 수정(EXP-025·034), 리랭커 교체(EXP-026), 청크 헤더 추가(EXP-027), 청크 크기 확대(EXP-028)를 검토하였다. EXP-029·030·031·033은 계획 단계로 기록되어 있다.

5. 구성 요소별 실험 결과

5.1 초기 검색 범위 및 임베딩 비교

초기 실험의 Factual Correctness 기록값은 표 4와 같다. 사업별 검색을 적용한 EXP-009는 EXP-008 대비 0.0250 높은 점수를 기록하였으며, 타 사업 근거의 혼입이 감소한 것으로 관찰되었다. 다만 '성능이 크게 개선되었다'는 정성적 설명과 점수의 변화량은 구분하였다.

표 4. 초기 10문항 실험의 Factual Correctness 기록값

실험	변경 내용	Factual Correctness
EXP-008	검색 청크 수 확대	0.8130
EXP-009	사업별 검색 범위 제한	0.8380
EXP-010	정제 단계 재적용	0.9090
EXP-011	청킹 1000/200 적용	0.3540
EXP-012	BAAI/bge-m3	0.7830
EXP-013	nlpai-lab/KURE-v1	0.7760
EXP-014	dragonkue/BGE-m3-ko	0.8950

EXP-010과 EXP-011의 결과 설명은 모두 '큰 차이 없음'이지만 점수는 0.9090에서 0.3540으로 감소하였다. 설명과 수치가 일치하지 않으므로, 정제 또는 청크 크기의 효과를 이 두 기록만으로 확정하지 않았다. EXP-011과 EXP-012는 청킹 설정도 함께 달라 직접적인 임베딩 교체 효과로 비교하지 않았다.

임베딩 비교 행에서는 한국어 BGE-M3가 0.8950으로 가장 높은 Factual Correctness를 기록하였다. 그러나 이 값은 임베딩의 검색 성능을 직접 나타내는 지표가 아니다. 생성 모델과 평가 문항의 동일성이 확인되지 않아, 해당 임베딩의 일반적인 우위를 입증한 결과로 해석하지 않았다.

5.2 검색 구성 비교 및 300문항 평가

EXP-015~022에 기록된 검색 구성은 표 5와 같다. Kiwi BM25 단독 구성은 정답 청크를 높은 순위에 배치한 것으로 관찰되었고, Dense·Kiwi BM25와 GTE 리랭커의 조합도 우수한 구성으로 기록되었다. 그러나 일부 구성의 수치가 없어 여섯 구성의 정량적 순위를 산출할 수는 없다.

표 5. EXP-015~022의 검색 구성과 결과 기록 범위

기록 ID	검색 구성	결과 기록
EXP-015~022-A	Kiwi BM25	정답 청크 순위가 양호하다는 정성 관찰
EXP-015~022-B	일반 BM25	개별 결과 미기록
EXP-015~022-C	Dense + Kiwi BM25	개별 결과 미기록
EXP-015~022-D	Dense + 일반 BM25	개별 결과 미기록
EXP-015~022-E	Dense + Kiwi BM25 + GTE 리랭커	문서 100개·문항 300개 평가값 기록
EXP-015~022-F	Dense + 일반 BM25 + GTE 리랭커	점수 원본 미확인

EXP-015~022-E의 문서 단위 Hit@5는 0.9933, MRR은 0.9670, LLM-as-Judge는 0.7699, Factual Correctness는 0.5991이었다. 300문항을 분모로 환산하면 Hit@5는 약 298문항에 해당한다. 이 값은 정답 문서의 검색 여부에 관한 결과이며, 응답 정확도 또는 모든 정답 근거의 확보 비율을 뜻하지 않는다. 원본 CSV와 RAGAS 결과 파일은 이번 분석에 포함되지 않아 기록표의 집계값을 재계산하지 않았다.

5.3 후반부 30문항 실험의 검색 구성 비교

후반부 실험의 검색 지표는 표 6, 생성 응답 평가값은 표 7에 제시하였다. 기준 구성인 EXP-023은 한국어 BGE-M3, Dense + Kiwi BM25, GTE 리랭커 및 700/100 청킹이다. 생성 모델은 Claude Haiku 4.5, 평가 모델은 Gemini로 기록되어 있다. EXP-023의 상태는 '완료'이나 결과 설명에는 '아직 미실행'이 남아 있어, 후속 행들이 인용하는 비교 기준값으로만 사용하였다.

표 6. 10개 문서·30문항 실험의 검색 성능

실험 및 변경 조건	Hit@5	MRR
EXP-023: 기준 구성	0.9667	0.8137
EXP-024: 일반 BM25 적용	0.9667	0.8139
EXP-025: 프롬프트 수정, 잠정값	0.9667	0.8137
EXP-026: BGE 리랭커 적용	1.0000	0.8889
EXP-027: 사업명·기관 헤더 추가	0.9333	0.8867
EXP-028: 1000/200 청킹 적용	1.0000	0.9306
EXP-032: Dense 단독	0.9667	0.8141

표 7. 10개 문서·30문항 실험의 생성 응답 평가값

실험	LLM-as-Judge	Factual Correctness
EXP-023	0.9383	0.4807
EXP-024	0.9167	0.3460
EXP-025: 잠정값	0.9400	0.5417
EXP-026	0.9367	0.4860
EXP-027	0.9367	평가 생략
EXP-028	0.9467	평가 생략
EXP-032	0.9433	0.4727

Kiwi BM25를 일반 BM25로 변경한 EXP-024는 기준 구성과 검색 지표가 거의 같았지만 생성 응답 평가값은 낮았다. 다만 해당 행의 청킹과 임베딩 설정이 비어 있어 다른 조건이 동일했는지 확인해야 한다. Dense 단독인 EXP-032도 기준 구성과 유사한 검색 지표를 기록하였다. 따라서 이 평가 집합에서는 하이브리드 검색이 Dense 단독보다 일관되게 우수하다고 판단하기 어렵다.

5.4 리랭커 교체에 따른 검색 성능

변경 조건 EXP-026에서는 기준 구성의 GTE 리랭커를 BGE 리랭커로 교체하였다.

측정 결과 Hit@5는 0.9667에서 1.0000으로 증가하여 정답 청크를 검색한 문항이 29개에서 30개로 늘었다. MRR은 0.813675에서 0.888889로 0.075214 증가하였다. 그림 1은 기준 구성, 리랭커 교체 및 후속 청크 크기 변경 조건의 MRR을 비교한 것이다.

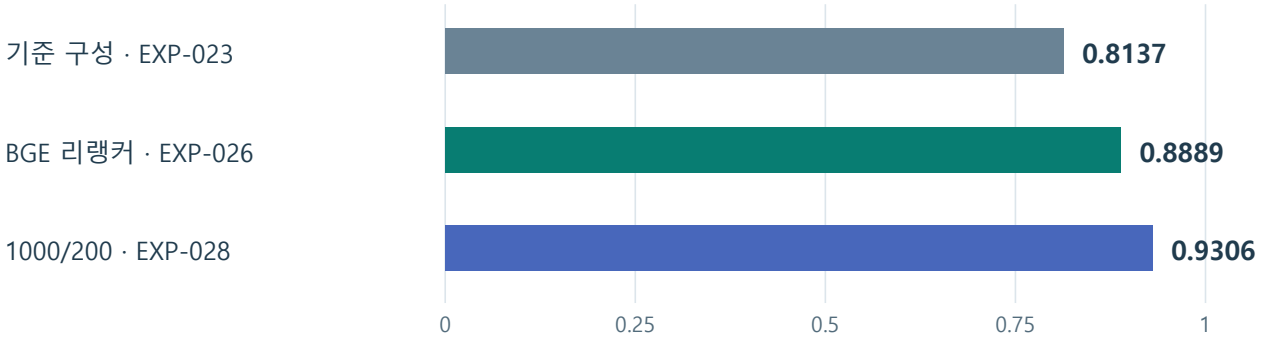


그림 1. 리랭커 및 청크 크기 변경 조건의 MRR 비교

10개 문서·30문항의 기록값. 가로축은 MRR(0~1)이며 높을수록 좋다. EXP-023의 실행 상태는 미확정이며, 비교 기준값으로 사용하였다.

해석 및 한계 리랭커 교체 전후의 LLM-as-Judge는 0.9383과 0.9367, Factual Correctness는 0.4807과 0.4860으로 큰 차이를 보이지 않았다. 즉 검색 순위의 개선은 기록되었으나 생성 응답의 품질 향상은 확인되지 않았다. 반복 평가와 통계 검정이 수행되지 않아 작은 점수 차이의 통계적 유의성은 판단하지 않았다.

5.5 청크 크기 변경에 따른 정답 근거 포함 범위

검토 배경 EXP-026에서는 모든 문항의 상위 5개 결과에 정답 청크가 포함되었지만, 모든 정답 근거가 생성 모델의 입력에 포함된 문항은 26개였다. 이는 정답 청크를 하나 이상 검색하는 것과 응답에 필요한 근거를 모두 확보하는 것이 서로 다른 평가 대상임을 보여준다.

변경 조건 및 결과 EXP-028에서는 BGE 리랭커를 유지하고 청킹을 700/100에서 1000/200으로 변경하였다. MRR은 0.888889에서 0.930556으로 증가하였으며, 모든 정답 근거를 포함한 문항은 26개에서 28개로 증가하였다. 이에 해당하는 문항 비율은 86.7%에서 93.3%로 6.7%p 높아졌다. 정답 근거 포함 범위에 관한 비교는 표 8과 그림 2에 제시하였다.

표 8. 청크 크기 변경에 따른 정답 근거 포함 범위

평가 항목	EXP-026: 700/100	EXP-028: 1000/200
모든 정답 근거를 포함한 문항 수	26/30	28/30
상위 5개 결과의 근거 문장 재현율	0.9200	0.9667
생성 모델 입력 문맥의 근거 문장 재현율	0.9367	0.9667
생성 모델 입력 문맥의 평균 길이	3,545자	5,122자

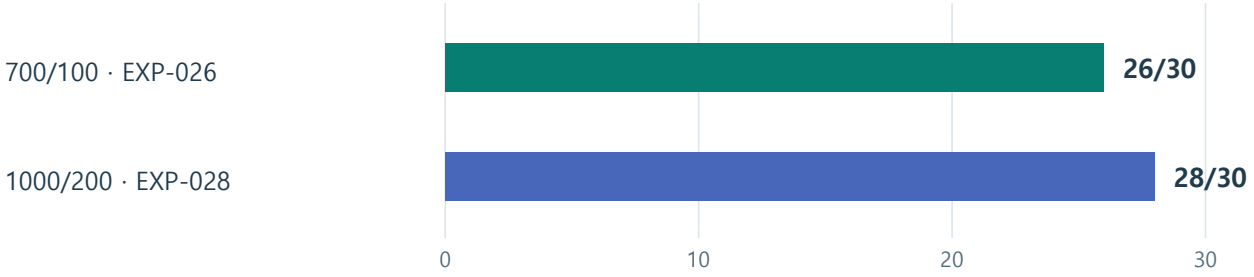


그림 2. 청크 크기별 전체 정답 근거 포함 문항 수

정답 근거가 모두 생성 모델의 입력 문맥에 포함된 문항 수. 분모는 30문항이며 EXP-026은 86.7%, EXP-028은 93.3%이다.

개선 범위 청크 크기가 증가하면 정답 내용이 검색 결과에 포함될 가능성도 높아질 수 있다. 따라서 Hit@5와 MRR의 변화만으로 성능을 판단하지 않고 근거 문장 재현율을 함께 검토하였다. 두 재현율도 증가한 점에서 EXP-028은 정답 근거의 누락을 줄인 구성으로 해석할 수 있다. 다만 그림 3과 같이 생성 모델 입력 문맥의 평균 길이가 3,545자에서 5,122자로 약 44.5% 증가하였다. 실제 토큰 사용량, 비용 및 지연 시간의 증가율은 측정되지 않았다.

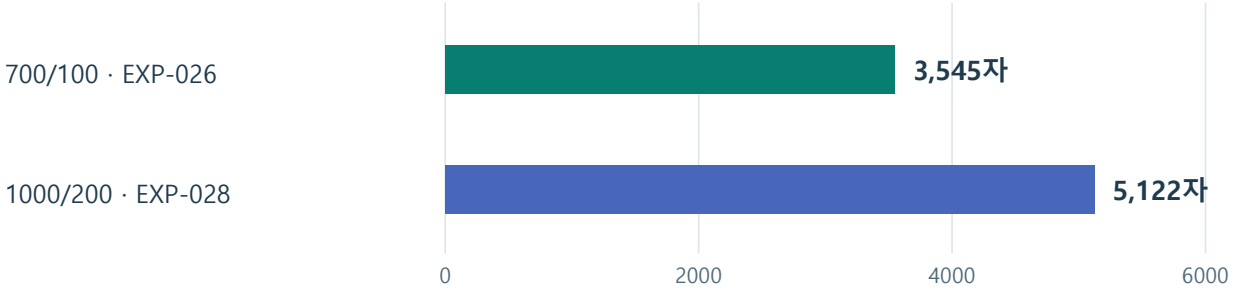


그림 3. 청크 크기별 생성 모델 입력 문맥의 평균 길이

문항당 평균 문자 수. 3,545자에서 5,122자로 약 44.5% 증가하였다. 실제 토큰 사용량·비용·지연 시간의 증가율은 아니다.

한계 및 남은 문제 EXP-028은 생성 프롬프트도 v2로 변경하였다. 따라서 LLM-as-Judge 0.9467을 EXP-026의 값과 비교하여 청크 크기만의 생성 품질 개선 효과로 제시할 수 없다. Factual Correctness는 평가가 생략되었다. 단일 위치의 사실을 확인하는 direct_fact 유형의 근거 누락은 해소된 것으로 기록되었으나, 여러 섹션의 정보를 결합하는 multi_section 유형의 재현율은 0.90으로 유지되었다. DOC001-Q03은 3개 근거 중 2개, DOC010-Q03은 3개 중 1개만 포함되어 추가 개선이 필요하다.

5.6 청크 헤더 추가에 따른 검색 결과의 변화

변경 목적 및 조건 EXP-027은 EXP-026의 청크 앞에 사업명과 발주기관을 추가한 실험이다. 사업 식별에 실패하여 전체 문서를 검색하는 경우에도 동일 사업의 청크를 선택하도록 유도하는 것이 목적이었다. 이 실험은 EXP-028과 별도로 비교하였으며, EXP-028이 헤더 구성을 계승한 것으로 보지 않았다.

측정 결과 그림 4와 같이 타 사업 문서의 청크가 포함된 문항은 3개에서 0개로 감소하였다. 반면 Hit@5는 1.0000에서 0.9333으로 하락하였으며, 상위 5개 결과의 근거 문장 재현율은 0.9200에서 0.8717로 감소하였다. 생성 모델 입력 문맥의 재현율도 0.9367에서 0.9133으로 낮아졌다. 모든 정답 근거를 포함한 문항 수는 26개로 같았다.

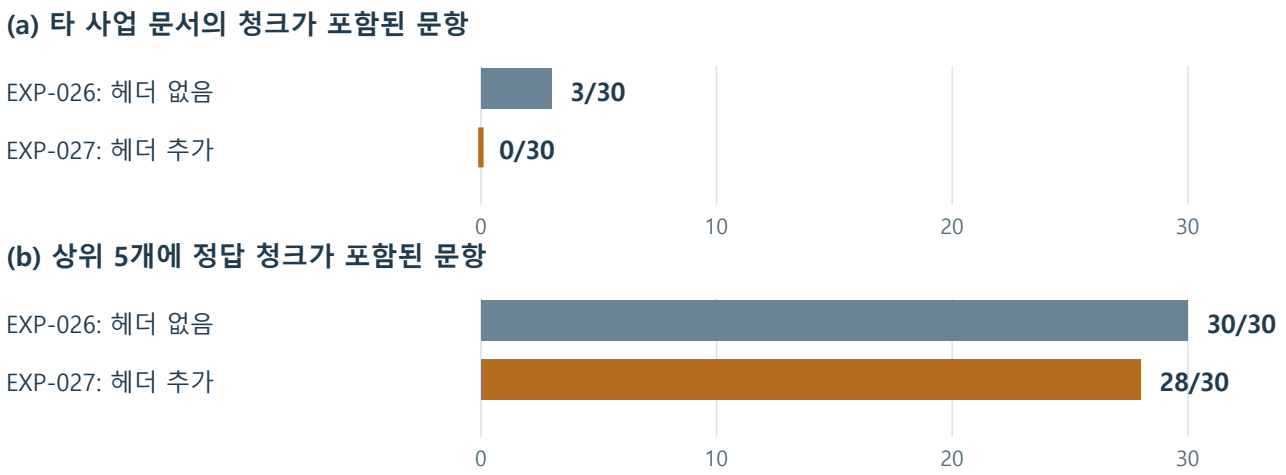


그림 4. 청크 헤더 추가에 따른 타 사업 문서 포함 문항 수와 정답 검색 문항 수

분모는 모두 30문항이다. (a)는 문항 수가 적을수록, (b)는 많을수록 좋다. 두 지표는 같은 문항 집합을 서로 다른 기준으로 평가한 결과이다.

적용 판단 사업 식별에 실패한 문항 수는 28개로 유지되었다. 따라서 헤더 추가는 사업 식별 자체를 개선한 것이 아니라 검색 결과의 문서 구성을 변경한 것으로 해석된다. 같은 문서의 청크를 선택하는 비율은 높아졌지만 해당 문서 내 정답 근거를 선택하는 성능은 하락하여, 기록상 10문서 조건에서는 적용하지 않기로 하였다. 동일한 사업명이 모든 청크에 포함되어 청크 간 구분이 약화되었을 가능성이 제기되었으나, 이는 검증된 원인이 아니라 기록자의 해석이다.

5.7 프롬프트 수정 및 미완료 실험

EXP-025에는 프롬프트 수정 후 Factual Correctness가 0.5417로 기록되어 있다. 기준값 0.4807보다 높지만 상태가 '계획'이고 설명도 '아직 미실행'이므로 잠정값으로 분류하였다. EXP-034는 새 프롬프트와 리랭커를 결합한 진행 중 실험이며 수치가 없다. 두 행을 완료된 개선 성과에 포함하지 않았다. 후속 실험의 목적과 확인 사항은 표 9와 같다.

표 9. 계획 또는 진행 중인 후속 실험

실험	변경 계획	평가할 사항
EXP-029	요구사항 표 단위 청킹	청크 경계에 의한 요구사항 근거 누락
EXP-030	text-embedding-3-small 적용	생성 조건을 고정한 임베딩 교체 효과
EXP-031	사업 카드 점수 기반 검색 범위 선택	정식 사업명이 없는 질의의 사업 선택 성능
EXP-033	child-parent 청킹	작은 청크 검색과 상위 문맥 확장의 효과
EXP-034	새 프롬프트와 리랭커 결합	검색된 근거가 생성 응답에 반영되는 정도

6. 종합 분석과 후속 과제

6.1 검색 성능과 생성 응답 평가의 관계

분석 결과, 검색 성능과 생성 응답 평가값은 같은 방향으로 변하지 않았다. EXP-026의 MRR은 증가하였으나 생성 응답 평가값은 기준 구성과 유사하였다. EXP-028에서는 정답 근거의 포함 범위가 넓어졌지만 프롬프트 변경이 동반되어 응답 품질의 개선 원인을 분리할 수 없었다. 따라서 현재 기록이 뒷받침하는 성과는 검색 순위와 정답 근거의 포함 범위 개선으로 한정된다.

Hit@5가 1.0000인 조건에서도 모든 정답 근거가 포함되지 않은 문항이 존재하였다. 제안요청서와 같이 여러 요구사항을 함께 확인해야 하는 질의에서는 첫 정답 청크의 검색 여부만으로 응답에 필요한 정보의 충분성을 판단하기 어렵다. 후속 평가에서는 Hit@5·MRR과 함께 근거 문장 재현율 및 전체 정답 근거의 포함 여부를 유지할 필요가 있다.

6.2 적용 검토 및 후속 검증

BGE 리랭커와 1000/200 청킹은 후반부 30문항 기록에서 검색 성능이 개선된 구성으로 검토할 수 있다. 그러나 입력 문맥 길이 증가를 고려해야 하며, 생성 품질과 처리 비용을 포함한 최종 적용 판단에는 추가 실험이 필요하다. Dense 단독도 기준 하이브리드 구성과 유사한 지표를 기록했으므로 검색 구조를 단순화할 가능성도 배제하지 않았다.

후속 비교에서는 동일한 문서·문항 집합, 생성 프롬프트 및 리랭커를 유지하고 하나의 구성 요소만 변경해야 한다. 특히 EXP-029의 비교 기준인 EXP-028은 BGE 리랭커를 사용하지만 계획 행에는 GTE 리랭커가 적혀 있으므로, 청킹 효과를 분리하려면 설정을 먼저 통일해야 한다. 사업 식별 실패와 다중 섹션 근거 누락은 각각 사업 선택 성능 및 근거 문장 재현율로 평가할 수 있다.

6.3 분석의 한계

첫째, 데이터 집단과 정답 판정 단위가 달라 초기·300문항·30문항 결과를 통합 비교할 수 없다. 둘째, 일부 행의 상태와 결과 설명이 충돌하며 생성 모델, 정제 방식, 검색 개수 및 평가 설정이 누락되어 있다. 셋째, 평가 문항이 30개인 주요 비교에서 반복 실행과 통계 검정이 없어 결과의 일반화에 제약이 있다. 넷째, 청킹 변경과 함께 평가 대상 청크의 범위가 달라져 지표 상승에 영향을 줄 수 있다. 마지막으로, 본 보고서는 원본 코드와 문항별 결과 파일을 재검증하지 않았다. 주요 불일치는 부록 A에 정리하였다.

7. 결론

본 보고서는 한국어 제안요청서 RAG 시스템의 구축 및 개선 실험 기록을 구성 요소별로 분석하였다. 초기에는 문서 처리 범위와 자동 평가 절차를 확장하였고, 이후 사업별 검색, 임베딩, 검색 구성 및 리랭커를 비교하였다. 후반부 30문항 기록에서 BGE 리랭커 적용은 Hit@5와 MRR을 높였으며, 1000/200 청킹은 모든 정답 근거를 포함한 문항 수를 26개에서 28개로 증가시켰다.

청크 헤더 추가는 타 사업 문서의 포함을 줄였으나 정답 근거 검색 성능을 낮추었다. 또한 청크 확대에 따른 입력 문맥 길이 증가와 프롬프트 변경의 영향을 함께 고려해야 한다. 따라서 현재의 개선 결과를 생성 응답의 사실적 정확성 향상이나 최종 구성의 우수성으로 일반화하기는 어렵다. 향후에는 생성 조건을 고정한 구성 요소별 비교와 다중 섹션 근거 누락 분석을 통해 검색 성능의 향상이 응답 품질로 이어지는지 검증해야 한다.

참고문헌 및 분석 자료

[1] 중급 프로젝트 실험 기록표, Google Sheets, Sheet1, 2026년 10월 16일 최초 조회본. 원본 시트.

[2] 사용자 제공 자료, 초기 RAG 실험 EXP-001~022의 수행 경위 및 과거 청킹 비교 계획, 이 채팅에 제공된 설명, 2026.

[3] J.-W. Seo and J. Min, “Optimization of a Hybrid RAG System for Korean Legal QA,” Journal of The Korea Society of Computer and Information, vol. 30, no. 8, pp. 53–63, 2025. DOI: 10.9708/jksci.2025.30.08.053. 논문 원문.

[4] J.-K. Oh and S. K. Kim, “Design of a RAG-based Q&A System for University Academic Administration Assistants,” Journal of The Korea Society of Computer and Information, vol. 30, no. 7, pp. 79–86, 2025. DOI: 10.9708/jksci.2025.30.07.079. 논문 원문.

[5] 한국국방기술학회, “한국국방기술학회지 원고 작성 규정,” 2026년 10월 16일 확인. 작성 규정.

[6] Ragas, “Factual Correctness,” 공식 문서, 2026년 10월 16일 확인. 평가 지표 설명.

문헌 [3,4]는 기술 용어와 결과를 서술하는 표현 방식의 참고자료로 사용하였다. 본문은 실험을 검토하기 위한 기술보고서 구성으로 정리하였으며, 표·그림의 캡션은 규정 [5]를 참고하였다. 외부 문헌의 성능값은 본 프로젝트의 결과로 사용하지 않았다.

부록 A. 원본 기록의 불일치 및 미확인 항목

표 A-1. 원본 기록의 불일치와 분석상 처리

대상	불일치 또는 미확인 내용	처리 원칙
EXP-010·011	관찰 설명과 0.9090 → 0.3540이 일치하지 않음	정제·청크 크기 효과 판단 유보
EXP-012·013	개별 점수 미기록 설명과 점수 칸이 공존	행의 집계값만 인용
EXP-015~022	여덟 번호가 여섯 구성 행으로 정리됨	개별 실행 번호를 재배정하지 않음
EXP-015~022-E·F	옛 열 문자와 정정된 열 문자 혼재	실제 열 제목을 기준으로 지표 대응
EXP-023	완료 상태와 미실행 설명 공존	후속 비교 기준값으로 인용, 실행 상태는 미확정
EXP-024	청킹·임베딩 설정 누락	완전한 단일 변수 비교로 단정하지 않음
EXP-025	계획·미실행 상태에 평가값 기재	잠정값으로 구분
EXP-028	입력 토큰 증가 설명과 실제 문자 수 기록 혼재	문자 수 증가만 확인
EXP-029	기준 실험과 계획의 리랭커 불일치	실행 전 동일 조건으로 정리 필요

사용자 설명의 '23번 청킹 비교 미실행'은 과거 계획에 관한 기록이다. 현재 시트의 EXP-023은 후반부 실험의 기준행으로 사용되고 있으므로, 요구사항 단위 청킹(EXP-029) 및 child-parent 청킹(EXP-033) 계획과 구분하였다.

부록 B. 주요 모델 식별자

표 B-1. 본문에서 사용한 모델 이름과 식별자

본문 이름	원본 기록의 식별자
BGE-M3	BAAI/bge-m3
KURE-v1	nlpai-lab/KURE-v1
한국어 BGE-M3	dragonkue/BGE-m3-ko
GTE 리랭커	Alibaba-NLP/gte-multilingual-reranker-base
BGE 리랭커	BAAI/bge-reranker-v2-m3
Claude Haiku 4.5	기준행: claude-haiku-4-5-20251001. 일부 후속행은 제품명만 기재
Gemini 평가 모델	gemini-3.1-flash-lite
OpenAI 임베딩 비교 계획	text-embedding-3-small