한국어 제안요청서 기반 RAG 시스템의 실험 결과 요약

기술보고서 요약본 · 2026년 10월 16일

요약

한국어 제안요청서 질의응답을 위한 검색 증강 생성(RAG) 시스템의 실험 기록을 분석하였다. 후반부 30문항 평가에서 리랭커 교체와 청크 크기 확대는 검색 순위와 정답 근거의 포함 범위를 개선하였다. 다만 생성 응답 평가값의 변화는 작거나 프롬프트 변경과 함께 나타나, 응답의 사실적 정확성 향상은 확인되지 않았다.

1. 분석 방법

분석 자료는 2026년 10월 16일에 최초 조회한 실험 기록표이다[1]. 주요 비교는 문서 10개·30문항 평가를 대상으로 하였다. 기준 구성은 한국어 BGE-M3, Dense + Kiwi BM25, GTE 리랭커 및 700/100 청킹이며, EXP-026은 리랭커를 BGE로 교체하고 EXP-028은 1000/200 청킹을 적용한 조건이다. 본 요약에서는 새 실험을 수행하지 않았다.

2. 실험 결과

표 1. 주요 구성 변경에 따른 검색 및 정답 근거 포함 결과

비교	변경 내용	기록된 변화
EXP-023 → 026	GTE → BGE 리랭커	Hit@5: 0.9667 → 1.0000; MRR: 0.8137 → 0.8889
EXP-026 → 028	청킹 700/100 → 1000/200	전체 정답 근거 포함 문항: 26/30 → 28/30; MRR: 0.8889 → 0.9306



그림 1. 주요 구성 변경 조건의 MRR 비교

10개 문서·30문항의 기록값. 가로축은 MRR(0~1)이며 높을수록 좋다. EXP-023의 실행 상태는 미확정이며, 비교 기준값으로 사용하였다.

MRR은 첫 정답의 순위 역수 평균이며 값이 높을수록 정답이 앞에 위치한다. Hit@5는 상위 5개에 정답 대상이 포함된 문항 비율로, 전체 정답 근거의 확보 여부와는 구분된다.

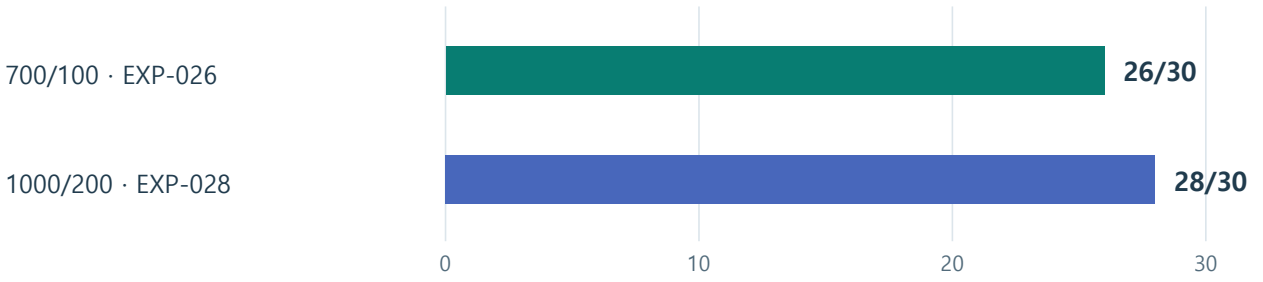


그림 2. 청크 크기별 전체 정답 근거 포함 문항 수

정답 근거가 모두 생성 모델의 입력 문맥에 포함된 문항 수. 분모는 30문항이며 EXP-026은 86.7%, EXP-028은 93.3%이다.

EXP-026 대비 EXP-028의 전체 정답 근거 포함 문항 비율은 86.7%에서 93.3%로 증가하였다. 생성 모델 입력 문맥의 근거 문장 재현율도 0.9367에서 0.9667로 증가하였다.

2. 실험 결과: 추가 비교

EXP-027은 청크 앞에 사업명과 발주기관을 추가한 조건이다. 타 사업 문서의 청크가 포함된 문항은 3개에서 0개로 감소하였으나, Hit@5는 1.0000에서 0.9333으로 하락하였다. 상위 5개 결과의 근거 문장 재현율도 0.9200에서 0.8717로 감소하여, 기록상 10문서 조건에서는 적용하지 않았다.

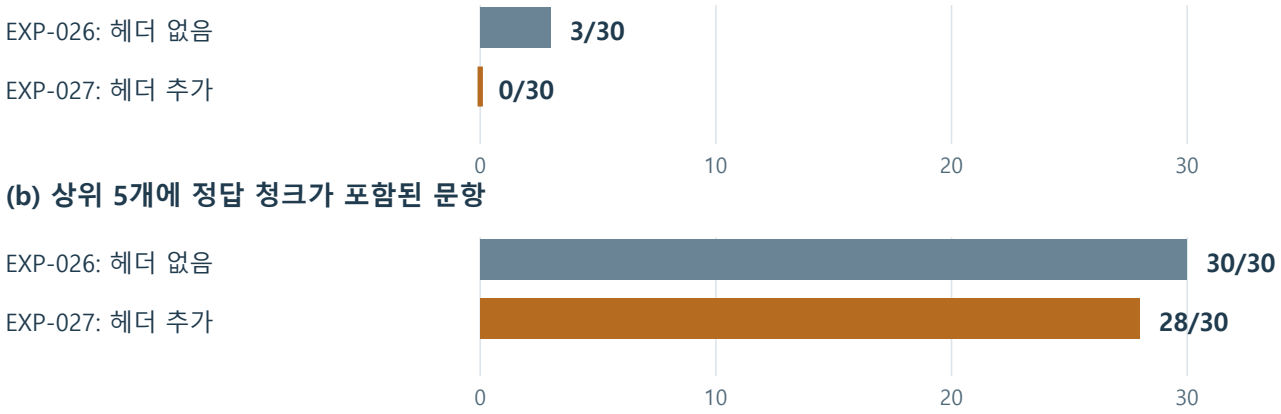


그림 3. 청크 헤더 추가에 따른 타 사업 문서 포함 및 정답 검색 문항 수

분모는 모두 30문항이다. (a)는 문항 수가 적을수록, (b)는 많을수록 좋다. 두 지표는 같은 문항 집합을 서로 다른 기준으로 평가한 결과이다.

표 2. 초기 및 별도 평가 집단의 주요 기록값

실험	평가 조건	결과
사업별 검색: EXP-008 → 009	초기 10문항	Factual Correctness: 0.813 → 0.838; 타 사업 근거 혼입 감소 관찰
임베딩 비교: EXP-012~014	초기 10문항	한국어 BGE-M3: 0.895; 세 후보 중 가장 높은 기록값
EXP-015~022-E	100문서·300문항, 문서 단위	Hit@5: 0.9933; Factual Correctness: 0.5991

3. 논의 및 한계

리랭커 교체 전후 LLM-as-Judge는 0.9383과 0.9367, Factual Correctness는 0.4807과 0.4860으로 유사하였다. 청크 확대 조건은 생성 프롬프트도 변경되어 응답 품질의 변화를 청킹 효과로 분리할 수 없다. 입력 문맥의 평균 길이는 3,545자에서 5,122자로 약 44.5% 증가했으며, 실제 비용과 지연 시간은 미측정이다.

EXP-023의 상태와 설명은 서로 충돌하므로 비교 기준값으로만 인용하였다. 초기·300문항·30문항 결과는 데이터와 정답 판정 단위가 달라 직접 비교하지 않았다. 원본 코드 재현 및 통계적 유의성 검정도 수행하지 않았다.

4. 결론

BGE 리랭커와 1000/200 청킹은 후반부 평가에서 검색 순위와 정답 근거의 포함 범위를 개선한 구성으로 검토할 수 있다. 다만 생성 응답의 사실적 정확성 향상은 추가 검증이 필요하다. 후속 실험에서는 생성 조건을 고정하고 사업 식별 실패와 다중 섹션 근거 누락을 평가해야 한다.

분석 자료

[1] 중급 프로젝트 실험 기록표, Sheet1, 2026년 10월 16일 최초 조회본. 원본 시트. 국내 논문 및 원고 작성 규정의 서지사항은 상세 보고서의 참고문헌에 수록하였다.