실험 결과 요약 · 2026.10.16

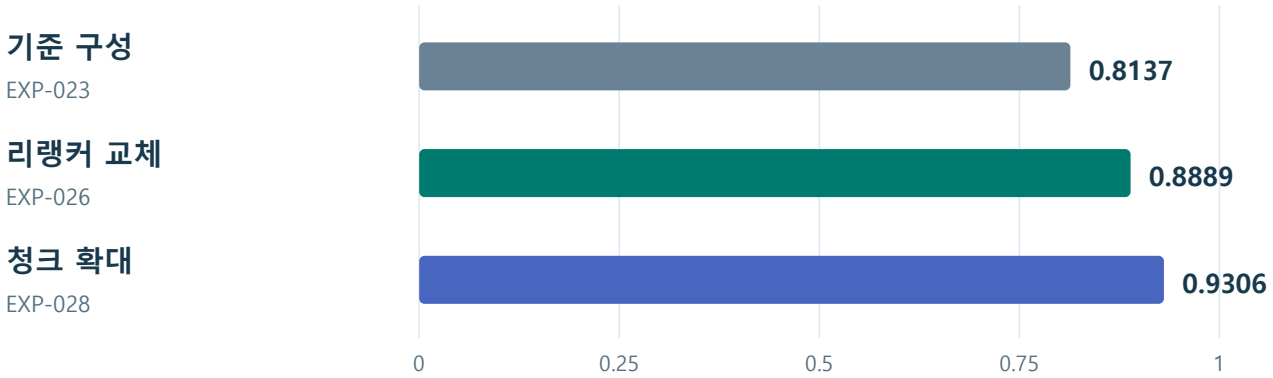
RAG 실험 핵심 요약

검색 순위와 근거 전달은 개선됐다.
답변의 사실적 정확성까지 개선됐는지는 추가 확인이 필요하다.

주요 비교: 문서 10개·질문 30개. 개정본의 기록값을 요약했으며 새 실험은 실행하지 않았다.

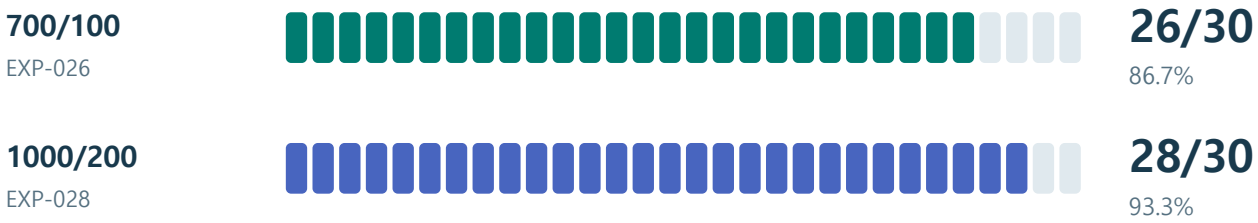
핵심 실험	바꾼 내용	개선된 점
EXP-026 리랭커 교체	GTE → BGE 리랭커	정답 근거 검색 **29 → 30개** MRR **0.8137 → 0.8889**
EXP-028 청크 확대	700/100 → 1000/200 BGE 리랭커 유지	전체 근거 전달 **26 → 28개** MRR **0.8889 → 0.9306**

그래프 1. 첫 정답 근거가 더 앞에 놓였다



MRR: 첫 정답의 순위 점수. 0~1이며 높을수록 좋다. 가로축은 0부터 시작한다.

그래프 2. 필요한 근거를 모두 전달한 질문이 늘었다



한 칸은 질문 1개. 회색은 일부 근거가 빠진 질문이다. 칸의 순서는 실제 질문 ID와 무관하다.

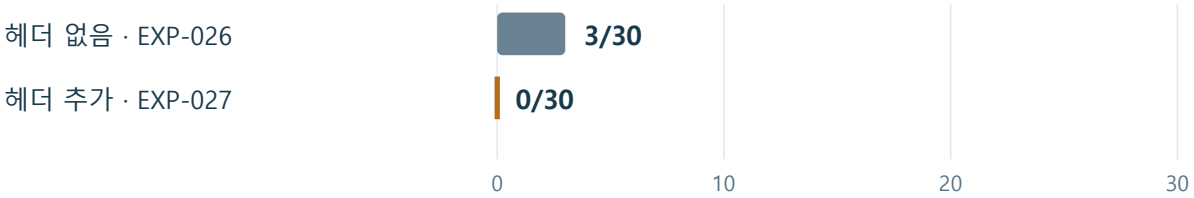
Hit@5는 상위 5개에 정답 근거가 포함된 질문의 비율이다. 근거를 모두 찾았다는 뜻은 아니다.
EXP-023은 상태와 설명이 충돌해 비교 기준값으로만 인용했다. EXP-028은 답변 프롬프트도 달라 답변 점수 상승을 청킹의 효과로 확정하지 않았다.

적용 판단과 남은 과제

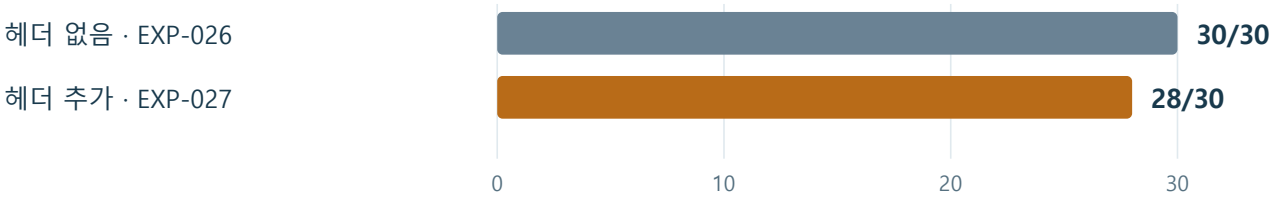
좋아진 점과 함께 볼 한계

그래프 3. 헤더는 혼입을 줄였지만 필요한 근거도 놓쳤다

다른 사업의 근거가 섞인 질문 · 적을수록 좋음



상위 5개에 정답 근거가 있는 질문 · 많을수록 좋음



두 지표의 분모는 모두 질문 30개. EXP-026과 EXP-027을 비교했다.

근거를 더 담은 대가: 질문당 전달 문맥 **3,545자 → 5,122자, 약 44.5% 증가.**
실제 토큰 사용량·비용·응답 시간의 증가율은 측정하지 않았다.

앞선 실험에서 얻은 방향 · 별도 평가 조건

실험	기록된 결과	읽을 때의 범위
사업별 검색 EXP-008 → 009	사실 일치 점수 **0.813 → 0.838**	다른 사업 근거 혼입 감소 관찰. 초기 10개 질문 기록
임베딩 비교 EXP-012~014	한국어 BGE-M3 **사실 일치 점수 0.895**	세 후보 중 가장 높음. 동일 실행 조건은 미확인
하이브리드·리랭커 EXP-015~022-E	문서 Hit@5 **99.33%** 사실 일치 점수 **0.5991**	100문서·300질문 결과. 문서 검색률과 답변 정확도는 다름

채택 판단: 헤더 추가는 10문서 조건에서 미채택. 한국어 BGE-M3 + Dense·Kiwi BM25 + BGE 리랭커 + 1000/200 청킹은 **채택 후보**다.

남은 과제: 여러 섹션에 흩어진 근거를 모으는 질문은 누락이 남았다. 같은 프롬프트·리랭커를 유지한 비교로 청킹 효과와 답변 개선 여부를 분리해 확인해야 한다.

출처: 실험 기록표 Sheet1과 2026-10-16 개정본. 최초 조회 자료 기준이며 원본 실행을 재현하지 않았다. 검색·답변 지표와 서로 다른 평가 집단을 구분했다. 원본 시트