검색 개선은 확인됐다.
답변 품질의 최종 채택은 남아 있다.

한국어 RFP 질의응답 RAG · 최종 평가 리포트 · 2026년 10월 16일

초기 설계부터 기존 메인 선정, 팀원 구성 비교, EXP-001~034 개선 실험까지 정리했다. **이 보고서는 현재 자료의 종합 평가본**이며, 최종 운영 구성을 승인한 문서는 아니다.

리랭커 교체 · EXP-023 → 026

29 → 30 / 30

상위 5개 정답 포함 · 기준행 상태 충돌 유의

청크 확대 · EXP-026 → 028

26 → 28 / 30

필요한 근거를 모두 전달한 문항

청크 확대 후 문맥 길이

+44.5%

3,545 → 5,122자 · 토큰·비용은 미측정

평가 대상	이번 종합 판단	판단 근거
기존 `07_verify`	비교 기준 유지	팀원 전체 대체를 입증하지 못했다. 기존 누락·범위 문제는 남아 있다.
EXP-026 · BGE 리랭커	채택 후보	Hit@5 1.0000, MRR 0.8889. 답변 점수 상승은 작다.
EXP-028 · 1000/200	우선 검증 후보	MRR 0.9306, 전체 근거 28/30. 프롬프트도 변경됐고 사실 일치 점수는 없다.
EXP-027 · 사업명 헤더	해당 조건 미채택	타 사업 혼입은 3→0문항, 정답 포함은 30→28문항.
최소 모듈러 기준선	연결 확인	Haiku·TF-IDF 합성 2문서 성공. 실제 RFP 품질 우승 근거는 아니다.

읽는 순서 2쪽 과정 → 3~6쪽 이전 평가 → 7쪽 비교 기준 → 8~10쪽 최신 실험 → 11쪽 반영 여부 → 12쪽 후속 판단. 13~15쪽은 전체 실험과 근거다.

자료 기준 10월 14일 검토자료와 10월 16일 기술보고서·보존 시트. 이번 작업은 기존 결과 대조와 계산·시각화이며 새 모델 평가를 실행하지 않았다.

전체 과정: 세 갈래의 목적을 구분해야 한다

버전 번호가 이어져 보여도, 데이터·질문·모델·평가기까지 같다는 뜻은 아니다.

A · 기존 메인	**00_baseline → 06_route → 07_verify** 작은 로컬 모델이 질문 의도에 맞게 근거를 사용하도록 개선
B · 팀 공동 실험	**M/A/B 후보 비교 → 전체 대체 보류 → 최소 모듈러** 원형 보존·수정본 분리·부품 교체 규약 확보
C · 기록표 실험	**EXP-001~014 → 015~022 → 023~034** 문서 처리·검색 구성 탐색 → 검색 순위·근거 전달 진단

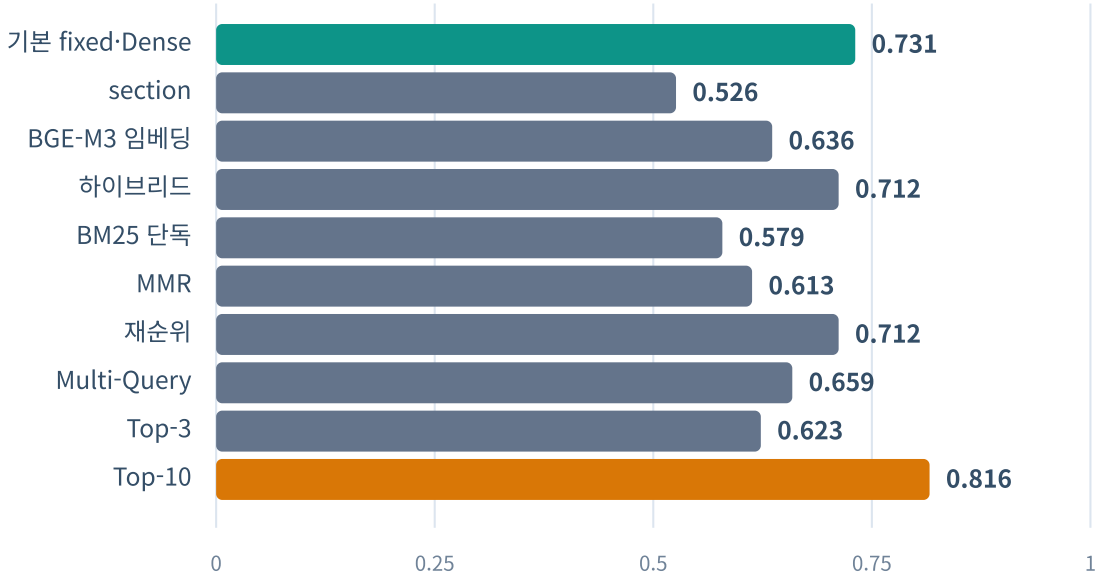
시기·구간	해결하려던 문제	진행한 일과 남은 결론
9/30 초기 설계	HWP·표, 작은 로컬 모델, 근거 추적	100문서(HWP 96·PDF 4), 40문항을 준비했다. 문서 준비와 질문 처리를 분리했다.
초기 검색·생성 비교	어느 공정에서 실패하는가	KURE·fixed·Dense Top-5를 선택했다. 질문 분류가 가장 큰 관측 개선이었다.
10/02 이후 보강	원문 검수·채점이 충분한가	EDA·전처리 재구축, 심판 2판·3판을 보강했다. 전처리 효과는 채점 변동과 분리하지 못했다.
10/09 검색 확장	부모·자식 청크·재순위가 나은가	100문서·168문항 검색 비교. 생성·전체 서비스의 최종 선정은 보류했다.
10/11~12 팀원 통합	메인을 교체할 수 있는가	출처 고정, 원형 A·수정 B 분리. 코드 결함 일부 반영, DEV8 전체 대체는 보류했다.
10/14 자료 정리	선정 이유와 팀 실험을 설명하는가	기존 선정 구성을 발표 메인으로 유지했다. 최소 모듈러는 별도 실험 출발점으로 설명했다.
10/16 기록표 종합	검색 성공이 완전한 답으로 이어지는가	EXP-034까지 32개 기록 행을 정리했다. BGE 리랭커·청크 확대의 근거 전달 개선을 확인했다.

비교 원칙 A·B·C의 점수를 연결한 “전체 정확도 상승률”은 계산하지 않는다. 기존 52개 버전 설명 항목도 52회의 동일 조건 실행을 뜻하지 않는다.

이전 검색 평가: 기능을 늘리는 대신 근거를 비교했다

전처리 전 · 개발 30문항 · 검색만 비교. “사실 포함률”은 핵심 표현을 찾는 문자열 지표다.

검색 사실 포함률 · 0~1, 높을수록 좋음



변경	Hit@5	MRR	사실 포함률	판정
기본 fixed·Dense	0.967	0.917	0.731	기본 채택
section	0.933	0.900	0.526	기본 우위 미입증
BGE-M3 임베딩	0.933	0.917	0.636	기본 우위 미입증
하이브리드	0.967	0.840	0.712	기본 우위 미입증
BM25 단독	0.900	0.828	0.579	기본 우위 미입증
MMR	0.967	0.917	0.613	기본 우위 미입증
재순위	0.967	0.875	0.712	기본 우위 미입증
Multi-Query	0.933	0.900	0.659	기본 우위 미입증
Top-3	0.900	0.883	0.623	기본 우위 미입증
Top-10	0.967	0.917	0.816	생성 효과 작음

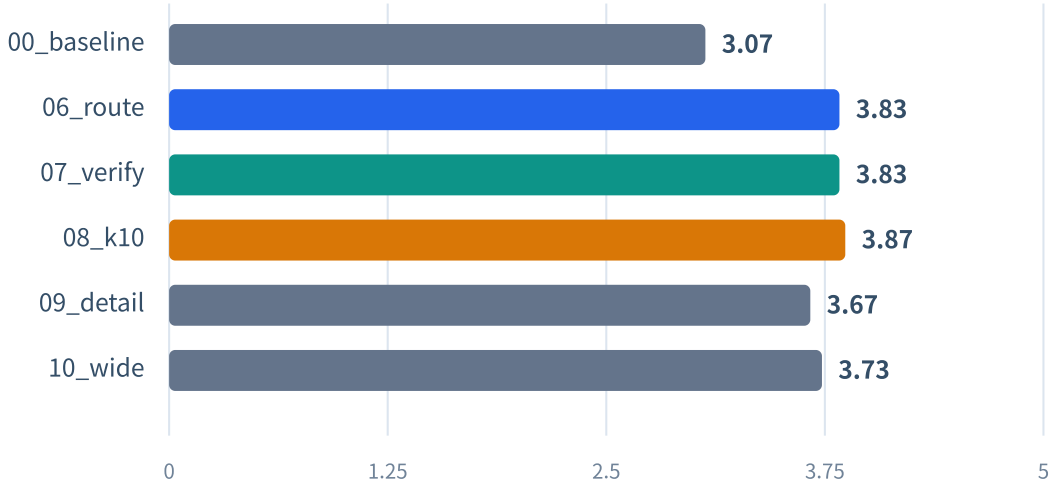
KURE 선택 근거 KURE의 Hit@5 0.967·사실 포함률 0.731이 BGE-M3의 0.933·0.636보다 높았다. BGE-M3의 Hit@1은 0.900으로 KURE 0.867보다 높았지만, 당시 우선순위는 Hit@5 → 사실 포함률 → MRR → Recall@5였다.

해석 한계 fixed 방식의 비교 우위와 1000/200 크기의 최적성은 다르다. 크기 전체를 탐색한 실험은 없었다. 기관명 필터는 해당 집단에서 결과가 같았다.

이전 생성 버전: 질문 분류의 효과가 가장 컸다

전처리 전 · DEV30(답 있음 23·답 없음 7) · 심판 2판 · 정확성은 5점 척도다.

답변 정확성 · 0~5점, 높을수록 좋음



버전	핵심 변경	정확성 /5	과도 거절	p95(초)
00_baseline	검색 후 한 번 생성	3.07	17.39%	3.872
06_route	질문 분류·유형별 처리	3.83	4.35%	9.344
07_verify	숫자 확인+사전 요약	3.83	0.00%	9.645
08_k10	전달 근거 5→10개	3.87	0.00%	13.178
09_detail	항목별 상세 생성	3.67	0.00%	15.002
10_wide	상세 생성+근거 확대	3.73	0.00%	16.588

00 → 06
정확성 +0.7666점. 답 있는 질문의 거절이 17.39%→4.35%로 줄었다. p95는 3.872→9.344초로 늘었다.

06 → 07
정확성은 3.8333으로 동일. 과도 거절은 0%가 됐다. 검증·요약의 개별 효과는 분리하지 않았다.

Top-10 미채택 이유 07 대비 정확성 +0.0334점, p95 +3.533초. 작은 점수 차이와 지연 증가를 함께 보고 Top-5를 유지했다. 09·10도 기존 07보다 정확성·근거 충실도가 낮았다.

확인용 10문항 00 3.0 → 07 3.7, 동일 근거를 받은 Claude 3.9. 계획상 +0.5점·참조 차이 0.5 이내를 충족했다. 단, 10개 중 2개가 개발 중 노출돼 완전한 독립 시험은 아니다.

모델과 확장 검색: 선택 이유는 집단 안에서만 성립한다

기존 모델 선택과 168문항 검색 확장은 서로 다른 실험이다. 두 결과를 한 순위로 합치지 않았다.

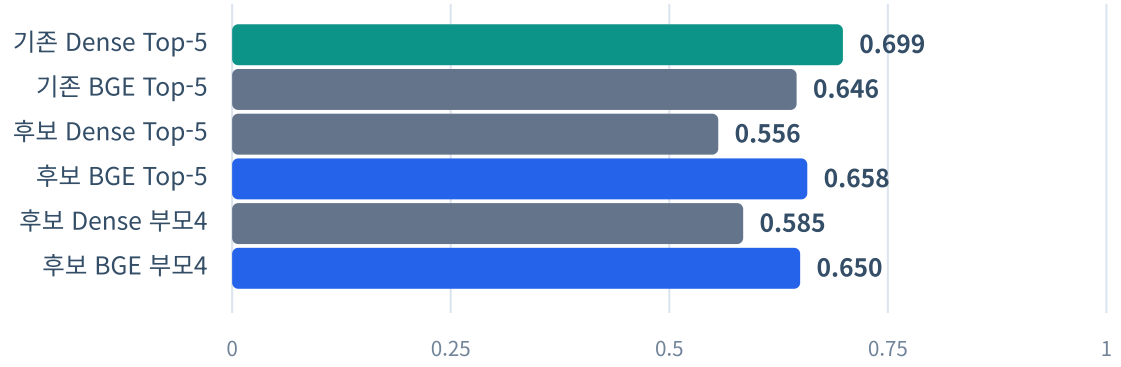
생성 모델 선택 · 전처리 전 DEV30 · 심판 2판

모델	정확성 /5	근거 충실도 /5	거절 정확도	p95
EXAONE 3.5 7.8B	3.83	4.23	1.000	9.6초
Qwen 3.5 9B	3.77	4.73	0.857	14.0초
Gemma 4 12B	미측정	미측정	미측정	미측정

EXAONE은 정확성이 비슷한 상황에서 거절·속도를 보고 선택했다. Qwen은 근거 충실도가 더 높았다. Gemma는 당시 메모리 한도로 실행하지 못했으므로 품질 탈락이 아니다.

100문서·168문항 · 2026-10-09 검색만 비교

원문에 존재하는 인용 근거의 회수율 · 분모 491개



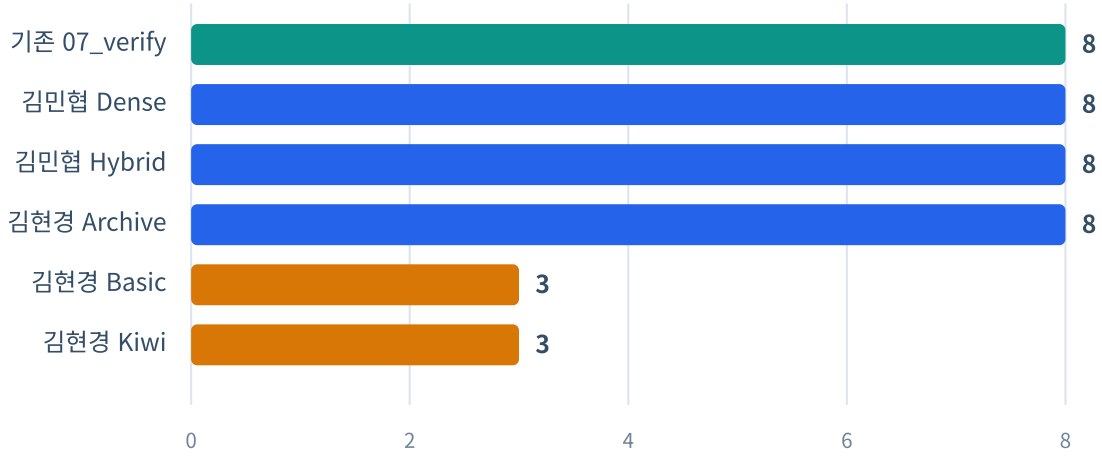
같은 후보 안의 비교	근거 회수율	전체 근거 확보 문항	평균 문맥 토큰
Dense Top-5 → BGE Top-5	0.5560 → 0.6578	81 → 89 /168	1,420 → 2,046
Dense Top-5 → Dense 부모4	0.5560 → 0.5845	81 → 87 /168	1,420 → 2,824
기존 Dense Top-5	0.6986	95 /168	2,238

판정 후보 내부의 재순위·문맥 확장 이점은 있다. 기존 Dense가 이 집단의 인용 근거 회수율은 더 높다. 생성·심판 호출은 0회이며 최종 선정은 pending이다. 168문항은 14개 사업에 묶여 있고, 이 토큰 예산은 EXAONE 전체 프롬프트와 다르다.

팀원 평가: 처리 성공과 품질 채택을 나눠 보았다

2026-10-12 · 원본 100문서 재구축 · 동일 DEV8을 6구성에 적용 · 공통 생성 gpt-6-luna/low.

정상 답변 처리 건수 · 구성별 최대 8건 · 정확도가 아님



구성	정상/시도	주요 문제	판정
기존 07	8/8	Q21 세부조건 누락, Q12 기관 범위 주의	기준 유지
김민협 Dense	8/8	다른 기관 요구 혼입, Q13 기간 누락	보류
김민협 Hybrid	8/8	수량 일부 회복, 기관 혼입·비교 대상 누락 잔존	보류
김현경 Archive	8/8	목적·근거 장점, 상세조건·기간 누락	보류
김현경 Basic	3/8	사업명 인식 소스 오류 5건, 대화·다중 비교 한계	보류
김현경 Kiwi	3/8	같은 오류 5건, Kiwi만의 개선 미입증	보류

실제 반영
메인의 JSON 응답 처리·항목별 근거 검증 결함을 로컬 커밋 `9f7c5ce`로 수정했다. 팀원 전체 구성의 우승을 뜻하지 않는다.

수정본의 경계
김현경 원형 A 파싱 99/100 → 별도 B 100/100. 기존 성공 99문서는 공백 정리 뒤 동일했다. 메인 파서에는 같은 실패가 없어 이식하지 않았다.

해석 한계 정상 38/48·오류 10/48은 처리 결과다. 독립 질문 48개가 아니다. 원래 EXAONE·KULLM3 생성기 재현도 아니다. 제출본을 확보하지 못한 권유진·이원영은 품질 탈락 판정을 하지 않는다.

평가지표: 무엇을 측정했는지 먼저 맞춘다

같은 이름이라도 정답 단위·분모·평가기·채점 판이 다르면 직접 비교할 수 없다.

비교 집단	규모·생성/평가	이 보고서의 사용 범위
기존 검색	개발 30문항 · 검색 지표	KURE·청킹·검색 방식 비교. 전처리 전.
기존 생성	DEV30·확인10 · Claude 심판 2판/3판	판별·표본을 나눠 표시. 5점 척도.
확장 검색	100문서·168문항 · 생성 없음	인용 근거 회수·문맥 부담만 비교.
팀원 native	100문서·공통 DEV8 × 6 · Luna	처리·오류·직접 의미 검토. 전체 정확도로 환산하지 않음.
EXP 초기	008~014 · 10문항 · GPT-5 mini 평가	Factual Correctness 기록값. 생성 모델·동일 조건 미확인.
EXP 대규모	015~022-E · 100문서·300문항	문서 검색 Hit@5. 생성·평가 GPT-5 mini.
EXP 후속	023 이후 · 주로 10문서·30문항	청크 검색으로 설명됨. Haiku 생성·Gemini 평가. 상태·설정 누락 표시.

지표	답하는 질문	주의할 점
Hit@5	상위 5개 안에 정답이 하나라도 있는가?	문서/청크 기준을 구분. 전체 근거 확보율·답변 정답률이 아니다.
MRR	첫 정답이 얼마나 앞에 있는가?	첫 정답 순위 역수의 평균. 여러 근거의 회수 여부는 알 수 없다.
사실·근거 재현율	필요한 사실이 검색 문맥에 들어갔는가?	기존 fact_recall·인용 회수율·최신 근거 문장 재현율은 구현·분모가 다르다.
근거 전부 전달	필요한 근거를 모두 전달한 문항은 몇 개인가?	생성 모델이 근거를 모두 활용했는지는 별도다.
Judge / 정확성	평가 모델은 답을 어떻게 채점했는가?	기존 5점과 최신 0~1은 별도 척도. 단순 환산해 비교하지 않는다.
Factual Correctness	기준 답과 사실적으로 얼마나 일치하는가?	RAGAS mode·설정 미확인. 일괄적으로 F1·정답률이라 부르지 않는다.
거절·환각·지연	유용성과 안전성·부담은 어떠한가?	답 있음/없음 분모, 주장 채점 판, 실제 지연·비용 측정 조건 확인.

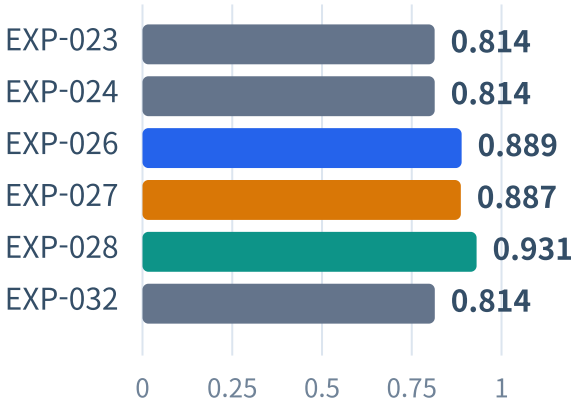
표기 규칙 0~1 점수 차이는 Δ점수, 비율 차이는 %p로 쓴다. 30문항에서 1문항은 약 3.33%p다. 미평가·미실행을 0점으로 바꾸지 않는다. 통계 검정·신뢰구간·재현 실험은 이번에 수행하지 않았다.

최신 버전 비교: 검색 지표와 답변 지표의 방향이 다르다

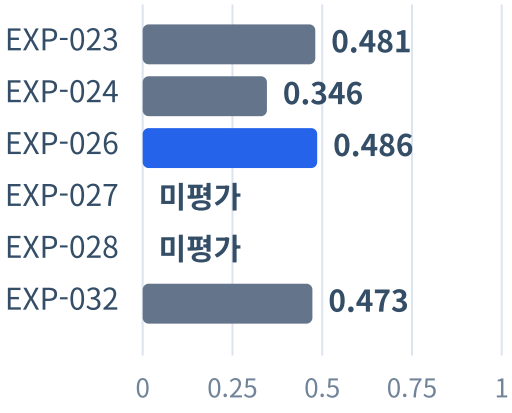
주로 10문서·30문항 · EXP-023 기준행 · 동일 문항·실행 설정은 원본 결과로 추가 확인이 필요하다.

실험·변경	Hit@5	MRR	Judge	사실 일치
EXP-023 GTE 리랭커 기준[1]	0.9667	0.8137	0.9383	0.4807
EXP-024 일반 BM25[2]	0.9667	0.8139	0.9167	0.3460
EXP-025 프롬프트 개선·잠정[3]	0.9667	0.8137	0.9400	0.5417
EXP-026 BGE 리랭커	1.0000	0.8889	0.9367	0.4860
EXP-027 026+사업명 헤더	0.9333	0.8867	0.9367	—
EXP-028 026+1000/200·프롬프트 v2	1.0000	0.9306	0.9467	—
EXP-032 Dense 단독	0.9667	0.8141	0.9433	0.4727

MRR · 0~1



Factual Correctness · 0~1



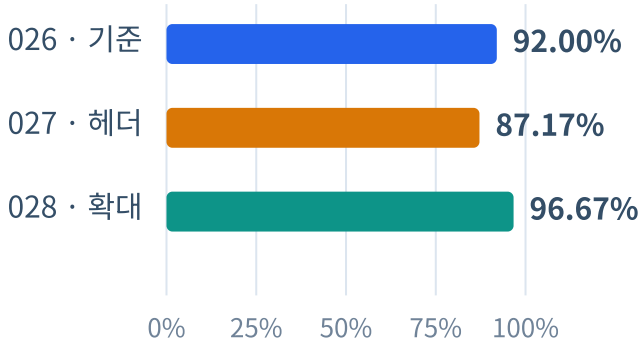
026의 효과 023 대비 Hit@5 29/30→30/30, MRR +0.075214. Judge는 −0.001666, 사실 일치 점수는 +0.005333으로 답변 품질의 뚜렷한 개선을 입증하지 못했다.

비교 경계 [1]023은 완료·미실행 설명이 충돌한 기준값이다. [2]024는 청킹·임베딩 칸이 비어 있다. [3]025는 계획·미실행과 점수가 공존해 잠정값으로만 표시하고 그래프·완료 성과에서 제외했다. 027·028의 —는 RAGAS 미평가다.

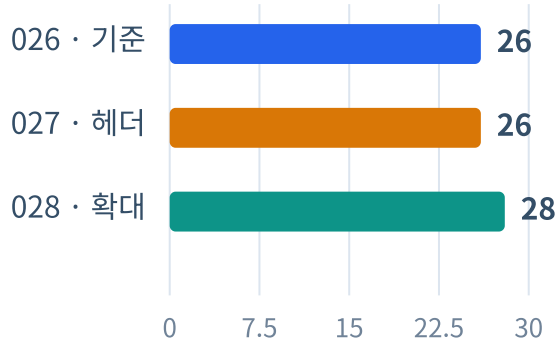
근거 전달: 정답 하나를 찾는 것과 전부 모으는 것은 다르다

EXP-026 → 027은 헤더 추가, EXP-026 → 028은 청크 확대다. 027을 거쳐 028이 된 순차 실험이 아니다.

상위 5개 근거 문장 재현율 · %



근거 전부 전달 · 문항 수 /30



항목	026	027 · 헤더	028 · 확대
Hit@5	30/30	28/30	30/30
MRR	0.888889	0.886667	0.930556
상위 5개 근거 재현율	92.00%	87.17%	96.67%
전달 문맥 6개 근거 재현율	93.67%	91.33%	96.67%
근거 전부 전달	26/30	26/30	28/30
타 사업 청크 혼입	3/30	0/30	2/30
문항당 문맥 길이	3,545자	미기록	5,122자

028 · 전체 근거 전달

+2문항

+6.67%p · 아직 2문항은 일부 근거 누락

028 · MRR 변화

+0.041667

026 대비 기록값 차이

028 · 문맥 길이 증가

+1,577자

+44.5% · 품질·비용 최적점은 미확인

남은 실패 028의 직접 사실 문항 누락은 해결됐다는 관찰이 있다. 다중 섹션 재현율은 0.90으로 동일했고 DOC001-Q03은 2/3, DOC010-Q03은 1/3의 근거만 전달했다.

효과의 범위 Judge는 0.936667→0.946667이나 프롬프트도 v2로 바뀌었다. 이를 청킹만의 답변 개선량으로 쓰지 않는다. 실제 토큰·요금·응답 시간 증가율은 측정하지 않았다.

기술을 선택한 이유: 문제와 실험 근거를 연결했다

구현 가능한 이유와 비교에서 우세했던 이유를 구분했다. 기록에 없는 선정 근거는 보충하지 않았다.

기술·방법	사용한 핵심 이유	남아 있는 근거와 판단
원문 HWP·PDF 추출	CSV 본문만으로 세부 요구사항이 부족했다.	olefile의 당시 HWP 중앙값 0.02초. 표의 완전 복원은 미입증. PyMuPDF의 경쟁 도구 대비 정확도 우승 기록은 없다.
LangChain·Chroma	부품을 바꿔 조립하고 청크·벡터를 로컬에 보관한다.	모델·청크별 색인 분리. 다른 프레임워크·DB보다 우수하다는 비교 자료는 없다.
질문 분류·사업 식별	한 문서·여러 문서·후속 질문에 맞는 근거를 제공한다.	기존 정확성 3.07→3.83. 최신 기록의 사업 식별 실패는 28/30으로 남아 모든 질문에서 해결된 것은 아니다.
KURE / BGE-m3-ko	한국어 문서에서 필요한 근거를 찾는다.	기존 검색30에서는 KURE 우위. EXP 초기10의 답변 사실 일치에서는 BGE-m3-ko 0.895. 집단·지표가 달라 모순은 아니다.
Kiwi BM25 + Dense	한국어 낱말 일치와 의미 유사도를 함께 탐색한다.	Kiwi는 형태소 토큰을 만든다. 최신 Dense 단독과 비교한 일관된 우위는 미입증. 기존 메인에도 같은 계열 기능이 있었다.
BGE 리랭커	검색 후보 중 정답 근거를 앞쪽에 배치한다.	EXP-026에서 Hit@5·MRR 상승. 기존 검색에서는 재순위를 꺼 두었다. 데이터·리랭커·구성이 달라 자동 소급하지 않는다.
큰 청크·겹침	서로 이어진 근거가 경계에서 분리되는 문제를 줄인다.	EXP-028 전체 근거 26→28/30, 문맥 +44.5%. 1000/200의 보편적 최적성은 미입증.
JSON·근거 ID·숫자 확인	답과 출처를 연결하고 일부 형식·수치 오류를 막는다.	재현 가능한 계약 결함은 수정했다. 숫자가 근거에 있어도 관계·귀속이 맞는지 의미 검토가 필요하다.

문서 준비
추출 → 청크·메타데이터 → 색인·요약

→

질문 처리
분류·사업 식별 → 검색·재순위 → 생성 → 검증

> **현재 검토 방향** EXP-028의 BGE-m3-ko + Dense·Kiwi + BGE 리랭커 + 1000/200을 근거 전달 관점의 우선 검증 후보로 둔다. 운영 채택·배포를 확인한 것은 아니다.

이전 평가 반영: 적용된 변경과 남은 검증을 분리했다

아래 표는 “개선안을 제시했다”와 “코드에 반영했다”와 “효과를 검증했다”를 따로 보여 준다.

이전 지적·평가	후속 조치	현재 판정
원문 검수·전처리가 부족함	EDA, 청크·색인·요약 재구축. 읽힘 기준을 추가함.	절차 보강. 임계값의 근거·정제의 품질 개선은 미입증.
답변 의도·누락 채점이 느슨함	심판 2판 강화, 3판 주장 단위·전체 근거 대조.	채점 절차 반영. 판이 다른 점수를 합치지 않음. 사람 평가와 일치도 미확인.
후보 원본과 통합 수정이 섞임	제출 SHA 고정, 원형 A·수정 B 분리, M/A/B 비교.	출처·변경 경계 반영. A의 실패를 B의 성공으로 소급하지 않음.
JSON·항목별 근거 검증 결함	메인 로컬 커밋 9f7c5ce로 계약 결함 수정.	코드 반영 확인 기록. 원격 배포·운영 적재는 이번에 확인하지 않음.
팀원 구성 전체 개선 미입증	DEV8 누락·기관 혼입·사업명 오류 보존.	전체 대체 보류. 단순히 8/8 처리됐다고 채택하지 않음.
문서 hit가 높아도 근거 부족	최신 실험에서 근거 문장·전체 근거 전달을 분석.	026의 Hit@5 1.0에도 4문항 누락. 028은 2문항으로 감소.
타 사업 혼입·이름 매칭 실패	009 사업별 검색, 027 사업명 헤더 실험.	초기 혼입 감소. 027은 검색 손실로 미채택, 라우팅 실패는 잔존.
팀이 공정별로 바꾸기 어려움	최소 모듈러의 Document→Chunk→SearchHit→Answer 규약.	합성 2문서 연결 확인. 분류·기억·평가·의미 검증은 당시 잔여 범위.

이 보고서에서 바꾼 설명

오해하기 쉬운 표현	최종 리포트의 표기
“검색 99.33% = 답변 정확도”	300문항의 문서 검색 Hit@5 0.993333. 답변 사실 일치 0.5991은 별도 점수.
“최신 구성으로 이미 전부 교체”	기존 비교 기준 유지 / 최신 채택 후보 / 연결 기준선을 구분.
“청크 확대가 답변 품질을 올림”	근거 전달은 증가. 프롬프트 동시 변경·RAGAS 미평가로 생성 효과 보류.
“38/48 정확도·52번 실험”	38/48은 정상 처리, 52개는 버전 설명 항목. 동일 조건 독립 평가 횟수가 아님.

최종 판단과 후속 과제: 답변 품질을 같은 조건에서 확인한다

확인된 검색 성과는 유지하되, 데이터 충돌·다중 근거·생성 효과를 다음 검증 대상으로 둔다.

우선순위	다음에 확인할 것	완료 증거
1 · 기록 정리	023·025 상태, 010·011 점수/설명, 024 설정, 029 리랭커를 정리.	실행 ID·설정·상태·문항별 결과가 일치한 기록. 기존 수치 임의 수정 금지.
2 · 생성 효과 분리	BGE·700/100·새 프롬프트를 확정해 028과 비교.	동일 문서·30문항·답·생성/평가 모델에서 청킹만 다른 결과. EXP-034 결과 확보.
3 · 다중 섹션 회수	요구사항 단위·child-parent 청킹 검토.	DOC001-Q03·DOC010-Q03의 누락 근거와 전체 전달율, 문맥 길이 대조.
4 · 사업 라우팅	정식 사업명이 없는 질문의 사업 카드·전체 검색 복귀.	라우팅 정답·오선택·기관 혼입·되묻기를 별도 집계. EXP-031.
5 · 단순화·실제 부담	Dense 단독과 하이브리드, 실제 토큰·요금·p95 비교.	문항별 원본·반복 평가·측정 조건. 문자 수를 비용으로 환산하지 않음.

미실행·진행 중인 계획

실험	변경안	현재 상태·주의
029	요구사항 표 한 개를 한 청크로 유지	계획·수치 없음. 기준은 BGE인데 리랭커 칸 GTE로 불일치.
030	text-embedding-3-small	계획·수치 없음. 새 호출 전 범위·비용 승인 필요.
031	사업 카드 기반 검색 범위 제한	계획·수치 없음. 정식명 없는 질문을 포함해야 함.
033	child-parent 청킹	계획·수치 없음. 근거 회수와 문맥 부담 함께 비교.
034	새 프롬프트 + 새 리랭커	진행 중·수치 없음. 028의 생성 효과 분리에 필요.

이번 작성에서 확인한 결정 사용자가 기존 기록 기준 작성을 선택했다. EXP-023은 상태 충돌이 있는 기준행, EXP-025는 잠정값, EXP-028은 채택 후보로 표시했다. 최신 결과를 임의로 추정하지 않았다.

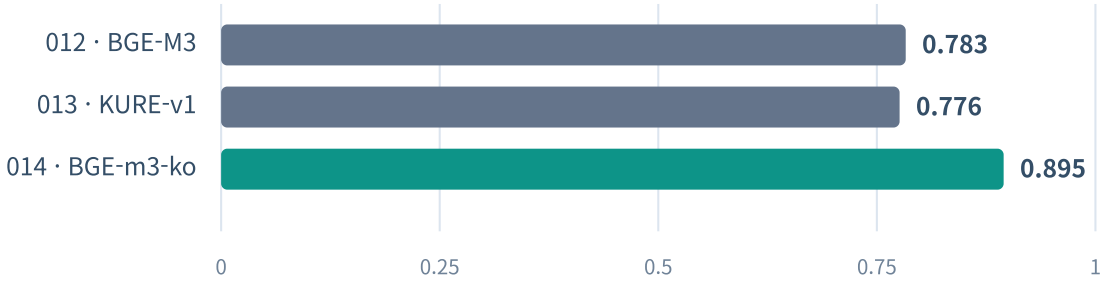
이번 납품 범위 요약·대조·계산·그래프·HTML/PDF 작성. 후속 실험·유료 호출·원본 시트 정정·메인 교체는 수행하지 않았다. 자료만으로 필요한 보고서를 완성할 수 있어 추가 승인 때문에 납품을 멈추지 않는다.

부록 A · EXP-001~014의 핵심 변경과 판정

전체 과정의 누락을 막기 위한 기록표다. 초기 점수와 최신 30문항 점수는 직접 연결하지 않는다.

실험	무엇을 바꿨나	결과	해석·판정
EXP-001	PDF 1개·500/100·KoE5·Qwen2.5-3B	기본 흐름 구현	수치 없음. 초기값 최적성 미입증
EXP-002	PDF/HWP·표 Markdown·700/100·GTE·EXAONE	문서 처리 확장	생성 저하·불필요 청크로 HyDE 비교 보류
EXP-003	text-3 embedding·GPT-5 mini로 동시 교체	정성 개선	개별 기여도·정확한 임베딩 ID 미확인
EXP-004	Dense/BM25 각8→재순위 상위4	구조 점검	HyDE 일반 질문과 큰 차이 없음·일반 질문 사용
EXP-005	AI 검색·답변 평가 도입	평가 기능 구현	점수·심판 모델 미기록
EXP-006	RAGAS·Qwen2.5-1.5B 평가 코드	평가 구체화	문항별 결과 미기록
EXP-007	팀 정제 단계 적용	효과 보류	성능 낮아 비교 불가
EXP-008	top-k 확대	사실 일치 0.813	변화 없음 관찰·타 사업 혼입·k 미기록
EXP-009	사업별 검색	사실 일치 0.838	혼입 감소 관찰·008 대비 +0.025
EXP-010	사업별 검색에 정제 재적용	사실 일치 0.909	“큰 차이 없음” 설명과 수치 차이 유의
EXP-011	700/100→1000/200	사실 일치 0.354	“큰 차이 없음”과 직전 −0.555 충돌
EXP-012	BAAI/bge-m3·700/100	사실 일치 0.783	답변 지표. 청킹 복귀·점수 미기록 설명 충돌
EXP-013	KURE-v1·700/100	사실 일치 0.776	답변 지표. 개별 점수 미기록 설명 충돌
EXP-014	BGE-m3-ko·700/100	사실 일치 0.895	기록된 세 임베딩 중 최고·초기10문항 한정

초기 임베딩 비교 · Factual Correctness · 10문항



지표 경계 위 임베딩 비교는 검색 Hit@5가 아니라 생성 답변의 사실 일치 기록값이다. 생성 모델 칸과 전체 동일 조건은 미확인이다. EXP-010·011의 충돌은 정제·크기 효과를 확정하는 근거로 사용하지 않았다.

부록 B · EXP-015~034의 핵심 변경과 판정

015~022는 여섯 구성 A~F로 묶인 기록이다. 여덟 실험 번호에 억지로 일대일 대응하지 않았다.

EXP	핵심 변경	기록 상태	수치·판정
015~022-A	Kiwi BM25 단독·재순위 없음	완료	정답 청크 초기 순위가 좋다는 관찰·수치 없음
015~022-B	일반 BM25 단독	완료	개별 결과 미기록
015~022-C	Dense + Kiwi BM25	완료	개별 결과 미기록
015~022-D	Dense + 일반 BM25	완료	개별 결과 미기록
015~022-E	Dense + Kiwi + GTE 재순위	완료	100문서·300문항: 문서 Hit@5 0.993333, MRR 0.967, Judge 0.7699, 사실 일치 0.5991
015~022-F	Dense + 일반 BM25 + GTE	완료	점수 원본 미확인·수치 공란
023	700/100·BGE-m3-ko·Kiwi·GTE	상태 충돌	점수 있는 후속 기준행·완료/미실행 충돌
024	일반 BM25로 변경	완료	사실 일치 0.3460·청킹/임베딩 공란
025	프롬프트 개선	잠정	사실 일치 0.541667 기재·계획/미실행과 충돌
026	GTE→BGE 리랭커	완료	Hit@5 1.0·MRR 0.888889·전체 근거 26/30
027	026+사업명·발주기관 헤더	완료·미채택	혼입 3→0/30, Hit@5 30→28/30·RAGAS 없음
028	026+1000/200·프롬프트 v2	완료·후보	MRR 0.930556·전체 근거 28/30·RAGAS 없음
029	요구사항 표 한 개를 한 청크	계획	결과 없음·리랭커 표기 불일치
030	text-embedding-3-small	계획	결과 없음
031	사업 카드 라우팅	계획	결과 없음
032	BM25 제거·Dense 단독	완료	기준 대비 Judge +0.005·사실 일치 −0.008·방향 혼재
033	child-parent 청킹	계획	결과 없음
034	새 프롬프트·새 리랭커	진행 중	결과 없음

300문항 결과 0.993333은 분모 300을 적용하면 약 298/300이다. 시트 정정에 따라 문서 검색 성과로 표시했다. 30문항의 청크 검색 성과와 별도 집단이다.

보존 자료 실험 기록 32행 CSV · 이전 52개 버전 설명 목록 · 팀원 6구성 결정 CSV. 전체 기록을 함께 전달하며, 본문은 판단에 필요한 변경만 추렸다.

근거와 검증 범위

원본을 읽은 범위와 이번에 확인한 범위를 구분했다. 보고서의 수치는 별도 명시가 없으면 기존 실행의 기록값이다.

ID	대조한 자료	뒷받침하는 내용
S1	10/16 RAG_실험_기술보고서	실험 배경·수치·불일치·후속 계획. 원본 HTML과 로컬 Markdown을 확인.
S2	10/14 팀원자료_평가와반영경위 / 설계과정	초기 선택·M/A/B·채택 기준·저장소 목적. 기존 PDF 대응 원문을 사용.
S3	기존 프로젝트 기술문서	검색 사다리·생성 버전·모델·채점 판·제약. 해당 절을 직접 대조.
S4	10/12 native 기술보고서·결정 CSV	6구성 DEV8·처리 실패·구체적 보류 사유. CSV 직접 대조.
S5	10/16 원본시트 스냅샷·CSV	32개 실험 기록 행·24열. 점수와 차이·문항 수 환산에 사용.
S6	10/09 full-retrieval 집계 JSON	168문항·491개 원문 존재 근거·6검색 구성·문맥 토큰. 집계 필드 직접 대조.
S7	기존 version-catalog-complete.csv	52개 버전 설명 항목. 기존 설정·미실행·채점 변경의 경계.
S8	10/14 상세 기술리포트·관련 인계	기존 발표 메인과 새 최소 모듈러를 분리한 방향 확인.
S9	00·06·07·08·09·10·11·12 결과 JSON	metrics.overall을 읽어 이전 생성 수치·분모·p95 대조. 문항별 재채점은 하지 않음.

이번 작업에서 한 일

기존 자료 읽기, 점수·집계 필드 대조, 차이·비율 재계산, 상태 충돌 표시, 그래프·표 재구성, 읽기 전용 HTML과 PDF 제작. 출처 경로·SHA256은 출처와 계산 파일에 보존했다.

결론의 제한

시트 최신값 재조회, 실험 재실행, 문항별 검색·생성 재현, 신규 채점, 통계 검정, 모델 호출·비용·토큰·운영 적재 확인은 하지 않았다. 10월 14일 이전 설계·팀 평가의 사실은 당시 문서와 보존 결과의 범위다. 원격 저장소의 현재 상태로 확대하지 않는다.

> **전달 형식** HTML은 외부 자료 없이 표·그래프를 볼 수 있다. PDF는 같은 본문을 인쇄한 문서다. CSV·근거 JSON은 같은 폴더의 보조 자료다. 기존 검토자료는 보존하고 `09_최종평가_20261016`을 추가한다.

대화는 이 보고서를 연 채팅에서 이어갑니다

보고서는 결과를 확인하는 화면입니다. 질문, 의견, 수정 요청은 Codex의 해당 채팅에 적어 주세요.

보고서의 자동 답변과 응답 대기는 꺼져 있습니다.